Софийски университет „Св. Климент Охридски“
Факултет по математика и информатика
Катедра „Компютърна информатика“

ДИПЛОМНА РАБОТА

Система за извличане с генериране (RAG) за достъп до фармакотерапевтични ръководства на български език

Цветелина Пашовска
Магистърска програма „Изкуствен интелект“, фак. номер 7MI3400669

Ръководител:
проф. д-р Мария Нишева
катедра „Компютърна информатика“, ФМИ, СУ „Св. Климент Охридски“

София, 2026

Съдържание

1 Увод **3**

1.1 Достъп до медицинска информация на български език и ролята на извличането с генериране . . . 3

1.2 Цели и задачи на дипломната работа . . . 4

2 Литературен обзор **4**

2.1 Архитектура и компоненти на системите за извличане с генериране . . . 4

2.2 Методи за извличане и модели за векторно представяне . . . 6

2.3 Приложения в областта на медицината . . . 6

2.4 Особености при работа с по-слабо ресурсни езици . . . 7

3 Методология **8**

3.1 Корпус от данни . . . 8

3.2 Изграждане на векторно представяне и индексиране . . . 9

3.3 Извличане на релевантни откъси . . . 10

3.4 Генериране на отговори . . . 11

4 Експерименти и резултати **12**

4.1 Демонстрационно приложение . . . 12

4.2 Подобряване на резултатите – съставяне на подсказката към генеративния модел . . . 15

4.3 Подобряване на резултатите – хибридно извличане, повторно класиране и праг за отказ . . . 20

4.4 Подобряване на резултатите – проверка на отговора за неподкрепени в откъсите детайли . . . 27

4.5 Подобряване на резултатите – маркиране на изреченията, на които стъпва отговорът . . . 29

4.6 Подобряване на резултатите – проверка дали ключовите понятия от въпроса ги има в откъсите . . . 30

4.7 Качествен анализ и оценка . . . 32

5 Техническа реализация **38**

5.1 Използвани инструменти и технологии . . . 38

5.2 Структура на проекта и файлове . . . 39

5.3 Проверка и възпроизводимост . . . 41

6 Изводи и препоръки за бъдещо развитие **42**

7 Заключение **42**

Приложения **45**

Приложение 1. Инсталиране и стартиране 45

1 Увод

1.1 Достъп до медицинска информация на български език и ролята на извличането с генериране

Фармакотерапевтичните ръководства, публикувани от Националния съвет по цени и реимбурсиране на лекарствените продукти [1], съдържат клинично и нормативно значима информация за десетки медицински области, но са структурирани като обемни PDF документи с разнородно вътрешно оформление. За здравен специалист, който търси конкретна препоръка, дозировка на лекарство или противопоказание, това на практика означава ръчно търсене в десетки страници, дори когато отговорът вече е формулиран в официално одобрен документ. Проблемът тук не е липса на информация, а нейната трудна дотъпност в момента на вземане на клиничното решение.

Тази трудност се потвърждава и от самите лекари. В курсов проект по избираемата дисциплина „Методология на изследователската работа“ авторът на настоящата дипломна работа проучва нагласите на общопрактикуващите лекари в България към системите с изкуствен интелект чрез анкета, попълнена от 13 лекари в периода април – юни 2025 г. [2]. На въпроса при кои предизвикателства подобни системи биха им били от най-голяма полза 7 от 13 анкетирани посочват трудния достъп до актуална медицинска информация. Това е третият по честота отговор след координацията със специалисти (9) и проследяването на хронични заболявания (8), а в свободен текст един от лекарите назовава изрично като очакване „възможен достъп до медицински стандарти“. Същото проучване очертава и условията, при които такава система би била използвана. Най-честото притеснение е опасността от грешки (11 от 13), следвано от нарушаването на поверителността (6) и липсата на прозрачност (5), а като най-силни фактори за решението да започнат да я използват 12 от 13 лекари посочват научните доказателства за точност и лесната употреба. Тези очаквания съответстват пряко на проектните решения в настоящата система: при липса на подходящ откъс от ръководствата тя отказва да отговори (раздел 4.3), генерираният отговор се проверява за неподкрепени детайли (раздел 4.4) и се придружава от източниците си с отбелязани съответстващи изречения (раздел 4.5), а цялата обработка се извършва локално, без въпросите да напускат компютъра на потребителя (раздел 4.1). Извадката обаче е малка и непредставителна, тъй като преобладават лекари под 30-годишна възраст, със стаж под три години и с практика в столицата. Затова резултатите се приемат като ориентир за нуждите на практиката, а не като статистически обоснован извод.

Система от типа извличане с генериране (Retrieval-Augmented Generation, RAG) предлага пряко решение на този проблем. Вместо да разчита единствено на параметричната памет на езиков модел, която може да бъде остаряла или неточна за специфична за България нормативна база, системата извлича релевантни откъси от актуалните ръководства и генерира отговор въз основа на тях, придружен от изричен източник: документ, страница и раздел. Именно възможността отговорът да бъде проследен до конкретен официален документ прави подхода особено подходящ за медицински контекст, в който грешен или непроверим отговор носи реален риск, а не само неудобство.

Настоящата дипломна работа надгражда резултатите от преддипломния проект [3], в който бе изграден и структуриран корпус от 1380 откъса от 17 национални фармакотерапевтични ръководства, готов за индексиране, като всеки откъс носи данни за произход (provenance): документ, страници и раздел. След преглед на научната литература (arXiv, ACL Anthology, RANLP) и общодостъпни източници на български език не беше открита

публикувана система от типа извличане с генериране, насочена конкретно към медицински или фармакотерапевтични ръководства на български език. Намерените български публикации по темата са предимно общи, популярни разяснения на подхода, а не описания на реализирана система върху национален медицински корпус. Тази празнина е допълнителна мотивация за настоящата работа: тя не само прилага установен подход към нов, специализиран корпус, но го прави за език и предметна област, за които все още липсва пряк аналог.

1.2 Цели и задачи на дипломната работа

Основната цел на тази дипломна работа е да се разработи работещ прототип на система за извличане с генериране за достъп до национални фармакотерапевтични ръководства на български език, използвайки резултатите от преддипломния проект и надграждайки с компоненти за извличане на релевантна информация и генериране на отговори.

За постигането на тази цел са поставени следните задачи:

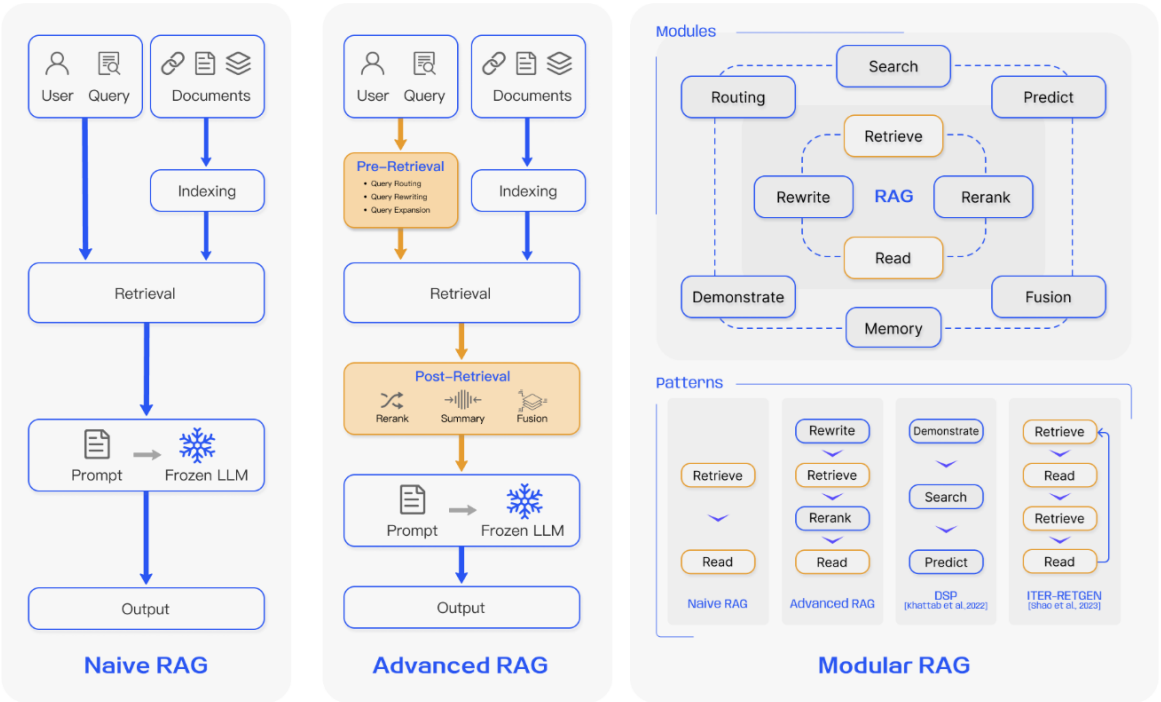
1. аналитичен обзор на литературата по системи за извличане с генериране, методи за извличане (retrieval), приложения в областта на медицината и особености при работа с текст на български език;
2. изграждане на векторно представяне (embeddings) на структурираните в преддипломния проект текстови откъси с многоезичен модел, подходящ за българския език, и индексиране във векторна база от данни;
3. реализация на компонент за извличане на релевантна информация (retrieval) по зададена заявка;
4. проектиране и имплементиране на слой за генериране на отговори на база извлечен контекст (prompt engineering);
5. разработване на демонстрационно уеб приложение за задаване на въпроси и преглед на генерираните отговори;
6. качествен анализ на примерни резултати от системата, включващи въпроси от различни медицински области, и дискусия на наблюдаваните ограничения;
7. формулиране на изводи и препоръки за бъдещо развитие.

2 Литературен обзор

2.1 Архитектура и компоненти на системите за извличане с генериране

Подходът извличане с генериране (Retrieval-Augmented Generation, RAG) е предложен от Lewis и др. [4] като начин да се съчетаят параметричната памет на голям езиков модел с непараметрична памет под формата на външен, обновяем корпус от документи: вместо да разчита единствено на теглата си, моделът получава по заявка извлечени откъси и генерира отговор въз основа на тях. Тази идея решава едновременно два практически проблема: ограничената и статична памет на езиковите модели и невъзможността отговорът да бъде проверен спрямо конкретен източник. Същевременно обаче тя прехвърля тежестта на верността на отговора върху качеството на извличането, а не само върху генеративния модел.

По-новите систематизиращи прегледи очертават еволюция от тази първоначална, линейна схема, при която заявката преминава последователно през извличане, допълване на подсказката (prompt augmentation) и генериране, към т.нар. модулна архитектура, при която всеки компонент – индексиране, извличане, преработка на извлечения контекст, генериране – е независимо заменяем и може да се комбинира с допълнителни стъпки, като преформулиране на заявката или повторно класиране на резултатите [5]. Gao и др. [6] описват тази еволюция като три последователни парадигми (фигура 1): наивна (naive), при която индексирането, извличането и генерирането са свързани във верига; усъвършенствана (advanced), която запазва веригата, но добавя стъпки преди извличането, като преформулиране на заявката, и след него, като повторно класиране; и модулна (modular), при която компонентите могат да се заменят, повтарят и пренареждат. Sharma [7] систематизира съществуващите варианти в няколко ориентации, насочени съответно към подобряване на извличането, на генеративния модул, към хибридни решения и към устойчивост спрямо шумни или противоречиви извлечени откъси, и посочва качеството на извличането като най-честото тясно място в цялостната система. Като по-нататъшно развитие се откроява агентният подход (agentic RAG), при който системата итеративно решава дали и какво да извлече, вместо да следва фиксирана еднократна последователност [8]. За целите на настоящата дипломна работа подобна сложност не е оправдана, тъй като въвежда допълнителна латентност и трудности при проследяване на произхода на отговора, без да е ясно, че ще подобри резултата върху затворен и сравнително добре структуриран корпус от национални ръководства. Затова избраната отправна точка тук е модулна, но не агентна архитектура, съобразена със структурата, зададена от преддипломния проект: индексиране на откъсите, самостоятелен компонент за извличане и отделен слой за генериране, всеки от които може да бъде подобряван независимо.



Фигура 1: Три парадигми на системите за извличане с генериране: наивна, усъвършенствана и модулна. Източник: Gao и др. [6], фиг. 3.

Оценяването на подобни системи е отделен методологически въпрос: освен показателите за самото извличане (виж 2.2), генерираният отговор трябва да бъде проверен за вярност спрямо извлечения контекст, тъй като езиковият модел може да „халюцинира“ твърдения, които не се съдържат в подадените откъси. Malin и др. [9] систематизират съществуващите показатели за вярност (faithfulness) и отбелязват, че оценяването с друг езиков модел като съдия към момента корелира най-добре с човешката преценка, докато Tamber и др. [10] предлагат постоянно обновяван еталон именно за тази цел. Тези резултати мотивират методиката за качествен анализ в тази дипломна работа (виж раздел 4.7) да включва не само проверка на извлечения източник, но и отделна преценка доколко генерираният отговор се придържа само към предоставения контекст.

2.2 Методи за извличане и модели за векторно представяне

Класическото разграничение в извличането на информация е между лексикално извличане, което съпоставя точни думи или n-грами (например BM25), и семантично извличане, при което заявката и документите се представят като вектори в общо пространство и се сравняват чрез мярка за близост, най-често косинусова близост, независимо от точното съвпадение на думите. Лексикалното извличане е бързо, обяснимо и не изисква обучение, но пропуска синоними и перифрази. Семантичното извличане улавя смисъла, но зависи изцяло от качеството на модела за векторно представяне (embeddings) и е по-трудно за диагностициране, когато върне грешен резултат. За медицински текст, богат на синоними, съкращения и специализирана терминология, например различни търговски и генерични названия на едно и също лекарство, семантичното извличане изглежда по-подходящо. Именно поради тази специализирана терминология обаче качеството на векторното представяне не бива да се приема за дадено, а трябва да бъде проверено емпирично (виж раздел 3.2).

Що се отнася до самите модели за векторно представяне, Luo и др. [11] показват, че използването на голям езиков модел като енкодер за плътно извличане (dense retrieval) подобрява точността спрямо по-малки специализирани енкодери, но с чувствително по-висока изчислителна цена. Този компромис трябва да се претегли спрямо ограничените изчислителни ресурси на дипломна работа и необходимостта системата да отговаря в разумно време при демонстрация. Извличането по правило се комбинира с векторна база от данни, оптимизирана за приблизително търсене на най-близки съседи. Неотдавнашно емпирично изследване на седем широко използвани системи – FAISS, Qdrant, Milvus, Weaviate, Chroma, pgvector и LanceDB – показва съществени разлики в компромиса между точност, латентност и консумация на памет в зависимост от индексиращата структура [12]. Това налага изборът на векторна база в тази дипломна работа (раздел 3.2) да бъде направен според мащаба на корпуса от преддипломния проект, тоест 1380 откъса, а не според общи препоръки за много по-големи колекции.

2.3 Приложения в областта на медицината

Систематизиращият преглед на He и др. [13] обхваща технологиите, наборите от данни и клиничните приложения на извличането с генериране в биомедицината и подчертава повтарящ се проблем: разминаване между способността на системите да извличат релевантна информация и способността им да я обосноват по проверим начин пред клиницист. Скринингов преглед на Miao и др. [14] върху 67 проучвания в областта на медицината

и сестринските грижи установява, че по-голямата част от съществуващите системи са насочени към отговаряне на медицински въпроси и клинична подкрепа при вземане на решения. Приложения, изградени върху затворен корпус от официално одобрени ръководства, какъвто е разглежданият в тази работа, остават сравнително слабо застъпени: повечето изследвани системи разчитат на широки, отворени биомедицински корпуси, например PubMed, а не на регулаторно одобрен, ограничен по обхват източник.

Именно тази разлика е показателна за настоящата дипломна работа. Докато извличането от отворен уеб корпус трябва допълнително да преценява достоверността и авторитетността на всеки източник, затвореният корпус от национални фармакотерапевтични ръководства носи авторитетност „по подразбиране“, а основният риск се измества към точността на самото извличане и към честността на генеративния модул да не добавя информация извън предоставения контекст. Li и Zhu [15] формулират именно такива практически препоръки от индустриален опит за медицински системи за извличане с генериране: стриктно ограничаване на генерирания отговор до предоставения контекст, връщане на изричен източник (документ, страница, раздел) към всяко твърдение и изрично сигнализиране, когато не е намерен релевантен откъс. Тези препоръки директно съответстват на изискването за данни за произход, наследено от преддипломния проект, и са отправна точка при проектирането на слоя за генериране на отговори (раздел 3.4), където е обсъдено и доколко могат да бъдат изпълнени от малък генеративен модел.

2.4 Особености при работа с по-слабо ресурсни езици

Повечето цитирани дотук резултати са получени и оценени основно върху английски текст, което поставя въпроса доколко изводите им важат за българския език. Съществуват по същество два алтернативни подхода за извличане на информация, когато езикът на корпуса е по-слабо ресурсен. Първият е кросезиково извличане: заявката или корпусът се превежда към високоресурсен език като английски, след което се използва силен английски модел за извличане и генериране. Ranaldi и др. [16] показват, че подобен превод преди извличането подобрява резултатите върху задачи, изискващи много фактическо знание, включително за по-слабо ресурсни езици. Този подход обаче въвежда допълнителна стъпка на превод, която може да изкриви медицинска терминология, дозировки и съкращения. Рисковете от подобно изкривяване вече бяха отчетени при OCR обработката в преддипломния проект и биха се повторили при машинен превод. Вторият подход е директна работа на изходния език чрез многоезичен или езиково специфичен модел за векторно представяне, без междинен превод. Той запазва оригиналната терминология, но изисква съответният модел действително да представя добре българския език, а не само големите езици в обучаващата му извадка.

По втория подход има насърчителни, но неоднозначни резултати. От една страна, съществуват специализирани български модели от типа BERT и RoBERTa, обучени основно за класификация, разпознаване на именувани обекти и синтактичен анализ [17, 18]. Това показва, че за българския език вече има зряла инфраструктура за представяне на текст, но тези модели не са били оценявани конкретно за задачата извличане чрез сходство на вектори, което представлява отворен въпрос. От друга страна, изследвания върху други по-слабо ресурсни езици показват, че общите многоезични модели за векторно представяне често подценяват съответния език и се нуждаят от допълнително адаптиране. Omotoso и др. [19] дообучават многоезичния модел BGE-M3 за нигерийски по-слабо ресурсни езици с осезаемо подобрение. Nzeyimana и Rubungo [20] изграждат специализиран, лексикално

обоснован модел за извличане за езика киняруанда вместо да разчитат на генеричен многоезичен модел. Navasardyan и др. [21] показват, че дори малък обем шумни, синтетично генерирани данни е достатъчен за забележимо подобряване на векторното представяне на по-слабо ресурсен език. Общото между тези резултати е изводът, че годността на дадено многоезично векторно представяне за конкретен по-слабо ресурсен език не бива да се приема по подразбиране, а трябва да се провери емпирично и, при нужда, да се коригира с целево, дори ограничено по обем, дообучение.

За разлика от векторното представяне, при генеративния компонент положението за българския език е по-благоприятно. Alexandrov и др. [22] от Института по компютърни науки, изкуствен интелект и технологии (INSAIT) представят BgGPT – семейство отворени модели, получени чрез продължено предобучение на Gemma 2 върху около 100 милиарда токена, от които 85 милиарда на български, съчетано с техника за сливане на модели (branch-and-merge), ограничаваща катастрофалното забравяне на английски и общи умения при адаптирането към нов език. Моделите се разпространяват в няколко размера – 2.6, 9 и 27 милиарда параметри – с отворени тегла и готови квантувани версии за локално изпълнение, а по данни на самите автори по-малкият вариант надминава по представяне на български сравними по размер отворени модели. Наличието на специализиран за българския език генеративен модел, който може да се зарежда изцяло локално, прави обосновано генеративният компонент на настоящата система (раздел 3.4) да се базира на BgGPT, вместо на по-голям, но неспециализиран за българския език модел или на модел, достъпен само през платено API.

От направения преглед следват две методологически решения за настоящата дипломна работа. Първо, вместо предварително да се избере един модел за векторно представяне въз основа само на общите му многоезични показатели, ще бъдат съпоставени емпирично няколко кандидат-модела върху корпуса от преддипломния проект (раздел 3.2), а директният подход на изходния език ще бъде предпочетен пред превод към английски, за да се запази медицинската терминология непроменена. Второ, за генериране на отговори (раздел 3.4) ще бъде използван BgGPT, зареден локално чрез Ollama, което съответства едновременно на изискването системата да работи без връзка към платено API и на установената по-добра пригодност на този модел за българския език.

3 Методология

3.1 Корпус от данни

Корпусът е резултат от преддипломния проект [3] и се състои от 1380 откъса (chunks), получени чрез разбиване на текста на фрагменти (chunking) от 17 национални фармакотерапевтични ръководства, изтеглени от сайта на Националния съвет по цени и реимбурсиране на лекарствените продукти [1]. Всеки откъс запазва данни за произход: документ, диапазон страници, секция и идентификатор (`chunk_id`). Корпусът е публично достъпен заедно с изходния код на системата в хранилището `https://github.com/ccvetanska/MedGuideRag/tree/main/data/processed`: файлът `chunks.jsonl` съдържа откъсите, а `documents.jsonl` – извлечения текст на ръководствата по страници. Извличането, почистването и фрагментирането на текста са описани в преддипломния проект, чието хранилище съдържа и изходния код, с който е получен корпусът.

3.2 Изграждане на векторно представяне и индексиране

В съответствие с извода от литературния преглед (раздел 2.2), моделът за векторно представяне не е избран предварително, а се съпоставят три отворени, многоезични кандидата, поддържащи българския език, всеки изпълняван локално чрез библиотеката `sentence-transformers` без връзка към платено API: `BAAI/bge-m3` [23], `intfloat/multilingual-e5-base` [24] и `sentence-transformers/paraphrase-multilingual-mpnet-base-v2` [25]. При моделите от семейството e5 текстовете се представят с префиксите `query:` и `passage:`, изисквани от авторите им за коректна работа, докато другите два модела не се нуждаят от такъв префикс – разлика, която се третира изрично в имплементацията (`src/medguiderag/indexing/embed.py`), за да не се получи подвеждащо ниска прилика само поради пропусната конвенция.

За векторна база е избран FAISS, а не сървър-базирано решение като Qdrant или Milvus, разгледани в раздел 2.2: при корпус от 1380 откъса точното (а не приближено) търсене чрез `IndexFlatIP` върху нормализирани вектори – еквивалентно на косинусова близост – отнема пренебрежимо малко време, така че компромисите между точност и латентност при приближено търсене на най-близки съседи, обсъдени по-горе, тук не се проявяват. За всеки кандидат-модел се изгражда отделен индекс с придружаващи метаданни (документ, страници, секция, текст на откъса), което позволява последващо сравнение един срещу друг върху едни и същи заявки (раздел 4.7).

Таблица 1 обобщава резултата от индексирането на трите кандидата върху локалната машина (на централния процесор, ограничен до две нишки на процес, за да се избегне изчерпване на паметта). Времето за изчисляване на векторните представяния е еднократен, офлайн разход при построяването на индекса и не се отразява на латентността при отговор на заявка, но е практически показателен за скоростта на итериране по време на разработка: `BAAI/bge-m3` отнема близо два часа за целия корпус, близо 20 пъти повече от по-леките кандидати. Разликата произтича от по-големия му размер (568 милиона параметри спрямо около 278 милиона за другите два) и по-високата размерност на изхода.

Таблица 1: Резултати от индексирането на трите кандидат-модела върху корпуса от 1380 откъса

Модел	Измерения	Размер на индекса	Време за индексиране
paraphrase-multilingual-mpnet-base-v2	768	4.0 MB	5.9 мин
multilingual-e5-base	768	4.0 MB	15.9 мин
BAAI/bge-m3	1024	5.4 MB	115.9 мин

Разликата във времето за индексиране сама по себе си не определя кой модел е по-подходящ; това ще бъде установено едва чрез качеството на извличането върху ръчно анотирани въпроси (раздел 4.7). Тя е основание обаче изборът между кандидатите да отчита и практическата цена на преизчисляване на индекса, ако корпусът или стратегията за фрагментиране се променят по-нататък в разработката. След преминаването към изчисления на графичния процесор (раздел 4.3) индексирането с `BAAI/bge-m3` отнема 84 секунди, така че тази цена престава да бъде практическо ограничение.

Трите кандидата се различават и по характеристика, която не личи от таблица 1, но се оказва решаваща: максималната дължина на входа, която моделът обработва при изчисляване на векторното представяне. Тя е 8192 токена за `BAAI/bge-m3`, 512 за `intfloat/`

`multilingual-e5-base` и едва 128 за `paraphrase-multilingual-mpnet-base-v2`, а подългите текстове се отрязват без предупреждение. Откъсите от преддипломния проект са с дължина около 420 думи, т.е. средно около 860 токена, като размерът им е избран преди да е известен моделът за векторно представяне. Последиците от това несъответствие са измерени в раздел 4.2 и показват, че сравнението на трите кандидата при сегашния размер на откъсите не е равностойно.

3.3 Извличане на релевантни откъси

Компонентът за извличане приема текстова заявка и връща най-много k откъса заедно с оценка на релевантността и пълните данни за произход. В сегашния си вид той е хибриден и се състои от три последователни стъпки (`src/medguiderag/retrieval/hybrid.py`):

1. *Кандидати.* Заявката се търси по два независими начина: семантично, чрез векторното представяне и индекса от раздел 3.2, и лексикално, чрез функцията за класиране BM25 [26] върху същите откъси. Преди лексикалното търсене всяка дума се съкращава до първите си шест знака, за да съвпадат различните граматични форми на една и съща дума. Всеки от двата метода връща по 50 откъса.
2. *Сливане.* Двата списъка се обединяват чрез сливане по реципрочни рангове (Reciprocal Rank Fusion) [27]: всеки откъс получава сумата от $1/(60 + r)$ за всеки от списъците, в които се среща на позиция r, и за следващата стъпка се запазват първите 20.
3. *Повторно класиране (reranking).* Двадесетте кандидата се подреждат наново от модела `BAAI/bge-reranker-v2-m3`, изграден върху `BAAI/bge-m3`. За разлика от модела за векторно представяне, той обработва заявката и откъса заедно, като кръстосан енкодер (cross-encoder) [28], и връща оценка на релевантността между 0 и 1. Запазват се най-много k откъса с оценка поне 0.1. Ако нито един откъс не достига този праг, системата не генерира отговор, а съобщава, че в ръководствата не е открита информация по въпроса.

Всяка от стъпките отговаря на конкретна слабост на по-простите алтернативи, измерена в раздел 4.3. Лексикалното търсене е добавено, защото двата метода грешат при различни въпроси и обединението им съдържа верния откъс по-често от всеки поотделно. За съкращаването на думите е предпочетено грубо отрязване пред морфологичен анализатор за български, защото не изисква допълнителен езиков ресурс, а вече подобрява съществено лексикалното търсене. Сливането използва само позициите в списъците, а не самите оценки, защото оценките на BM25 и косинусовата близост са в несравними скали. Претеглена сума от двете оценки би изисквала настройване на тегло върху данни, каквито в достатъчен обем липсват, докато константата 60 е стойността, препоръчана от Cormack и др., и не е настройвана. Кръстосаният енкодер е по-точен от сравнението на независимо изчислени вектори, защото вижда заявката и откъса едновременно, но е и много по-бавен: оценяването на всичките 1380 откъса за всяка заявка би било непрактично, затова той се прилага само върху малък брой кандидати. Оценката му е в една и съща скала за всички заявки и затова служи и като праг за отказ. Така изискването за изрично съобщение при липса на релевантна информация (раздел 3.4) се изпълнява на ниво извличане, а не се поверява на генеративния модел.

Първоначалният вариант – само семантично търсене и k най-близки откъса (`src/medguiderag/retrieval/retriever.py`) – е запазен като алтернативен режим, който се

избира от интерфейса. Той служи за отправна точка при сравненията и е единственият практичен режим, когато няма графичен процесор, тъй като на централния процесор повторното класиране отнема около 70 секунди на въпрос. И в двата режима всеки от моделите за векторно представяне от раздел 3.2 се използва през един и същ интерфейс, което позволява сравняването им без промяна на останалата част от системата.

3.4 Генериране на отговори

За генеративния компонент е избран BgGPT (раздел 2.2) във варианта с 2.6 милиарда параметри и 4-битово квантуване, зареден локално чрез Ollama, без връзка към платено API. По-големите варианти (9 и 27 милиарда параметри) изискват повече памет от наличните 6 GB на видеокартата, а 5-битовото квантуване на по-малкия модел не успя да бъде заредено изцяло на нея, въпреки че формално свободната видеопамет е достатъчна. По-новият вариант на BgGPT с 4 милиарда параметри, изграден върху Gemma 3, също с 4-битово квантуване, е сравнен с избрания в раздел 4.3 и след въвеждането на проверката за неподкрепени подробности е приет по подразбиране (раздел 4.4). По-малкият модел остава избираем от интерфейса.

Подсказката към модела е съставена по следния начин, като всяко от решенията е резултат от експериментите в раздел 4.2:

- Инструкцията и откъсите се подават в едно потребителско съобщение, а инструкцията стои след откъсите, непосредствено преди въпроса. Шаблонът за диалог (chat template) на моделите Gemma 2 и Gemma 3, върху които са изградени двата варианта на BgGPT, няма отделна системна роля, и системното съобщение се подава като допълнителен потребителски ход в самото начало, най-далеч от въпроса.

- Откъсите се подреждат в обратен ред на релевантността, така че най-близкият до заявката откъс е последен, непосредствено до въпроса.

- Текстът на откъсите се нормализира: преносите на редове от PDF документите, които при двустранно подравнените редове отделят дори единични думи, се заменят с интервали.

- Инструкцията изисква отговор само с информация от откъсите, без добавени факти, но не изисква цитиране на източници. Източниците се показват от системата детерминистично, от данните за произход на извлечените откъси, тъй като моделът измисля цитати, когато бъде помолен да ги посочи.

- Контекстният прозорец (context window) е зададен изрично на 8192 токена, колкото е естественият за Gemma 2, вместо стойността по подразбиране на Ollama от 4096 токена, при която подсказката се отрязва без предупреждение. Поради същото ограничение броят на подаваните откъси е най-много пет.

- Температурата на генериране, т.е. параметърът, който управлява степента на случайност при избора на следващ токен, е нула. Така един и същ въпрос върху едни и същи откъси получава практически един и същ отговор, което е предпоставка за сравнимост на експериментите. Остатъчните разлики между отделните изпълнения на експеримента са обсъдени в раздел 4.3.

- Наказанието за повторение (repeat penalty) е 1.2, а дължината на отговора е ограничена до 1024 токена. Без тях моделът може да зацикли, когато получи само един откъс (раздел 4.3).
- Преди генерирането се проверява дали ключовите понятия от въпроса – имената на лекарства и редките за корпуса думи – се срещат в показаните откъси. Ако не се срещат, отговор не се генерира, а интерфейсът посочва липсващото понятие (раздел 4.6).
- След генерирането отговорът се проверява автоматично за имена на лекарства, АТС кодове и числа, които не се срещат в откъсите, и те се отбелязват в интерфейса (раздел 4.4).
- Изреченията от отговора се съпоставят с изреченията от откъсите, а използваните части се маркират в показаните източници (раздел 4.5).

Спрямо препоръките на Li и Zhu [15] това е съзнателно отклонение. Вместо моделът да посочва източник към всяко твърдение, проследимостта се постига на ниво система: потребителят вижда точните откъси, върху които е изграден отговорът, заедно с документа и страниците им. Изискването за изрично съобщение при липса на релевантна информация също не е поверено на модела, защото при опит да бъде изпълнено чрез инструкция моделът отказва да отговори и когато откъсите съдържат отговора. Решението дали изобщо има релевантен откъс е по-естествено да се взема на ниво извличане и е реализирано чрез праг върху оценката на повторното класиране (раздели 3.3 и 4.3). Прагът обаче не разпознава медицинските въпроси извън обхвата на ръководствата, затова е допълнен с проверка преди генерирането дали ключовите понятия от въпроса се срещат в откъсите (раздел 4.6).

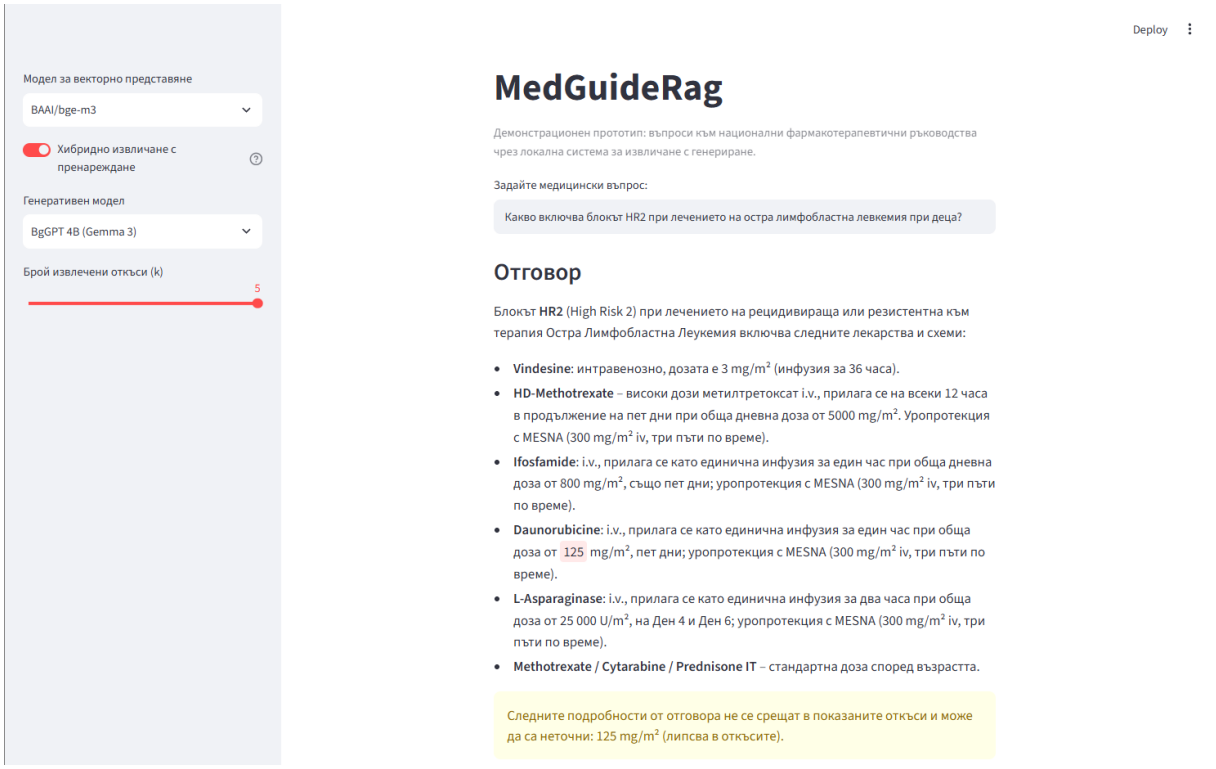
4 Експерименти и резултати

4.1 Демонстрационно приложение

Демонстрационното приложение дава достъп до системата чрез уеб интерфейс, в който потребителят задава въпрос и вижда отговора заедно с откъсите, на които той стъпва. Описано е окончателното му състояние, а промените, довели до него, са обосновани в следващите раздели. Приложението е реализирано с библиотеката Streamlit (`src/medguiderag/app/ui.py`). Разгледани са три алтернативи. Gradio също позволява бързо изграждане на интерфейс към модели, но е насочен преди всичко към демонстрации с един вход и един изход, докато тук резултатът се състои от отговор, предупреждения и няколко източника с маркиран текст. Отделен сървър (например Flask или FastAPI) със собствен клиент на JavaScript дава пълен контрол върху интерфейса, но изисква втори език и двойно повече код, което не е оправдано за прототип с един потребител. Chainlit е предназначен за разговор с история, какъвто приложението съзнателно не поддържа. Streamlit позволява целият конвейер да остане на Python. Моделите за векторно представяне и за повторно класиране и данните за проверката на отговора се зареждат веднъж, при първия въпрос, и се преизползват при следващите.

Интерфейс. Въпросът се въвежда в едно текстово поле и всеки въпрос се обработва самостоятелно, без история на разговора. Историята би заела част от контекстния прозорец от 8192 токена, който петте откъса почти изчерпват (раздел 3.4), и би смесила откъси от различни въпроси. Освен това проверката и маркирането на източниците се отнасят до откъсите на текущия въпрос. Отговорът се показва под въпроса (фигура 2). Имената на лекарства, ATC кодовете и числата, които не се срещат в откъсите, са оцветени и изброени в предупреждение под отговора (раздел 4.4). Отговорът е придружен и от постоянна бележка, че е генериран от езиков модел и може да съдържа неточности.

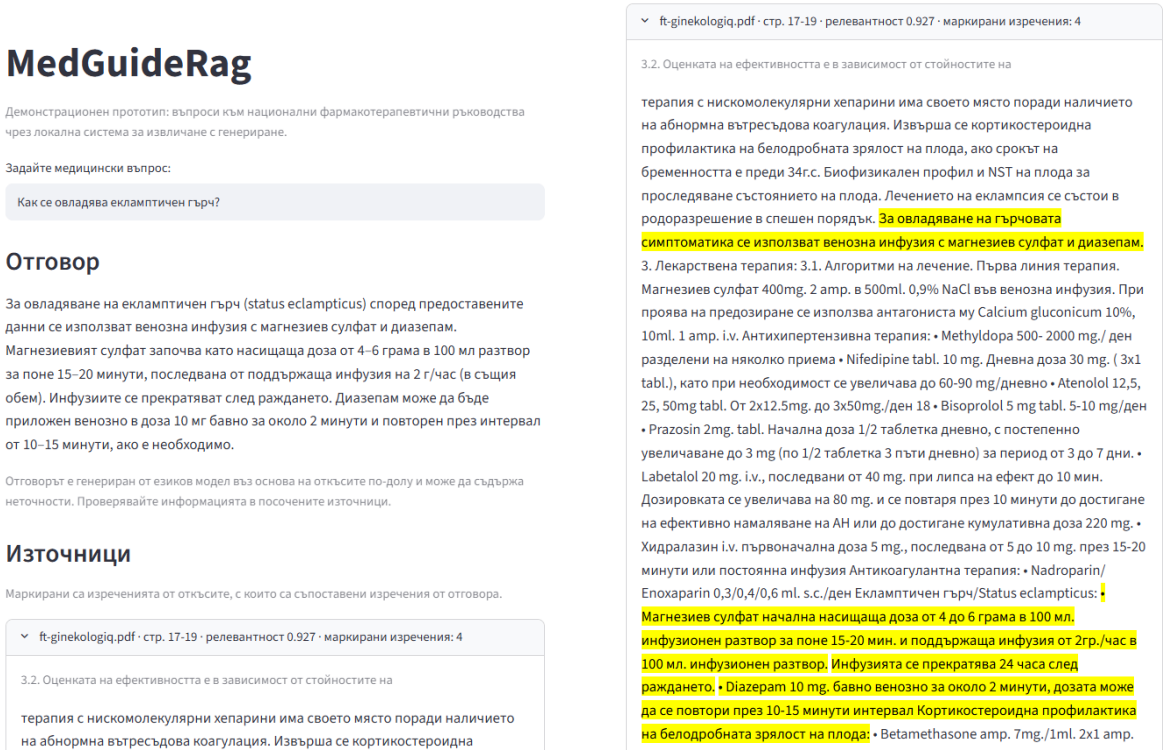
Под отговора са източниците (фигура 3). Всеки откъс е показан като разгъващ се панел, озаглавен с документа, страниците и оценката на релевантност. В заглавието е посочено и колко изречения от откъса са маркирани или че откъсът не е използван в отговора. В панела са разделът на ръководството и пълният текст на откъса, в който са оцветени изреченията, съпоставени с отговора (раздел 4.5). Изреченията от отговора, за които не е открито съответствие, са изброени в отделен панел. Ако нито един откъс не достигне прага на релевантност, системата не генерира отговор, а показва съобщение, че в ръководствата не са открити откъси по въпроса (фигура 4 и раздел 4.3). Отговор не се генерира и когато ключовите понятия от въпроса не се срещат в откъсите. Тогава съобщението посочва липсващото понятие, например че в намерените откъси не се споменава ревматоиден артрит (раздел 4.6).



Фигура 2: Отговор с отбелязана неподкрепена подробност и предупреждение под него. Вляво са настройките на приложението.

Настройки. Страничната лента съдържа четири настройки, които позволяват част от сравненията в следващите раздели да се повторят направо в интерфейса:

- *Модел за векторно представяне* – един от трите кандидата от раздел 3.2, по подраз-



(а) отговор (б) разгънат първи източник

Фигура 3: Отговор и разгънатият му първи източник: изреченията от откъса, съпоставени с изречения от отговора, са оцветени.

биране `BAAI/bge-m3`.

- *Хибридно извличане с повторно класиране* – включено по подразбиране, когато е наличен графичен процесор. Изключено, системата използва само семантичното търсене и показва косинусовата близост вместо оценката на релевантност. Възможността е нужна, защото без графичен процесор повторното класиране отнема около 70 секунди на въпрос.
- *Генеративен модел* – BgGPT с 4 милиарда параметри по подразбиране или вариантът с 2.6 милиарда (раздел 4.4).
- *Брой откъси* – от един до пет. Горната граница следва от контекстния прозорец, а при хибридното извличане откъсите могат да са по-малко, защото тези под прага се отхвърлят.

Обработка на въпрос. След въвеждането на въпроса приложението последователно извлича откъсите (семантично и лексикално търсене, сливане, повторно класиране, праг; раздел 3.3), проверява дали ключовите понятия от въпроса се срещат в тях (раздел 4.6), генерира отговора чрез Ollama, проверява го за неподкрепени подробности и съпоставя изреченията му с откъсите. Първият въпрос отнема около 35 секунди, защото тогава моделите се зареждат на графичния процесор. Следващите отговори отнемат около 6–8 секунди с модела с 4 милиарда параметри и около 5 секунди с по-малкия, а отказът около 2 секунди. При заредени модели за векторно представяне, за повторно класиране и генеративен модел видеопаметта е заета до около 5.7 от 6 GB. Затова в нея се побира само един генеративен модел, а смяната му в страничната лента отнема около 10 секунди за повторно зареждане.



Фигура 4: Отказ при въпрос извън обхвата на ръководствата: нито един откъс не достига прага и генеративният модел не се използва.

Локално изпълнение. Всички компоненти работят на машината, без връзка към външни услуги. Ollama приема заявки само на локалния адрес, а моделите за векторно представяне и за повторно класиране се зареждат от локалното хранилище на Hugging Face в режим без мрежа. Без този режим библиотеката проверява при всяко зареждане дали в хранилището има по-нова версия на модела. Проверка на мрежовите връзки по време на зареждането потвърждава, че в режим без мрежа приложението не осъществява нито една връзка извън машината, срещу една връзка без него.

Ограничения. Приложението е предназначено за един потребител. Моделите се споделят между отворените сесии, но заявките към тях се обработват последователно, а видеопаметта не оставя място за паралелна работа. Отговорът се показва след като е генериран изцяло, а не постепенно, докато се генерира. Приложението не поддържа вход с потребителско име, история на въпросите или събиране на обратна връзка. Сървърът на Streamlit е достъпен по подразбиране и от локалната мрежа, затова при демонстрация на споделена мрежа достъпът трябва да се ограничи до самата машина.

4.2 Подобряване на резултатите – съставяне на подсказката към генеративния модел

Първите опити с демонстрационното приложение показаха, че отговорите често не възпроизвеждат информацията от показаните източници, а съдържат общи или неподкрепени от тях твърдения. Характерен пример е въпросът „Как се лекува хиперемезис гравидарум?“ с модела за векторно представяне `BAAI/bge-m3`. Извлеченият откъс от Фармакотерапевтичното ръководство по акушерство и гинекология изрежда конкретни групи лекарства: антиеметици (ondansetron, metoclopramide, фенотиазини), антисекреторни средства (esomeprazole, famotidine, ranitidine), инфузии с глюкозни разтвори и електролити, седативни средства. Генерираният отговор споменава инфузионната терапия и антисекреторните средства, но пропуска антиеметиците и добавя групи лекарства, каквито в откъса няма: антихипертензивни средства (метопролол), антикоагуланти (варфарин) и антиконвулсанти (валпроат). Разделът описва експериментите, с които бяха установени причините, и промените, които подобриха отговорите. Промените не са окончателни и разделът завършва с проблемите, които остават отворени.

Протокол. За да се отделят отделните причини, експериментите следват един и същ протокол. Използват се три въпроса от различни области, за които корпусът съдържа отговор: хиперемезис гравидарум (акушерство и гинекология), кога се прилага инсулин при захарен диабет тип 2 (ендокринология) и лечение на атопичен дерматит (дерматология). За всеки въпрос откъсите се извличат веднъж с `BAAI/bge-m3` ($k = 5$) и остават фиксирани, а между вариантите се променя по един фактор на подсказката. Генерирането е с температура нула, за да се изключи случайността. Всеки отговор се оценява по два начина. Автоматично се брои колко от предварително изброените факти в релевантния откъс се срещат в отговора (съответно 14, 7 и 8 факта, най-често имена на лекарства и мерки). Ръчно отговорът се прочита изцяло и се отбелязват твърденията, които не се съдържат в откъсите. Автоматичната мярка е груба, защото отчита само наличието на ключова дума, и при разминаване предимство има ръчният прочит.

Отрязване на подсказката. Първата находка не е свързана с формулировката на подсказката, а с размера ѝ. Пет откъса заедно с инструкцията заемат между 5500 и 6300 токена, а Ollama по подразбиране използва контекстен прозорец от 4096 токена. При препълване библиотеката llama.cpp, чрез която Ollama изпълнява модела, запазва само последната половина от прозореца. Така подсказката е била съкратена до около 2000 токена, без предупреждение, като отпадат първите откъси, които при подреждане по релевантност са и най-важните. Отрязването е установено по броя обработени токени, който Ollama отчита за всяка заявка. Контекстният прозорец е увеличен до 8192 токена, а броят на откъсите е ограничен до пет.

Системна роля, цитиране и отказ. Първоначалната подсказка съдържаше правилата в системно съобщение: да се използва само предоставеният контекст, да се цитира източник във формат „[документ, стр.]“ и изрично да се съобщава, когато липсва информация. Тъй като шаблонът за диалог на Gemma 2 няма системна роля, правилата попадат в отделен потребителски ход в самото начало, а при описаното по-горе отрязване на подсказката те са отпадали изцяло. Затова правилата бяха преместени непосредствено преди въпроса, а контекстният прозорец беше увеличен. Проверката на този вариант с откъси, извлечени с `paraphrase-multilingual-mpnet-base-v2`, разкри два по-сериозни проблема. С дословно зададена фраза за отказ моделът отговаря с нея на всички въпроси, включително на въпроса за инсулина, чийто отговор се съдържа във втория извлечен откъс. Без тази фраза моделът отговаря, но измисля източници: за контролния въпрос „Колко е висок връх Мусала?“, на който корпусът няма отговор, посочва хематологичното ръководство, а в друг вариант несъществуващ файл „ФТР_География.pdf“. В медицински контекст измисленият източник е по-опасен от липсващия, защото придава привидна достоверност на отговора. Затова цитирането и отказът са изнесени извън генеративния модел (раздел 3.4).

Варианти на подсказката. Таблица 2 обобщава вариантите, сравнени при фиксирани откъси. Изходният вариант V0 съответства на състоянието на системата в момента на наблюдавания проблем: инструкцията е след откъсите, а контекстният прозорец е 8192 токена.

Ред на откъсите. Най-голямото подобрение идва от реда на откъсите (V1 спрямо V2): при въпроса за хиперемезис възпроизведените факти нарастват от 1 на 7 от 14. При подреждане по релевантност най-подходящият откъс е първи, на около 5000 токена от въпро-

Таблица 2: Възпроизведени факти от релевантния откъс при различни варианти на подсказката (откъси, извлечени с `BAAI/bge-m3`, температура нула)

Вариант	Описание	Хиперемезис	Инсулин	Дерматит
V0	изходен: необработен текст, 5 откъса по реда на релевантност	2/14	1/7	3/8
V1	V0 с нормализиран текст	1/14	1/7	3/8
V2	V1, най-релевантният откъс последен	7/14	2/7	4/8
V3	V2 с 3 откъса	7/14	3/7	4/8
V4	V2 с конкретизираща инструкция	9/14	5/7	4/8
V5	V4 с 3 откъса	8/14	6/7	4/8
V6	само най-релевантният откъс, конкретизираща инструкция	7/14	4/7	4/8

са, и моделът на практика го пренебрегва, като съставя отговора от последните, несвързани откъси и от собствената си параметрична памет. Във варианта V1 например отговорът представя като лечение на хиперемезис вазоактивните лекарства terlipressin и octreotide и инфузиите със somatostatin. Те са от последния откъс, от ръководството по гастроентерология, който описва лечението на кървене. Резултатът е в съгласие с наблюденията на Liu и др. [29], според които езиковите модели използват най-добре информацията в началото и в края на дълъг контекст и най-слабо тази в средата. При BgGPT с 2.6 милиарда параметри ефектът е дори по-силен: в наблюдаваните случаи позицията в началото не е достатъчна, ако между нея и въпроса има хиляди токени несвързан текст, и решаваща е близостта до въпроса.

Нормализиране на текста. Замяната на преносите на редове с интервали (V0 спрямо V1) променя броя възпроизведени факти най-много с един, но съкращава подсказката с около 6% и премахва накъсването на изреченията, затова е запазена.

Конкретизираща инструкция. Инструкция, която изрично иска да се изброят мерките, лекарствата и дозировките, посочени в откъсите (V4–V6), повишава автоматичната оценка при хиперемезис и при инсулина, но ръчният прочит показва обратното. Моделът попълва исканата структура с измислено съдържание. При хиперемезис добавя диетичен режим („избягване на мазни и пикантни храни“, „банани, ориз и ябълково пюре“), какъвто в откъса няма, приписва на лекарствата погрешни ATC кодове, а във варианта V5 посочва и дози („Esomeprazole: 20 mg перорално дневно“, „Ondansetron: 4 mg“), каквито откъсът не съдържа. При инсулина посочва взаимно противоречиви прагове на гликирания хемоглобин. Затова е запазена по-простата инструкция. Случаят илюстрира и ограничението на автоматичната мярка: тя отчита наличието на ключова дума, но не и верността на твърдението около нея.

Брой откъси. С три откъса (V3) отговорите остават верни спрямо източниците, броят възпроизведени факти не намалява, а подсказката е с около 40% по-кратка. Въпреки това е запазен вариантът с пет откъса, защото при три откъса верният откъс отпада винаги, когато извличането го класира на четвърто или пето място. В набора за разработка от раздел 4.3 това се случва при два от 24 въпроса.

Температура. При температура 0.2 три последователни изпълнения на въпроса за инсулина върху едни и същи пет откъса (извлечени с `paraphrase-multilingual-mpnet-base-v2`) дадоха три различни отговора, единият с невярно твърдение: хипогликемията е представена като показание за инсулиново лечение, докато тя е риск от него. Температура нула прави отговорите повторими и е условие за сравнимост на експериментите.

Резултат. След промените (вариант V2) отговорът за хиперемезис описва инфузиите с глюкозни и левулозни разтвори с добавен инсулин, корекцията на електролитите, поливитамините, групите антиеметици (5-HT3-блокери, D2-рецепторни блокери, H1-блокери), антисекреторните средства (esomeprazole, famotidine, ranitidine) и седативните средства, както и критериите за оценка на ефективността. Всички тези сведения се съдържат в откъса. Пропуснати остават хоспитализацията, покоят и диетичните препоръки от първоначалните грижи, както и конкретните антиеметици.

Зависимост от извличането. Промените в подсказката подобряват отговора само когато релевантният откъс е сред извлечените. Таблица 3 показва, че при въпроса за хиперемезис това е изпълнено единствено за `BAAI/bge-m3`. Другите два модела не извличат откъса с отговора сред първите пет, а връщат откъси от ръководствата по нуклеарна медицина, нефрология, гастроентерология, ендокринология, хематология, неврология и неонатология и друг раздел от ръководството по акушерство и гинекология. При другите два въпроса трите модела извличат релевантни откъси и отговорите са сравними.

Таблица 3: Позиция на откъса с отговора сред петте извлечени и възпроизведени факти по модели за векторно представяне (подсказка V2)

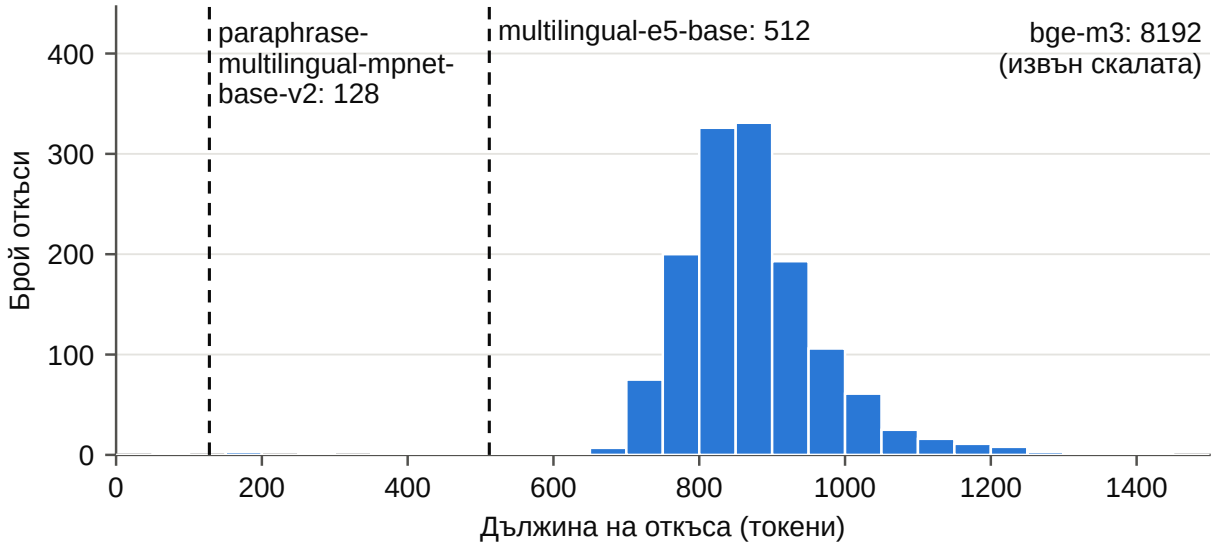
Модел	Хиперемезис	Инсулин	Дерматит
bge-m3	№1; 7/14	2/7	№1; 4/8
multilingual-e5-base	не е извлечен; 1/14	3/7	№1; 3/8
paraphrase-multilingual-mpnet-base-v2	не е извлечен; 1/14	2/7	№2; 4/8

Ограничение на дължината на входа. Причината е несъответствието, посочено в раздел 3.2, между дължината на откъсите и максималната дължина на входа на моделите (таблица 4). Откъсите са с медиана около 860 токена и максимум около 1410 (фигура 5). `paraphrase-multilingual-mpnet-base-v2` представя средно едва 15% от всеки откъс, т.е. първите около 60 думи, а в откъса за хиперемезис терминът се появява едва около 440-ия токен, така че моделът никога не го „вижда“. `multilingual-e5-base` обхваща термина, но не и описанието на лечението след него. Освен това стойностите на сходство при него са сгъстени (0.84–0.85 за всичките пет извлечени откъса), така че и малки отклонения в представянето променят класирането. Само `BAAI/bge-m3` представя откъсите изцяло.

Следователно досегашното сравнение на трите модела не е равностойно, защото два от кандидатите се оценяват върху непълно представяне на откъсите. Размерът на откъсите е определен в преддипломния проект преди избора на модел за векторно представяне и за `paraphrase-multilingual-mpnet-base-v2` е неподходящ по конструкция.

Таблица 4: Обхват на представянето на откъсите при максималната дължина на входа на всеки модел

Модел	Макс. вход (токени)	Отрязани откъси	Представена част	Позиция на „hyperemesis“
bge-m3	8192	0%	100%	438
multilingual-e5-base	512	99%	60%	439
paraphrase-multilingual-mpnet-base-v2	128	100%	15%	437



Фигура 5: Дължина на 1380-те откъса в токени и максимална дължина на входа на моделите за векторно представяне. Частта от откъса след линията на даден модел не участва в представянето му.

Отворени проблеми.

1. *Несвързани откъси.* Когато по дадена тема корпусът съдържа един релевантен откъс, фиксираният брой $k = 5$ добавя четири несвързани. При хиперемезис те са от ръководствата по ендокринология, нефрология и гастроентерология и от друг раздел на ръководството по акушерство и гинекология, със сходство 0.59–0.60 срещу 0.65 за релевантния, така че праг, който да ги отдели, не е очевиден. След обръщането на реда те вече не влияят на отговора, но продължават да се показват като източници. Възможни решения са повторно класиране с отделен модел и праг на сходството, калибриран поотделно за всеки модел за векторно представяне, тъй като стойностите на сходство при трите модела са в различни диапазони.
2. *Размер на откъсите спрямо ограничението на моделите.* За равностойно сравнение откъсите трябва да бъдат съобразени с максималната дължина на входа, например чрез по-кратки подоткъси, чиито представяния се съпоставят с изходния откъс.
3. *Граници на откъсите.* Откъсът за хиперемезис завършва по средата на списъка с използвани лекарства, така че част от информацията остава в съседния откъс, който не е извлечен.
4. *Формална оценка.* Изводите в този раздел почиват на три въпроса и следва да бъдат проверени върху по-голям набор от ръчно анотирани въпроси (раздел 4.7).

5. *Ресурси.* Сървърът, чрез който Ollama изпълнява модела, пази в оперативната памет кеш на обработените подсказки с лимит 8 GB. При серия от дълги подсказки кешът достигна този лимит и изчерпа паметта на машината за разработка, така че зареждането на други модели стана невъзможно. Това е практическо ограничение за локалното изпълнение, което следва да се отчита при по-нататъшните експерименти.

4.3 Подобряване на резултатите – хибридно извличане, повторно класиране и праг за отказ

Този раздел е насочен към отворените проблеми от раздел 4.2, свързани с извличането: несвързаните откъси, които фиксираният брой k добавя към контекста, неравностойното сравнение на моделите за векторно представяне и липсата на количествена оценка върху повече от три въпроса. За разлика от раздел 4.2, в който се променяше подсказката при фиксирани откъси, тук се сравняват методи за извличане. Затова първо е съставен набор за разработка с автоматично изчислими показатели. Промяната в извличането разкри и нов проблем при генерирането, описан в края на раздела.

Набор за разработка. От всяко от 17-те ръководства са избрани случайно по един откъс, а от четирите ръководства с поне 100 откъса – по два, като изборът е ограничен до откъси, в които се споменават дози. Към тях са добавени трите откъса от раздел 4.2, общо 24. За всеки откъс е формулиран въпрос, на който той отговаря, и този откъс се счита за верния резултат от извличането. Наборът служи за сравнение на варианти по време на разработката, а не за окончателна оценка, и има две ограничения, които трябва да се имат предвид при тълкуването на резултатите. Първо, при 24 въпроса един въпрос съответства на 0.04 от всеки показател, така че разлики от един-два въпроса не са показателни. Второ, въпросите са формулирани при наличен текст на откъса и неизбежно повтарят част от думите му, което облагодетелства лексикалното търсене. Окончателната оценка върху независимо формулирани въпроси е предмет на раздел 4.7.

Показатели. Използват се два стандартни показателя за извличане. Пълнотата при k (Recall@k) е делът на въпросите, при които верният откъс е сред първите k извлечени. Пълнотата при 5 съответства на броя откъси, подавани на генеративния модел, а пълнотата при 20 – на броя кандидати за повторното класиране. Средният реципрочен ранг (Mean Reciprocal Rank) е средната стойност на $1/r$, където r е позицията на верния откъс, като се отчита нула, ако той не е сред първите десет. За разлика от пълнотата, този показател отчита и колко високо е класиран верният откъс. Оценката е строга: за верен се приема само конкретният откъс, въпреки че съседните откъси от същото ръководство понякога съдържат част от отговора. Тъй като всички методи се оценяват върху едни и същи въпроси, разликите между тях се проверяват за статистическа значимост със сдвоени тестове. За пълнотата, която за всеки въпрос е „да“ или „не“, се използва точният тест на Макнемар (McNemar’s test) [30], който отчита само въпросите, при които двата метода се различават. За средния реципрочен ранг се използва рандомизационен тест (randomization test), препоръчан за оценка на извличането от Smucker и др. [31]. При него знакът на разликата за всеки въпрос се обръща случайно 100 000 пъти, а p-стойността е делът на случаите, в които така получената разлика в средното е поне толкова голяма, колкото наблюдаваната.

Таблица 5: Сравнение на методите за извличане върху набора за разработка (24 въпроса)

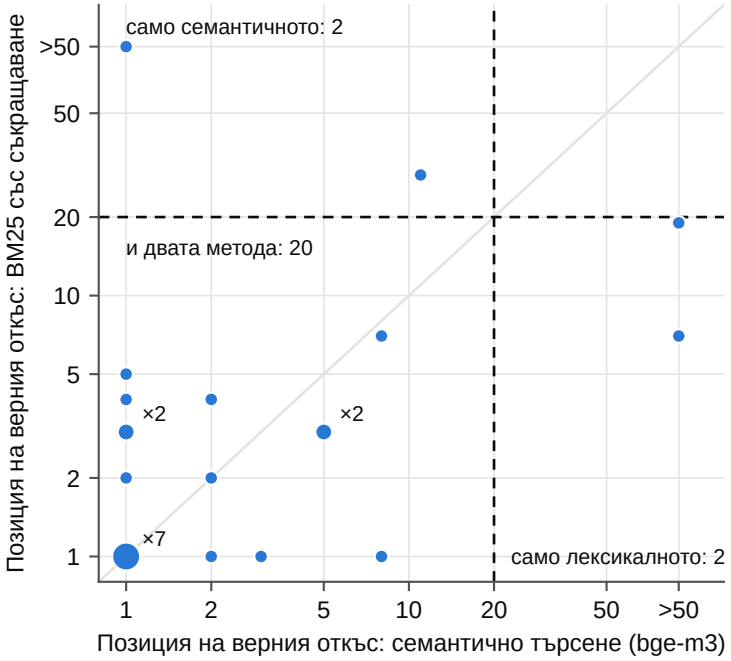
Метод	Пълнота при 1	Пълнота при 5	Пълнота при 20	Среден реципрочен ранг
Семантично търсене				
paraphrase-multilingual-mpnet-base-v2	0.04	0.25	0.46	0.15
multilingual-e5-base	0.42	0.62	0.75	0.50
embeddinggemma	0.33	0.71	0.83	0.48
qwen3-embedding (0.6 млрд. параметри)	0.46	0.83	0.96	0.61
bge-m3	0.54	0.79	0.92	0.65
Лексикално търсене				
BM25	0.25	0.79	0.92	0.44
BM25 със съкращаване на думите	0.42	0.79	0.92	0.55
Хибридно търсене				
сливане на bge-m3 и BM25	0.46	0.83	0.96	0.60
сливане и повторно класиране	**0.58**	**0.92**	**0.96**	**0.74**

Модели за векторно представяне. Таблица 5 потвърждава количествено наблюденията от раздел 4.2. `paraphrase-multilingual-mpnet-base-v2` е практически неизползваем: верният откъс е на първо място само при един от 24 въпроса и не е сред първите 20 при повече от половината. Това е единствената разлика в таблицата, която е статистически значима ($p < 0.001$). Следователно моделът не може да служи дори като първа стъпка, чиито грешки да се поправят от повторното класиране. `multilingual-e5-base` е по-добър, но отстъпва на `BAAI/bge-m3` по всички показатели, в съответствие с по-непълното представяне на откъсите (таблица 4). При 24 въпроса обаче и тази разлика не е значима. Като алтернативи на `BAAI/bge-m3` са изпробвани и два по-нови компактни многоезични модела, изпълнявани чрез Ollama, чиято максимална дължина на входа е достатъчна за откъсите: `qwen3-embedding` с 0.6 милиарда параметри [32] и `embeddinggemma` с 0.3 милиарда параметри [33]. За да е сравнението равностойно, `BAAI/bge-m3` е изпълнен и по същия начин и дава практически същите резултати като през библиотеката `sentence-transformers`. `qwen3-embedding` е наравно с `BAAI/bge-m3`: по-добър е по пълнота при 5 и при 20, по-слаб по пълнота при 1, като разликите са от един-два въпроса. `embeddinggemma` е по-слаб, като разликата в средния реципрочен ранг е на границата на значимостта (0.48 срещу 0.65, $p = 0.051$). Нито един от двата не дава основание за смяна на модела. Семейството Qwen3 включва и модели за повторно класиране, които не са изпробвани тук.

Варианти на представянето. Изпробвани са и три начина за подобряване на представянето при `BAAI/bge-m3`: нормализиране на текста, добавяне на заглавието на ръководството и на раздела пред текста на откъса и разделяне на откъса на застъпващи се подоткъси от 120 или 200 думи, при което откъсът се класира по най-близкия си подоткъс. Последният вариант беше предложен в раздел 4.2 като начин да се съобразят откъсите с ограничението на дължината на входа. Нито един от вариантите не подобрява последователно резултата: пълнотата при 1 е между 0.38 и 0.54, пълнотата при 5 – между 0.67 и 0.83, а средният реципрочен ранг – между 0.57 и 0.66, спрямо 0.54, 0.79 и 0.65 за изходния вариант. Разликите са в границите на един-два въпроса и в двете посоки, като нито една не е статистически значима (най-малката p-стойност е 0.25). Вероятното обяснение е, че `BAAI/bge-m3`

и без това обработва откъсите изцяло, а подоткъсите разделят сведения, които в заявката са свързани, например името на заболяването и описанието на лечението. Поради това разделянето е отхвърлено. За двата модела с кратък вход то не е изпробвано, защото при наличието на `BAAI/bge-m3` подобряването им има само сравнителна стойност.

Лексикално търсене. BM25 без обработка на думите класира верния откъс на първо място едва при 6 от 24 въпроса. Причината е богатата морфология на българския език: „лечение“, „лечението“ и „лечения“ са различни думи за функцията за класиране. Съкращаването на всяка дума до първите шест знака, грубо приближение на основата ѝ (stemming), повишава пълнотата при 1 от 0.25 на 0.42 и средния реципрочен ранг от 0.44 на 0.55. Това е ясна тенденция, но не и доказано подобрение ($p = 0.22$ и 0.14). По пълнота при 5 и при 20 лексикалното търсене се изравнява с `BAAI/bge-m3`, въпреки че не използва никакъв обучен модел. Това отчасти се дължи на отбелязаното облагодетелстване от начина на съставяне на въпросите. По-важно е обаче, че двата метода грешат при различни въпроси (фигура 6): сред първите 20 резултата `BAAI/bge-m3` намира верния откъс при два въпроса, при които лексикалното търсене не го намира, и обратно, а поне единият от тях го намира при всичките 24 въпроса. Дължината от шест знака не е настройвана систематично, а морфологичен анализатор би бил по-прецизна алтернатива.



Фигура 6: Позиция на верния откъс при семантичното търсене с `bge-m3` и при лексикалното търсене BM25 със съкращаване на думите (24 въпроса, логаритмична скала). Пунктирните линии отделят първите 20 резултата, а по-големите точки обединяват няколко въпроса с еднакви позиции.

Сливане и повторно класиране. Сливането по реципрочни рангове повишава пълнотата при 20 до 0.96, т.е. обединеният списък съдържа верния откъс при 23 от 24 въпроса. Сливането обаче понижава пълнотата при 1 спрямо `BAAI/bge-m3` самостоятелно (0.46 срещу 0.54). Това е разлика от два въпроса, която не е значима ($p = 0.63$), но посоката ѝ е обяснима. То увеличава шанса верният откъс да е сред кандидатите, но не и да е на първо

място, тъй като позицията му се усреднява с тази от по-слабия за дадения въпрос метод. Затова сливането е само първа стъпка, последвана от повторно класиране на първите 20 кандидата. Така се постигат най-добрите стойности по всички показатели: пълнота при 1 от 0.58, пълнота при 5 от 0.92 и среден реципрочен ранг от 0.74. Спрямо `BAAI/bge-m3` самостоятелно най-голямо е подобрението при пълнотата при 5, която определя дали верният откъс изобщо достига до генеративния модел: от 19 на 22 въпроса. Горната граница на подхода е пълнотата на кандидатите: при единствения въпрос, чийто откъс не е сред тях, повторното класиране не може да помогне. Повторното класиране има и ограничение: при въпроса за проследяването на бъбречната функция при хепатит B първите пет откъса са от други ръководства, с оценки от 0.78 до 0.98. Високата оценка показва, че откъсът е тематично близък до въпроса, но не гарантира, че е от вярното ръководство.

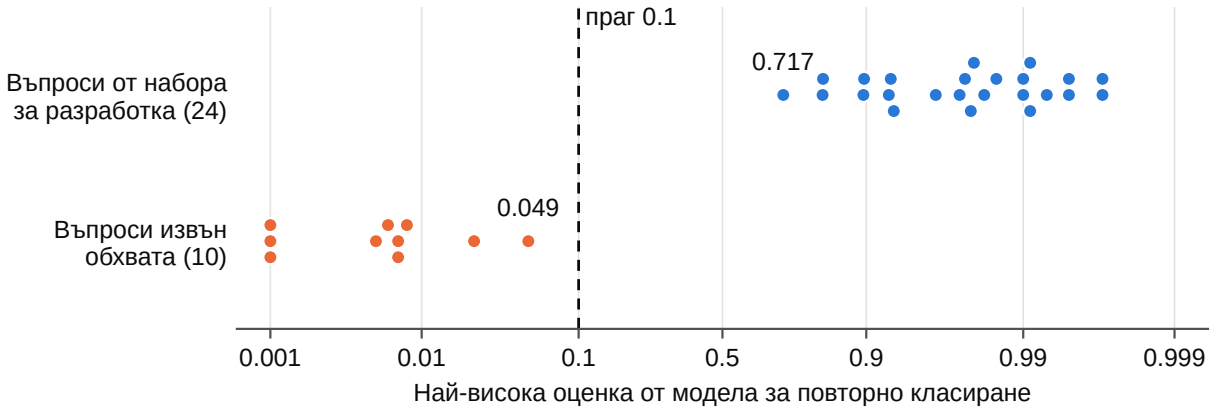
Статистическа значимост. Разликите между най-добрите методи са от порядъка на няколко въпроса и при 24 въпроса не са статистически значими (таблица 6). Хибридното извличане с повторно класиране превъзхожда `BAAI/bge-m3` по пълнота при 5 при три въпроса и не отстъпва при нито един, но вероятността такова разпределение да се получи случайно е 0.25. По пълнота при 1 повторното класиране печели при пет въпроса и губи при четири. Най-близо до значимост е подобрението на средния реципрочен ранг от повторното класиране спрямо самото сливане ($p = 0.095$). Следователно резултатите от сравнението показват последователна посока: никой от показателите на окончателния метод не е по-лош от тези на `BAAI/bge-m3`. Те обаче не доказват подобрение и трябва да се потвърдят върху по-голям набор. Ако съотношението между спечелените и загубените въпроси се запази, за да се открие подобрението на пълнотата при 5 с мощност 80% при ниво на значимост 0.05, са нужни около 60 въпроса. Ако повторното класиране губи и при един от 24 въпроса, са нужни около 190 [34]. Това определя минималния размер на набора за окончателната оценка (раздел 4.7). Всички тестове се изчисляват автоматично (`evaluation/significance.py`) върху запазените класирания и отговори от експериментите, така че резултатът не зависи от неповторимостта на генерирането, обсъдена по-долу.

Таблица 6: Значимост на основните разлики при извличането (24 въпроса). Посочени са въпросите, при които само единият метод е успешен, и p-стойността на сдвоения тест.

Сравнение (А → Б)	Пълнота при 1: само А / само Б, p	Пълнота при 5: само А / само Б, p	Среден реципрочен ранг: А → Б, p
bge-m3 → сливане и повторно класиране	4 / 5; 1.00	0 / 3; 0.25	0.65 → 0.74; 0.27
сливане → сливане и повторно класиране	3 / 6; 0.51	0 / 2; 0.50	0.60 → 0.74; 0.095
BM25 → BM25 със съкращаване	1 / 5; 0.22	1 / 1; 1.00	0.44 → 0.55; 0.14
bge-m3 → multilingual-e5-base	6 / 3; 0.51	5 / 1; 0.22	0.65 → 0.50; 0.15
bge-m3 → qwen3-embedding	4 / 2; 0.69	1 / 2; 1.00	0.65 → 0.61; 0.67
bge-m3 → paraphrase-multilingual-mpnet-base-v2	12 / 0; <0.001	13 / 0; <0.001	0.65 → 0.15; <0.001

Праг за отказ. Оценката на модела за повторно класиране е в една и съща скала за всички заявки, за разлика от косинусовата близост, чиито стойности зависят от модела за

векторно представяне и при `multilingual-e5-base` са сгъстени в тесен интервал. Затова прагът е определен върху нея. За калибрирането освен 24-те въпроса от набора за разработка са използвани десет въпроса извън обхвата на корпуса. Седем от тях са общи („Колко е висок връх Мусала?“, „Как се приготвя баница?“), а три са близки до медицината, но не и до фармакотерапевтичните ръководства („Как се лекува счупен крак?“, „Как се поставя пломба на зъб?“, „Каква е дозата на парацетамол за куче?“). Най-високата оценка при въпросите извън обхвата е 0.049, при въпроса за парацетамола, а при останалите е под 0.025. Най-ниската оценка на първия откъс при въпросите от набора е 0.717. Прагът 0.1 е избран в интервала между двете стойности (фигура 7), с двукратен запас над най-високата оценка извън обхвата. Така системата отказва да отговори на всичките десет въпроса извън обхвата, без да вика генеративния модел. Прагът има и втори ефект, който решава първия отворен проблем от раздел 4.2. Прилага се към всеки откъс поотделно, затова отпадат несвързаните откъси, които фиксираният брой k добавяше. При въпроса за хиперемезис остава само релевантният откъс, с оценка 0.98, докато останалите кандидати получават най-много 0.02, при косинусова близост 0.59–0.60 срещу 0.65. От 24-те въпроса 21 запазват пет откъса, а три – по-малко (един, два и три), като верният откъс не е отпаднал при нито един въпрос. Изводът за прага почива на малък брой въпроси извън обхвата, повечето от които са далеч от темата на корпуса. Най-рискови са медицински въпроси по теми, които ръководствата не покриват, но с близък речник, и прагът трябва да бъде проверен върху такива въпроси при окончателната оценка.



Фигура 7: Най-висока оценка от модела за повторно класиране за всеки въпрос от набора за разработка и за всеки въпрос извън обхвата. Оста е в скала на логаритъма на шансовете (logit), която разтяга стойностите близо до 0 и до 1. Пунктирната линия е прагът за отказ.

Изчислителна цена. На централния процесор повторното класиране на 20 кандидата отнема около 70 секунди на въпрос, което е неприемливо за интерактивна система. Машината за разработка разполага с графичен процесор NVIDIA GeForce RTX 2060 с 6 GB памет, който дотогава се използваше само от Ollama за генеративния модел, докато библиотеката PyTorch, чрез която се изпълняват моделите за векторно представяне и повторно класиране, беше във вариант само за централен процесор. След преминаването към варианта ѝ за графичен процесор (CUDA) моделите се изпълняват в половинна точност (fp16), т.е. с 16-битови числа с плаваща запетая вместо 32-битови. Това намалява двойно заеманата памет и е необходимо, за да се поберат всички модели в 6 GB. Таблица 7 обобщава резултата. Половинната точност не променя резултатите: подредбата след повторното класиране съвпада изцяло с получената на централния процесор, а векторните представяния

на откъсите имат косинусова близост поне 0.9997 с изчислените преди това. Затова вече построените индекси са запазени. При заредени три модела – за векторно представяне, за повторно класиране и генеративен – заетата видеопамет е около 5.6 от 6 GB, заедно с тази на операционната система, като генеративният модел остава изцяло на графичния процесор.

Таблица 7: Време за изпълнение на централния и на графичния процесор

Задача	Централен процесор	Графичен процесор, половинна точност
Повторно класиране на 20 кандидата за един въпрос	около 70 с	0.97 с
Индексиране на корпуса с `bge-m3`	116 мин	84 с
Цялото извличане за един въпрос	около 70 с	около 1 с

Зацикляне при кратък контекст. Прагът за релевантност разкри нов проблем при генерирането. При въпроса за хиперемезис до модела вече достига само един откъс, в който групите лекарства са изброени заедно с ATC кодовете им. Моделът започна да повтаря едни и същи четири реда, докато не изчерпа контекстния прозорец, което в приложението изглежда като блокиране за около две минути. При температура нула всеки следващ токен се избира като най-вероятния (алчно декодиране, greedy decoding), а този начин на декодиране е известен със склонността си към повторения, тъй като всяко повторение прави следващото още по-вероятно [35]. Вероятно ефектът се засилва от списъчната структура на единствения откъс, чийто шаблон моделът продължава.

Разгледани са четири възможни мерки. Връщането към случаен избор с температура над нула е отхвърлено, защото при експериментите в раздел 4.2 доведе до различни отговори на един и същ въпрос, единият с невярно твърдение. Ограничението на дължината на отговора спира зацикляне, но не и безсмисления текст преди това. Остават наказанието за повторение (repetition penalty), което намалява вероятността на токени, срещнали се сред последните обработени [36], и разширяването на прозореца, в който се отчитат повторенията. Предварителен опит върху шест въпроса показа, че разширяването на прозореца до 512 токена без по-силно наказание не спира зацикляне. Затова по-подробно е сравнена силата на наказанието, върху всичките 24 въпроса от набора за разработка и с откъсите от хибридното извличане (таблица 8).

Освен зацикляния и възпроизведените факти, таблицата отчита и нова мярка: числата и ATC кодовете в отговора, които не се срещат в подадените откъси. Числата и кодовете са най-опасният вид неподкрепена подробност във фармакотерапията, защото изразяват дози, прагове и идентификатори на лекарства. За разлика от броенето на факти, проверката не изисква предварително изброени факти и затова се прилага към всички 24 въпроса. Преди сравнението латинските букви и тези на кирилица с еднакъв вид се уеднаквяват, тъй като при разпознаването на текста от PDF документите те се смесват в кодовете: кодът на ranitidine в откъса е „A02BA02“ с буквите „A“ и „B“ на кирилица. Номерата на точките в изброяванията в отговора се пропускат.

Избор на наказанието за повторение. Всяка от изпробваните стойности премахва зацикляне. Стойността 1.2 дава най-много възпроизведени факти, а при предварителния

Таблица 8: Влияние на наказанието за повторение (24 въпроса, откъси от хибридното извличане, температура нула)

Наказание	Зацикляния	Факти (6 въпроса)	Числа и кодове	Отсъстващи от откъсите	Средна дължина (токени)
няма (1.0)	1	21/44	67	1	177
1.05	0	24/44	75	6	130
1.1	0	17/44	60	1	125
1.2	0	25/44	51	2	149

опит отговорът за хиперемезис съдържа 12 от 14 факта срещу 7 за варианта V2 от таблица 2, включително хоспитализацията и покоя, които тогава бяха пропуснати. Разликата спрямо алчното декодиране (25 срещу 21 от 44 факта) не е статистически значима ($p = 0.34$ при сдвояване по факт). Тъй като фактите от един отговор не са независими, тази стойност по-скоро подценява несигурността. Решаващо за избора е премахването на зацикляне, което прави отговора неизползваем. Числата и кодовете, отсъстващи от откъсите, са малко при всички стойности и не нарастват систематично със силата на наказанието. Ръчната проверка на отбелязаните случаи показва, че мярката открива истински грешки. Сред тях са ATC кодове, приписани на грешни лекарства (без наказание и при 1.05), измислената схема на прилагане „на ден 1, 4, 7, …, 31“ (при 1.05) и доза на ganciclovir от „8–16 mg/kg“, каквато в откъсите няма (при 1.2). Два от случаите обаче са фалшиви сигнали, дължащи се на различен запис на едно и също число: „90,000“ в отговора срещу „90 000“ в откъса. Прието е наказание 1.2 заедно с ограничение на отговора до 1024 токена, т.е. около 12 секунди. То не е нужно при нормална работа, където отговорите са средно около 150 токена, но ограничава времето за отговор, ако зацикляне все пак се появи. Прекъснатият отговор завършва с „[…]“, за да не бъде приет за пълен.

Повторимост. Сравнението на две изпълнения на експеримента с едни и същи въпроси показа, че температура нула не гарантира напълно еднакви отговори, както беше прието в раздел 4.2. При многократно подаване на една и съща подсказка се получават до два различни отговора, които съвпадат в началото и се разклоняват на различно място, в наблюдаваните случаи между 16-ия и 453-ия знак. Това се наблюдава и без наказание за повторение, а фиксирането на началната стойност на генератора на случайни числа (seed) не го променя. Следователно разликите не се дължат на случаен избор. Вероятната причина са малки числени разлики в изчисленията на графичния процесор, например в зависимост от това дали подсказката вече е обработена и запазена в кеша на Ollama. При два почти еднакво вероятни токена такава разлика променя избора, а оттам и целия следващ текст. На практика отговорите остават близки, но разлики между вариантите от порядъка на един-два факта не са показателни. Например наказание 1.2 дава 25 и 26 от 44 факта в две изпълнения на експеримента с едни и същи откъси.

Генеративен модел. Като алтернатива на BgGPT с 2.6 милиарда параметри е изпробван по-новият вариант, изграден върху Gemma 3, с 4 милиарда параметри (`INSAIT-Institute/BgGPT-Gemma-3-4B-IT`), също с 4-битово квантуване. Той се зарежда изцяло на графичния процесор (2.8 GB) и генерира 66 токена в секунда срещу 83 за по-малкия модел. При шестте въпроса и откъсите от `BAAI/bge-m3`, преди въвеждането на повторно-

то класиране и на наказанието за повторение, той възпроизвежда 32 от 44 факта срещу 22 за по-малкия модел. Ръчният прочит обаче показва, че по-дългите му отговори съдържат и повече неподкрепени подробности. При хиперемезис той приписва на метоклопрамида, прометазина и атропина ATC кодове, каквито в откъсите няма. При еклампсията изрежда антихипертензивни лекарства, сред които metoprolol, който не се споменава в откъсите, и пропуска посочения в тях methyldopa. Както при конкретизиращата инструкция (раздел 4.2), по-високият брой възпроизведени факти не означава по-вярен отговор. Затова по-големият модел засега не е приет. Изборът ще бъде преразгледан след въвеждането на автоматична проверка за неподкрепени подробности, която би позволила да се използва по-голямата му пълнота, като грешките му се откриват. Допълнително ограничение е видеопаметта: той заема с 0.7 GB повече от сегашния модел, а с трите модела вече е заета почти цялата памет на графичния процесор.

Резултат. Стойностите на всички показатели за извличането нарастват спрямо `BAAI/bge-m3` самостоятелно: пълнотата при 1 от 0.54 на 0.58, пълнотата при 5 – от 0.79 на 0.92, а средният реципрочен ранг – от 0.65 на 0.74. При 24 въпроса тези разлики не са статистически значими и трябва да се потвърдят при окончателната оценка. Качествените промени обаче не зависят от размера на набора. Несвързаните откъси вече не достигат до генеративния модел и не се показват като източници. Системата отказва да отговори на въпроси извън обхвата на корпуса, без да вика генеративния модел, а цялото извличане отнема около секунда. Така се изпълнява и препоръката на Li и Zhu [15] за изрично съобщение при липса на релевантен откъс, която при промените в подсказката (раздел 4.2) остана неизпълнена. Генерирането вече не зацикля, а отговорът за хиперемезис съдържа по-голямата част от сведенията в откъса.

Отворени проблеми.

1. *Неподкрепени подробности.* Моделът продължава да допуска грешни ATC кодове и дози, включително когато те са в откъса. Проверката на числата и кодовете от този раздел може да се превърне в проверка, прилагана автоматично към всеки отговор, като се разшири с имената на лекарствата и с уеднаквяване на записа на числата.
2. *Граници на откъсите.* Откъсът за хиперемезис продължава да завършва по средата на списъка с използвани лекарства. Възможни решения са добавянето на съседните откъси към контекста или фрагментиране по раздели на ръководствата.
3. *Проверка на прага.* Прагът за отказ трябва да бъде проверен върху медицински въпроси по теми, които ръководствата не покриват (раздел 4.7).
4. *Повторимост.* Сравненията на варианти на генерирането трябва да почиват на няколко изпълнения на експеримента или на разлики, по-големи от тези между отделните изпълнения.

4.4 Подобряване на резултатите – проверка на отговора за неподкрепени в откъсите детайли

Грешните ATC кодове, дози и имена на лекарства, отбелязани като първи отворен проблем в раздел 4.3, не могат да бъдат отстранени надеждно чрез подсказката, тъй като ги допускат и двата изпробвани генеративни модела. Затова всеки отговор се проверява автоматично спрямо показаните откъси (`src/medguiderag/generation/grounding.py`). Алтерна-

тивата – оценка на верността на целия отговор от друг езиков модел в ролята на съдия [9] – би изисквала втори модел в почти изчерпаната видеопамет и би удължила отговора. Затова проверката е детерминистична и се ограничава до три вида подробности, които във фармакотерапията носят най-голям риск и могат да бъдат проверени дословно:

- имена на лекарства, които не се срещат в откъсите;
- АТС кодове, които липсват в откъсите или в тях стоят до друго лекарство;
- числа (дози, прагове, срокове), които не се срещат в откъсите.

Отбелязаните подробности се оцветяват в отговора и се изброяват в предупреждение под него, но самият отговор не се променя. Преценката остава за потребителя, който вижда и откъсите.

Основната трудност е, че една и съща подробност се записва различно в отговора и в откъсите. Ръководствата дават лекарствата с международните им непатентни наименования (INN) на латиница, а моделът често ги пише на кирилица, затова двете форми се свеждат до обща транслитерация („метоклопрамид“ и „Metoclopramide“). Дума на кирилица се приема за име на лекарство, ако латинската ѝ форма се среща в корпуса поне толкова често, колкото тази на кирилица. Иначе общи думи като „терапия“ биха били отбелязвани, защото „therapy“ също се среща в корпуса. Кодовете в откъсите съдържат букви на кирилица и погрешно разпознати цифри („A02BAO3“ вместо A02BA03), а числата се записват с различни разделители („90 000“ и „90,000“), затова и двете се уеднаквяват преди сравнението. Имената се сравняват с възможност за грешка от една или две букви, за да не се отбелязват правописни варианти („хидрохлортиазид“ спрямо hydrochlorothiazide), а номерата на точките в изброяванията, числата от самия въпрос и позоваванията на страници не се проверяват.

Оценка. Проверката е приложена към всички 132 отговора от експериментите в раздел 4.3. Тя отбелязва 44 подробности в 15 отговора, от които ръчният прочит потвърждава 41 като истински грешки, т.е. 93% с 95% доверителен интервал на Уилсън (Wilson score interval) от 82 до 98% [37]. Сред тях са всички описани там грешки: АТС кодовете, приписани на грешни лекарства, измислената схема „на ден 1, 4, 7, …, 31“, дозата на ganciclovir, както и кодовете и metoprolol в отговорите на модела с 4 милиарда параметри. Отбелязани са и несъществуващи имена на лекарства („Chlormizine“, „Bromodies“) и четири грешки, пропуснати при ръчния прочит: левотироксин и парацетамол, добавени без опора в откъсите, и два кода, каквито в откъсите няма. Трите фалшиви сигнала се дължат на превод на термин от откъса („Sodium“ за „натриев“). Пълнотата на проверката не е измерена, защото това изисква ръчна анотация на всички отговори.

Ограничения. Проверката установява дали дадена подробност се среща в откъсите, но не и дали е свързана с правилното твърдение. Доза, отнесена към друг ден от схемата, вярно име с погрешно показание и пропуснатите сведения остават неоткрити. Затова тя допълва, но не замества проверката на източниците от потребителя.

Преразглеждане на генеративния модел. С въведената проверка моделът с 4 милиарда параметри е сравнен отново с досегашния, при сегашните настройки на системата и в две изпълнения на експеримента върху 24-те въпроса. Двете изпълнения дадоха еднакви резултати. По-големият модел възпроизвежда 29 срещу 25 от 44 факта, а проверката отбелязва неподкрепена подробност в един негов отговор (доза на daunorubicine в блока HR2)

срещу два за по-малкия модел. Нито една от двете разлики не е статистически значима: при фактите p = 0.45. Затова изборът почива главно на ръчния прочит. Ръчният прочит на отговорите на шестте въпроса и на двата най-сложни (блокът HR2 и неоадювантната терапия при HER2-позитивен карцином) показва по-пълни отговори при по-големия модел. Такива са пълната схема на магнезиевия сулфат и диазепама при еклампсия и локалната терапия при атопичен дерматит. Показва обаче и грешки, които проверката не открива: дози и дни, отнесени към грешно лекарство в блока HR2, мерна единица mg/kg вместо mg/m² при paclitaxel и целеви стойности, представени като показания за инсулин. Сходни грешки допуска и по-малкият модел, в блока HR2 и при антибиотиците за атопичния дерматит. Затова по подразбиране е приет по-големият модел, а по-малкият остава избираем от интерфейса. Трите модела заемат заедно около 5.7 от 6 GB видеопамет, генеративният остава изцяло на графичния процесор, а отговорът отнема средно около 7 секунди срещу около 5 за по-малкия модел.

4.5 Подобряване на резултатите – маркиране на изреченията, на които стъпва отговорът

Системата показва до пет откъса от по около 420 думи, така че проверката на един отговор изисква прочитането на около 2000 думи. В раздел 3.4 проследимостта беше постигната на ниво откъс, като съзнателно отклонение от препоръката на Li и Zhu [15] за източник към всяко твърдение. Тук проследимостта се стеснява до изречение: в показаните откъси се маркират изреченията, на които стъпва отговорът (`src/medguiderag/generation/attribution.py`).

Разгледани са три алтернативи. Генеративният модел да посочва сам източниците е отхвърлено, защото при експериментите в раздел 4.2 той измисляше цитати. Модел за логическо следване (natural language inference) или кръстосан енкодер върху всички двойки изречения би бил по-точен, но би добавил трети модел в почти изчерпаната видеопамет или стотици оценки на отговор. Маркирането направо в оригиналните PDF документи изисква откриване на текста по страниците, което разпознаването на текста от сканираните документи затруднява, и е оставено за бъдещо развитие. Избраният подход съпоставя изреченията с два признака, които вече са налични в системата. Семантичният е косинусовата близост между векторните представяния, изчислени с модела за векторно представяне, който е зареден за извличането. Лексикалният е делът от имената, числата и думите на изречението от отговора, които се срещат в изречението от откъса. Използва се нормализирането от раздел 4.4, а всяка дума тежи толкова повече, колкото по-рядко се среща в откъсите, така че общи думи като „лечение“ почти не влияят. Оценката на двойката е средното от двата признака. Изречение от отговора се свързва с изречение от откъс при оценка поне 0.45, като се допускат до три връзки, ако отговорът съчетава няколко факта. Въвеждащите изречения от рода на „Лечението включва:“ не се съпоставят. В интерфейса свързаните изречения се оцветяват, всеки откъс е обозначен с броя маркирани изречения или като „не е използван в отговора“, а изреченията от отговора без съответствие се изброяват отделно. Съпоставянето не удължава забележимо отговора.

Оценка. Прагът е определен чрез ръчен преглед на най-добрите съвпадения за изреченията в отговорите на модела с 4 милиарда параметри на 24-те въпроса. Под 0.45 съвпаденията бяха предимно грешни или засягаха въвеждащи изречения. При окончателните настройки от 93 изречения в тези отговори 87 са свързани с общо 136 изречения от откъ-

сите, а 6 остават без съответствие. Използвани са 49 от 111-те показани откъса. Ръчният преглед на всички 136 връзки показва, че 118 (87%, 95% доверителен интервал от 80 до 91%) сочат вярното място, 11 сочат сходен текст на друго място и 7 не могат да бъдат оценени еднозначно, защото таблица от документа е разпозната като едно дълго изречение. Типичната грешка е сходен текст в съседен раздел, например режимът за късен вместо за ранен сифилис или редът на друг блок от таблицата на протокола HR2. От шестте изречения без съответствие две наистина нямат опора в откъсите, три са пропуснати съвпадения (неправилно изписани имена на лекарства, перифраза и изречение с два факта), а едно е спорно. Тъй като прагът е определен и оценен върху едни и същи отговори, резултатът е по-скоро горна граница.

Полза. Съпоставянето допълва проверката от раздел 4.4. При въпроса за първично рефрактерната остра миелоидна левкемия откъсът с отговора не е извлечен и моделът отговаря от собствената си памет. Проверката за неподкрепени подробности не отбелязва нищо, защото отговорът не съдържа числа и имена на лекарства, но съпоставянето не намира опора за изречението и обозначава и петте откъса като неизползвани. Освен това погрешните твърдения често се свързват точно с мястото, което ги опровергава. Така „Инфузиите се прекратяват след раждането“ сочи изречението „Инфузията се прекратява 24 часа след раждането“, а дозата на paclitaxel в mg/kg сочи реда със 175 mg/m², което улеснява откриването на грешката.

Ограничения. Маркираното изречение показва откъде идва дадено твърдение, но не и че то е предадено вярно. Точността на маркирането зависи от разделянето на текста на изречения, което при таблиците и списъците в документите е грубо. Прагът е определен върху малък набор и трябва да бъде проверен при окончателната оценка (раздел 4.7).

4.6 Подобряване на резултатите – проверка дали ключовите понятия от въпроса ги има в откъсите

Първото пускане на окончателната оценка (раздел 4.7) показа, че прагът за отказ не разпознава медицинските въпроси извън обхвата на ръководствата. И десетте такива въпроса получават откъси над прага, защото моделът за повторно класиране намира текст с общи думи – лекарството, органа или вида лечение. При шест от тях генеративният модел отговаря с подробности от несвързаните откъси, например на въпрос за ревматоиден артрит изрежда лекарства за множествена склероза. Проверката за неподкрепени подробности не открива тези отговори, защото подробностите в тях се срещат в показаните откъси. Затова преди генерирането е добавена детерминистична проверка дали ключовите понятия от въпроса се срещат в откъсите (`generation/coverage.py`). Тя не изисква допълнителен модел и решението ѝ може да бъде обяснено на потребителя.

Ключови понятия. От въпроса се вземат думите с поне четири букви, без въпросителните и общите за медицинските въпроси думи („лечение“, „доза“, „пациент“ и т.н.), без глаголните форми, разпознати по окончанието („спадне“, „постъпване“), и без собствените имена с главна буква, които ръководствата пишат с друга транслитерация („Гилен-Баре“, „Уилсън“). Всяка дума се сравнява с текста чрез основите си с дължина от четири до шест букви, на кирилица и в латинска транслитерация. Използва се преобразуването

от проверката за неподкрепени подробности (раздел 4.4), така че „ризатриптан“ съвпада с „rizatriptan“, а „натрият“ – с „натрий“. Една дума се смята за специфична, ако основата ѝ се среща в най-много 30 от 1380-те откъса на корпуса (около 2%). Така общи думи като „хронична“ или „дете“ не влияят на решението, а имената на заболявания и лекарства влияят.

Правила. Отговор не се генерира в два случая:

- дума, която изглежда като име на лекарство (окончание от международните непатентни наименования или типично за лекарствата окончание), не се среща никъде в корпуса – „„еренумаб“ не се споменава в ръководствата“;
- въпросът съдържа специфични думи, но нито една от тях не се среща в показаните откъси – „в намерените откъси не се споменава „бизопролол“...“.

Второто правило изисква да липсват всички специфични думи, а не само една. Така въпрос, формулиран с думи, различни от тези в ръководството, продължава да получава отговор, ако поне едно от ключовите му понятия е в откъсите. Въпрос без специфични думи също получава отговор.

Оценка. Проверката решава само дали да се генерира отговор, затова е оценена върху откъсите, които системата вече е извлякла: при 24-те въпроса от набора за разработка и при 69-те въпроса от първото пускане на окончателната оценка (`evaluation/coverage_eval.py`). Проверката не спира нито един въпрос в обхвата: 0 от 24 в набора за разработка и 0 от 59 в окончателния набор (95% доверителен интервал 0–6%). От десетте въпроса извън обхвата спира седем, при нито един отказ преди нея (точен тест на Макнемар, $p = 0.016$). Три са спрени от първото правило (еренумаб, семаглутид, ескетамин) и четири от второто (бизопролол, ревматоиден артрит, подагра, зъбен абсцес). Сред тях са и шестте въпроса, на които без проверката генеративният модел отговаряше с несвързано съдържание. Не са спрени трите въпроса, на които моделът и без това отговаря, че в откъсите няма информация (хронична обструктивна белодробна болест, отит и ваксинация). Думите „отит“ и „морбили“ се срещат в показаните откъси, но в друг контекст, например отитът като причина за фебрилни гърчове.

Резултатът почти не зависи от границата за специфична дума (таблица 9). При граница от 5 до 80 откъса проверката спира шест или седем от въпросите извън обхвата и нито един от въпросите в обхвата на окончателния набор. Единственото изключение е един въпрос от набора за разработка при граници 12–20 откъса.

Ограничения. Правилата за глаголните форми и за собствените имена са добавени след прегледа на погрешните откази на първия вариант на проверката, сред които имаше и въпроси от окончателния набор. Затова резултатът върху него е по-оптимистичен от този, който би се получил върху съвсем нови въпроси, макар правилата да са общи, а резултатът да е стабилен в широк диапазон на границата. Проверката работи на ниво дума, а не на ниво смисъл. Тя не открива въпрос извън обхвата, чиято ключова дума се среща в откъсите в друг контекст. Може да откаже и на въпрос в обхвата, ако ключовото му понятие е изразено с дума, каквато в ръководствата няма. За този случай съобщението посочва липсващото понятие, така че потребителят да може да преформулира въпроса.

Таблица 9: Въпроси, спрени от проверката на ключовите понятия, при различна граница за специфична дума

Граница (брой откъси)	Набор за разработка (24)	Окончателен, в обхвата (59)	Окончателен, извън обхвата (10)
5	0	0	6
10	0	0	7
20	1	0	7
30 (избрана)	0	0	7
40	0	0	6
60	0	0	6
80	0	0	6

4.7 Качествен анализ и оценка

Изводите от итерациите в раздели 4.2–4.5 почиват на набора за разработка, върху който са избирани и самите настройки. Затова окончателната оценка е проведена върху отделен набор от въпроси, съставен след края на разработката. Настройките на системата са замразени и съвпадат с тези на демонстрационното приложение по подразбиране: хибридно извличане с повторно класиране и праг 0.1, $k = 5$, BgGPT с 4 милиарда параметри с наказание за повторение 1.2, проверка за неподкрепени подробности и маркиране на източниците. След първото пускане към тях е добавена проверката на ключовите понятия от раздел 4.6, мотивирана от резултатите му при въпросите извън обхвата. Освен правилата на тази проверка, върху набора нищо не е настройвано.

Набор за оценка. Наборът съдържа 59 въпроса в обхвата на корпуса и 10 въпроса извън него. Размерът му следва от оценката на нужния брой въпроси в раздел 4.3 (около 60). Въпросите в обхвата са разпределени по всички 17 ръководства: по два от всяко, а останалите 25 – пропорционално на броя на откъсите му (неврология – 10, хематология – 6, гастроентерология – 5 и т.н.). Въпросите са формулирани от автора въз основа на текста на ръководствата, но така, както би ги задал лекар или фармацевт, без преписване на изрази от откъсите. Целта е да се избегне предимството на лексикалното търсене, отбелязано при набора за разработка. При съставянето им авторът се е допитал до български общопрактикуващ лекар. Повечето въпроси засягат дози, избор на лекарство, продължителност на лечението и подготовка за него, а няколко – причини, симптоми и изследвания. За всеки въпрос, преди да бъдат видени отговорите на системата, са записани мястото в ръководството, където е отговорът (страница и дословен цитат), и между един и четири ключови факта, които верният отговор трябва да съдържа. Верните откъси са определени автоматично по цитата. Ръководствата за хепатити B и C и за възпалителните болести на червата повтарят дословно части от общото ръководство по гастроентерология, затова при съвпадащ текст и откъсът от другото ръководство се приема за верен. При два въпроса друго ръководство отговаря със свой текст: при дозата на тенофовир, която ръководството по гастроентерология и това за хепатити B и C записват различно, и при лечението на болестта на Уилсън, описана и в ръководството по неврология. В тези случаи за верен се приема и другият пасаж. Същото правило е приложено и след пускането, при прегледа на въпросите, при които верният откъс не е показан. При въпроса за дозата на ентекавир показаният откъс от ръководството по гастроентерология дава същите дози като ръковод-

ството за хепатити B и C и е приет за верен. При останалите неуспешни случаи такъв пасаж няма. Един от верните откъси съвпада с откъс от набора за разработка.

Въпросите извън обхвата са медицински, за разлика от въпросите, използвани за калибриране на прага в раздел 4.3, повечето от които са далеч от медицината. Седем са по теми, които нито едно ръководство не покрива: сърдечна недостатъчност, ревматоиден артрит, подагра, хронична обструктивна белодробна болест, зъбен абсцес, остър среден отит и ваксинация срещу морбили, паротит и рубеола. Три са по теми, които ръководствата покриват, но за лекарства, които в тях не се споменават: еренумаб, семаглутид и ескетамин.

Провеждане. Системата е пусната два пъти върху всички 69 въпроса: веднъж без проверката на ключовите понятия и веднъж с нея. Отговорите, класиранията и показаните откъси от двете пускания са запазени (`evaluation/final_eval.py`, `evaluation/results/thesis/`). Извличането е детерминистично и е еднакво при двете пускания. Отговорите на въпросите в обхвата също са еднакви при двете пускания, макар генерирането на графичния процесор по принцип да не е напълно повторимо (раздел 4.3). Затова резултатите по-долу се отнасят за системата с проверката, а там, където е посочено, и за първото пускане. Второто пускане отнема 9.8 минути на машината за разработка, включително зареждането на моделите. Медианното време е 1.0 s за извличането и 5.3 s за генерирането, а най-дългият отговор е генериран за 14.6 s. При първото пускане, при по-натоварена машина, медианите са 1.6 и 7.3 s. Нито един отговор не е прекъснат от ограничението на дължината.

Оценка на отговорите. Отговорите са оценени ръчно, тъй като автоматичното броене на възпроизведени факти отчита наличието на ключова дума, но не и верността на твърдението около нея (раздел 4.2). Схемата на оценката съчетава три утвърдени подхода, всеки от които отговаря на отделен въпрос: колко от нужната информация съдържа отговорът, има ли в него невярно твърдение и колко сериозно е то. Първият подход е оценката по съществени факти (nugget evaluation), въведена в конференцията TREC за оценка на системи за отговаряне на въпроси [38] и приложена наскоро и към системи за извличане с генериране [39]. За всеки въпрос ключовите факти са записани предварително, а показателят е делът на фактите, които се срещат в отговорите. По-нататък той е наречен изчерпателност на отговора, за да не се смесва с пълнотата при извличането. Вторият подход е вярността да се оценява отделно от изчерпателността. Така постъпват Goodman и др. [40], при които лекари оценяват отговорите на езиков модел на медицински въпроси по отделни скали за точност и за пълнота, и авторите на Med-PaLM [41], при които фактическата вярност и възможната вреда са отделни оси на оценката. Всеки отговор получава една от три присъди: „верен и пълен“, ако съдържа всички ключови факти и няма невярно твърдение, „верен, но непълен“, ако липсва част от фактите, и „с невярно твърдение“, ако поне едно твърдение противоречи на ръководството или няма опора в него. При отговорите с невярно твърдение е отбелязана и тежестта на грешката: грешка по същество, когато тя засяга това, което въпросът пита (лекарството, дозата, показанието, популацията или продължителността), и странична неточност, когато основният отговор е верен, а грешката е в допълнителна подробност. Тежестта е определена спрямо въпроса, а не като оценка на клиничната вреда, която би изисквала преценка на лекар. Третият подход е отчитането в строг и мек вариант, както в TREC, където двата варианта се различават по това дали се приема отговор без опора в документа [42]. При строгия вариант всяко невярно твърде-

ние прави отговора грешен, а при мекия – само грешката по същество, докато отговорът със странична неточност се отчита като непълен. Така вярността има три степени: без невярно твърдение, със странична неточност и с грешка по същество. Освен присъдите, за всеки сигнал на проверката за неподкрепени подробности е отбелязано дали е истинска грешка, записани са грешките, които тя е пропуснала, а за всяка връзка от маркирането – дали сочи вярното място. При въпросите извън обхвата, на които системата не отказва, е отбелязано дали отговорът съобщава за липса на информация, или съдържа измислено съдържание.

Извличане. Показателите са същите като в раздел 4.3. Освен строгата оценка, при която за верен се приема само конкретният откъс, е дадена и оценка, при която се приема и съседен откъс от същото ръководство, тъй като откъсите се застъпват и отговорът често продължава в съседния (таблица 10). Окончателният метод отново е най-добрият по всички показатели: верният откъс е първи при 58% от въпросите и е сред първите пет при 86%, а със съседните откъси пълнотата при 5 достига 0.93. Спрямо набора за разработка (таблица 5) стойностите му се променят малко (0.58, 0.92 и 0.74). При `BAAI/bge-m3` пълнотата при 5 също е близка (0.76 срещу 0.79), докато при лексикалното търсене пада от 0.79 на 0.64. Това потвърждава предположението от раздел 4.3, че въпросите от набора за разработка облагодетелстват лексикалното търсене, защото повтарят думите на откъса. Сливането само по себе си не подобрява `BAAI/bge-m3` (0.75 срещу 0.76 при пълнота при 5), т.е. подобрението идва от модела за повторно класиране. Моделът `multilingual-e5-base` остава по-слаб, а `paraphrase-multilingual-mpnet-base-v2` е почти неизползваем при откъси с дължината на тези в корпуса (раздел 4.2).

Таблица 10: Извличане при окончателната оценка (59 въпроса). Вляво – строга оценка, вдясно – приема се и съседен откъс от същото ръководство.

	Строго			Със съседни откъси		
Метод	П@1	П@5	СРР	П@1	П@5	СРР
paraphrase-multilingual-mpnet-base-v2	0.10	0.22	0.15	0.20	0.32	0.26
multilingual-e5-base	0.39	0.64	0.50	0.51	0.75	0.61
bge-m3	0.41	0.76	0.56	0.59	0.88	0.71
BM25 със съкращаване на думите	0.34	0.64	0.47	0.49	0.83	0.62
Сливане (bge-m3 и BM25)	0.44	0.75	0.58	0.58	0.88	0.71
Сливане и повторно класиране	0.58	0.86	0.70	0.69	0.93	0.80

П@k – пълнота при k; СРР – среден реципрочен ранг.

Статистическа значимост. При 59 въпроса част от подобренията, които при набора за разработка не можеха да бъдат потвърдени, стават статистически значими (таблица 11). Спрямо `BAAI/bge-m3` повторното класиране подобрява пълнотата при 1 (печели при 13 въпроса и губи при 3, p = 0.021) и средния реципрочен ранг (p = 0.004). Спрямо самото сливане то подобрява средния реципрочен ранг (p = 0.009), а при пълнотата при 5 печели при 9 въпроса и губи при 2, което е на границата на значимостта (p = 0.065). Подобрението на пълнотата при 5 спрямо `BAAI/bge-m3` обаче остава незначимо (10 срещу 4 въпроса, p = 0.18). Повторното класиране губи при четири въпроса, а не при нито един,

както при набора за разработка, което съответства на по-песимистичния сценарий от раздел 4.3, изискващ около 190 въпроса. Следователно основният доказан принос на повторното класиране е в подреждането: верният откъс по-често е на първо място. Разликите между `BAAI/bge-m3`, лексикалното търсене и `multilingual-e5-base` не са значими, а значимо е само изоставането на `paraphrase-multilingual-mpnet-base-v2`.

Таблица 11: Значимост на разликите при извличането в окончателната оценка (59 въпроса, строга оценка). Означенията и тестовете са като в таблица 6.

Сравнение (А → Б)	Пълнота при 1: само А / само Б, p	Пълнота при 5: само А / само Б, p	Среден реципрочен ранг: А → Б, p
bge-m3 → сливане и повторно класиране	3 / 13; 0.021	4 / 10; 0.18	0.56 → 0.70; 0.004
сливане → сливане и повторно класиране	5 / 13; 0.096	2 / 9; 0.065	0.58 → 0.70; 0.009
bge-m3 → сливане	3 / 5; 0.73	6 / 5; 1.00	0.56 → 0.58; 0.58
bge-m3 → BM25 със съкращаване	10 / 6; 0.45	13 / 6; 0.17	0.56 → 0.47; 0.089
bge-m3 → multilingual-e5-base	9 / 8; 1.00	12 / 5; 0.14	0.56 → 0.50; 0.34
bge-m3 → paraphrase-multilingual-mpnet-base-v2	18 / 0; <0.001	32 / 0; <0.001	0.56 → 0.15; <0.001

Откази. Системата не отказва на нито един въпрос в обхвата. С проверката на ключовите понятия тя отказва на седем от десетте медицински въпроса извън обхвата (95% доверителен интервал 40–89%), а без нея – на нито един. Прагът за отказ сам по себе си не спира нито един от тези въпроси. Най-високата оценка на модела за повторно класиране при тях е между 0.10 и 0.69 (медиана 0.42), при праг 0.1. При въпросите в обхвата най-ниската оценка е 0.30, а медианата – 0.96. Двата интервала се застъпват, така че никой праг не разделя напълно двете групи. Праг 0.3 би отказал на три от десетте въпроса извън обхвата без погрешен отказ, праг 0.5 – на осем от тях, но и на три въпроса в обхвата, а отказът на всички въпроси извън обхвата (праг 0.7) би струвал осем погрешни отказа. Прагът от раздел 4.3 е калибриран върху въпроси, далечни от медицината (най-висока оценка 0.049), и разпознава именно тях. При медицински въпрос моделът за повторно класиране намира откъси, свързани с отделни думи от въпроса – лекарството, органа или вида лечение – и им дава средни оценки.

При първото пускане, без проверката на ключовите понятия, решението дали да се отговори зависеше изцяло от генеративния модел. При четири от десетте въпроса (хроничната обструктивна белодробна болест, отитът, ваксинацията и еренумабът) той отговаря, че в откъсите няма такава информация, като понякога посочва какво съдържат те. При останалите шест отговаря с подробности от несвързаните откъси. На въпроса за ревматоиден артрит изрежда лекарства за множествена склероза (бета-интерферони, глатирамер ацетат, терифлуномид, диметил фумарат), на въпроса за подагра – кортикостероиди от текста за пристъпите на множествена склероза, на въпроса за ескетамин – дозата на десмопресин, а на въпроса за бизопролол дава доза „3–5 mg три пъти дневно“, каквато няма в нито едно ръководство, с позоваване на ръководството по хематология. Това са най-опасните грешки в оценката, защото отговорът изглежда уверен и се позовава на източник. Проверката на ключовите понятия спира и шестте въпроса, както и въпроса за

еренумаба (раздел 4.6). На останалите три въпроса извън обхвата системата с проверката отговаря, че в откъсите няма такава информация.

Проверка за неподкрепени подробности и маркиране. Проверката отбелязва подробности в 4 от 62-те генерирани отговора (5 сигнала), всички на въпроси в обхвата. При първото пускане тя не отбеляза нито един от шестте отговора с несвързано съдържание на въпросите извън обхвата: имената и числата в тях се срещат в показаните откъси, макар и в друг контекст. Проверката потвърждава, че дадена подробност я има в източника, но не и че източникът се отнася за въпроса. Маркирането свързва изречения от отговорите с изречения от откъсите в 241 връзки, 26 изречения остават без съответствие, а 111 от 287 показани откъса са използвани в отговорите.

Анализ на грешките. Грешките са разгледани по компонентите, които ги предизвикват.

Извличане. Верният откъс не е показан на модела при 8 от 59 въпроса. Причините са няколко:

- *Разделяне на раздела при фрагментирането.* Схемата за предоперативна химиотерапия при хепатобластом е в откъс, в който думата „хепатобластом“ не се среща, защото заглавието на раздела остава в предходния откъс, и нито един метод не класира този откъс сред първите десет. Лечението на неоперабилния хепатоцелуларен карцином (sorafenib) е в откъса след описанието на заболяването. Моделът за повторно класиране показва описанието, а откъса с лечението поставя на шесто място. Поддържащата терапия на острата миелоидна левкемия при деца е в откъс, обозначен с раздела за болестта на Ходжкин, в който заболяването се споменава само със съкращението AML.
- *Съкращения.* Текстът за лечението на епилептичния статус използва съкращението „ЕС“. Лексикалното търсене не намира откъса, а след сливането той е 21-ви – точно извън 20-те кандидата за повторно класиране.
- *Грешка на модела за повторно класиране.* При въпроса дали се спира лечението на болестта на Крон по време на бременност двата верни откъса са на шесто и осмо място след сливането, но моделът за повторно класиране ги измества на 15-о и 16-о място в полза на откъси за лечението на множествена склероза.
- *Повреден текст.* В сканираното ръководство по хематология верният откъс за полицитемия вера е осми.
- *Съседен откъс.* При два въпроса е показан съседният на верния откъс. При въпроса за лечението на хепатит B преди директно действащите антивирусни средства той съдържа продължението на отговора, но не и самото указание. Отговорът е верен по същество, но се позовава на цитат, който не го подкрепя. При въпроса дали депресията може да предизвика болест на Крон съседният откъс започва непосредствено след отговора и моделът отговаря погрешно, че няма данни за връзка.

Двата случая показват, че строгата оценка и оценката със съседни откъси (пълнота при 5 0.93) ограждат реалното положение. Съседният откъс понякога съдържа част от отговора, а понякога – нищо от него. Случаят с ентекавира, приет за верен след прегледа, показва и че строгата оценка може да подцени извличането, когато друго ръководство дава същата информация.

Генериране. Когато верният откъс липсва, генеративният модел не отказва, а отговаря с подробности от показаните откъси, както при въпросите извън обхвата. За хепатоб-

ластома дава схема с vincristine и dactinomycin от друг тумор, за хепатоцелуларния карцином – схемата FOLFIRINOX от предходния раздел за рак на панкреаса, а за болестта на Крон – спиране на natalizumab и alemtuzumab, които са лекарства за множествена склероза. При показан верен откъс грешките са главно пропуски и разместване на подробности. При болестта на Уилсън отговорът назовава само D-penicillamine, въпреки че показаният откъс съдържа и триентин. При хроничната миелоидна левкемия дозите са приписани на грешни лекарства (на dasatinib – дозата на nilotinib), като в сканирания текст имената на лекарствата са изкривени. При далтепарина отговорът добавя подробност (18.3 mg), каквато в откъсите няма, и тя е отбелязана от проверката.

Корпус. Част от грешките идват от данните, а не от системата. В ръководството по детска клинична хематология и онкология предварителната обработка е загубила много от имената на лекарствата в таблиците със схеми (например vincristine се среща 67 пъти в текста на PDF файла и само 23 пъти в откъсите, а cytarabine – 36 и 20 пъти), вероятно защото повтарящите се редове са премахнати като колонтитули. Затова в схемата на поддържащата терапия при острата миелоидна левкемия дозата на cytarabine е останала без името на лекарството. При този въпрос верният откъс не е показан, а отговорът е съставен от откъс от сканираното ръководство по хематология и съдържа изкривеното при разпознаването име на лекарството. Около 1% от текста на PDF файловете изобщо не е влязъл в откъсите, главно таблици с лекарства (стр. 30–37 от ръководството по урологични заболявания). Отделен случай са две ръководства, които дават една и съща информация различно. Ръководството по гастроентерология посочва за тенофовир 300 mg дневно, а ръководството за хепатити B и C – 245 mg тенофовир дизопроксил или 25 mg тенофовир алафенамид. По думите на консултиралия автора лекар в някои страни препаратът се продава в доза 300 mg, а в други – 245 mg, което вероятно е довело до разликата. При този въпрос системата показва само откъси от ръководството по гастроентерология и отговаря „300 mg веднъж дневно“, без да спомене другото ръководство. Тя третира ръководствата като независими източници и не открива, когато те си противоречат или записват едно и също различно.

Ограничения на оценката. Въпросите, ключовите факти и ръчните присъди са на един автор. При ново пускане отделни отговори могат да се различават в подробности, макар двете пускания тук да дадоха еднакви отговори в обхвата. Десетте въпроса извън обхвата са достатъчни, за да покажат, че прагът сам не разпознава медицинските въпроси извън обхвата (0 от 10 отказа, 95% доверителен интервал 0–28%) и че проверката на ключовите понятия подобрява това значимо. Те не са достатъчни обаче за точна оценка на дела на отказите, а правилата на проверката са уточнени след преглед и на въпроси от този набор (раздел 4.6). Строгата оценка на извличането подценява системата, а оценката със съседни откъси я надценява, когато съседният откъс не съдържа отговора.

Изводи. Окончателната оценка потвърждава избора на хибридно извличане с повторно класиране и прави статистически значимо подобрението му в подреждането на откъсите. Тя показа и най-сериозния проблем на системата: при медицински въпроси извън обхвата прагът върху оценката за релевантност не отказва, а генеративният модел в повечето случаи използва несвързаните откъси. Проверката за неподкрепени подробности не открива тези грешки, защото проверява подкрепата, а не уместността на източника. Проверката на ключовите понятия (раздел 4.6) решава проблема в седем от десетте случая, без погрешен отказ. Остават два вида случаи, които тя не улавя, защото понятията от въпроса присъстват

в показаните откъси: въпроси, чиято ключова дума се среща в друг контекст, и въпросите в обхвата, при които верният откъс не е намерен и моделът отговаря от съседни по тема откъси. За тях е нужна преценка по смисъл дали откъсите отговарят на въпроса, например отделна стъпка, в която генеративният модел решава само това. Втората група подобрения засяга данните: фрагментиране, което не разделя заглавието на раздела от съдържанието му, възстановяване на загубените имена на лекарства и предупреждение, когато откъси от различни ръководства съдържат различни дози за едно лекарство.

5 Техническа реализация

Тази глава описва как е реализирана системата: използваните инструменти, организацията на кода и данните и средствата за проверка и възпроизвеждане на резултатите. Изборът на методите е обоснован в глави 3 и 4, затова тук се препраща към тях. Инсталирането и стартирането са описани в приложение 1.

5.1 Използвани инструменти и технологии

Системата е написана на Python, на който са и всички използвани библиотеки за работа с езикови модели, така че целият конвейер, от индексирането до уеб интерфейса, е на един език. Таблица 12 изброява инструментите с версиите, с които са получени резултатите в тази работа.

Повечето избори вече са обосновани в предходните глави: FAISS в раздел 3.2, BgGPT в раздели 3.4 и 4.4, Streamlit в раздел 4.1, а изчисленията на графичния процесор в половинна точност в раздел 4.3. Остават два избора, които се отнасят само до реализацията.

Изпълнение на генеративния модел. Освен Ollama са разгледани три възможности за локално изпълнение на BgGPT. Библиотеката transformers зарежда теглата на модела в половинна точност, при което вариантът с 4 милиарда параметри заема около 8 GB, повече от наличните 6 GB видеопамет. Намаляването на паметта до 4 бита би изисквало допълнителни библиотеки за квантуване и не би използвало вече публикуваните от INSAIT квантувани версии. Библиотеката llama-cpp-python използва същия изпълнителен механизъм като Ollama (llama.cpp), но за работа на графичния процесор се компилира при инсталирането, което под Windows изисква отделни средства за компилиране и поддръжка на CUDA и прави инсталирането крехко. Сървърът vLLM е предназначен за едновременна работа на много потребители и поддържа официално само Linux. Ollama предлага готови изпълними файлове с поддръжка на CUDA, работи с квантуваните модели във формата GGUF и сам управлява зареждането и освобождаването им, а към него се изпращат заявки по протокола HTTP на локалния адрес. Цената на това удобство е по-малкият контрол: кешът на обработените подсказки в оперативната памет, достигащ до 8 GB, не може да бъде ограничен, което на машината за разработка неколкократно изчерпа паметта при серии от заявки.

Векторни представяния. Библиотеката sentence-transformers е предпочетена пред директното използване на transformers, защото предоставя общ интерфейс за моделите за векторно представяне и за кръстосания енкодер, с групова обработка и нормализиране на

Таблица 12: Използвани инструменти и модели

Компонент	Инструмент (версия)	Роля
Език	Python 3.11.9	целият конвейер
Изчисления	PyTorch 2.14.0 (CUDA 12.6)	изпълнение на моделите за векторно представяне и повторно класиране на графичния процесор
Векторно представяне	sentence-transformers 6.0.1 (transformers 5.17.0)	зареждане на моделите, изчисляване на векторите, кръстосан енкодер
Векторна база	FAISS 1.15.0	точно търсене по косинусова близост (раздел 3.2)
Лексикално търсене	rank_bm25 0.2.2	функцията за класиране BM25
Генериране	Ollama 0.34.4 (llama.cpp), клиент ollama 0.6.2	локален сървър за генеративния модел
Уеб интерфейс	Streamlit 1.64.0	демонстрационното приложение (раздел 4.1)
Модели		
Векторно представяне	`BAAI/bge-m3` (по подразбиране), `multilingual-e5-base`, `paraphrase-multilingual-mpnet-base-v2`	семантично търсене; съпоставяне на изреченията (раздел 4.5)
Повторно класиране	`BAAI/bge-reranker-v2-m3`	подреждане на кандидатите и праг за отказ
Генериране	BgGPT 4B (Gemma 3) и 2.6B (Gemma 2), 4-битово квантуване (Q4_K_M)	генериране на отговора

векторите. При директно използване на transformers обединяването на векторите на отделните токени във вектор на целия текст трябва да се реализира отделно за всеки модел, тъй като `BAAI/bge-m3` използва вектора на първия токен, а другите два модела – средното на всички. Грешка в тази стъпка би влошила извличането, без да е очевидна.

Машина за разработка. Системата е разработена и оценена на компютър с Windows 11, графичен процесор NVIDIA GeForce RTX 2060 с 6 GB видеопамет и 16 GB оперативна памет, от които при работа обикновено са свободни между 2 и 5 GB. Тези ограничения определиха няколко решения: 4-битовото квантуване на генеративния модел, половинната точност на останалите модели, зареждането на моделите веднъж и преизползването им при следващите въпроси и наличието на само един генеративен модел във видеопаметта. Определиха и начина на провеждане на експериментите: скриптовете за оценка се изпълняват при спряно приложение и периодично освобождават модела в Ollama, за да не се изчерпи паметта.

5.2 Структура на проекта и файлове

Кодът на системата е в пакета `src/medguiderag/` и е разделен на модули по стъпките на конвейера (таблица 13). Модулите са общо около 720 реда код, от които най-обемни са

проверката за неподкрепени подробности и съпоставянето на изреченията. Освен пакета проектът съдържа папката `evaluation/` със скриптовете за оценка (раздел 5.3), папката `data/` с корпуса и индексите и папката `docs/` с текста на дипломната работа.

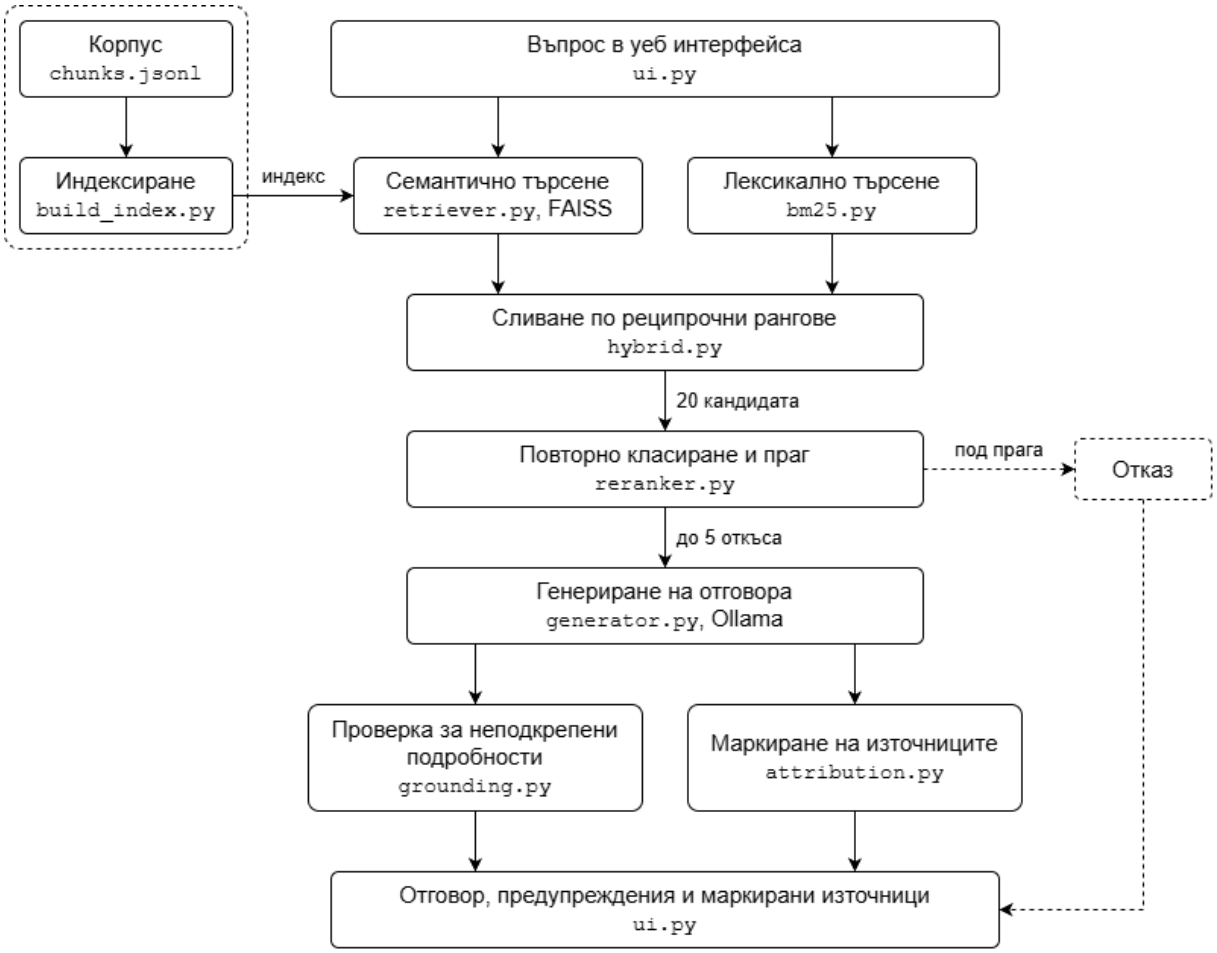
Таблица 13: Модули на пакета `src/medguiderag`

Файл	Предназначение
`config.py`	пътища до данните, модели, праг за отказ, брой кандидати, граница за редките думи
`ingest/load_chunks.py`	зареждане на откъсите от корпуса
`indexing/embed.py`	зареждане на модела за векторно представяне и изчисляване на нормализираните вектори
`indexing/build_index.py`	изграждане на индекса и метаданните за даден модел (от командния ред)
`retrieval/retriever.py`	семантично търсене в индекса
`retrieval/bm25.py`	лексикално търсене със съкращаване на думите
`retrieval/reranker.py`	модел за повторно класиране
`retrieval/hybrid.py`	хибридно извличане: сливане, повторно класиране, праг
`generation/coverage.py`	проверка дали ключовите понятия от въпроса се срещат в откъсите
`generation/generator.py`	подсказка и заявка към Ollama; премахва указанието, ако моделът го повтори в началото на отговора
`generation/grounding.py`	проверка за неподкрепени подробности
`generation/attribution.py`	съпоставяне на изреченията от отговора с откъсите
`app/ui.py`	уеб интерфейс

Фигура 8 показва как модулите се свързват при обработката на въпрос. Индексирането е предварителна стъпка, която се изпълнява веднъж за всеки модел за векторно представяне. Индексът за BM25 не се записва, а се изгражда в паметта при създаването на компонента за извличане, тъй като за 1380 откъса това отнема под секунда. Моделите се зареждат при първото използване и остават в паметта: на ниво модул чрез кеширане на функциите, които ги зареждат, и на ниво приложение чрез кеширане на ресурсите в Streamlit. Един и същ модел за векторно представяне служи и за извличането, и за съпоставянето на изреченията. Речникът с имената на лекарства, който използва проверката за неподкрепени подробности, и честотите на думите, които използва проверката на ключовите понятия, се изграждат веднъж от целия корпус.

Данни. Корпусът е копие на резултата от преддипломния проект в папката `data/processed/`, така че системата не зависи от неговите файлове. Файлът `chunks.jsonl` съдържа по един ред за всеки от 1380-те откъса с текста, документа, началната и крайната страница, раздела, идентификатора и броя думи. Файлът `documents.jsonl` съдържа текста по страници (1872 страници). Системата не го използва при отговор, но той би позволил маркирането на източниците да се пренесе в оригиналните документи. За всеки модел за векторно представяне индексът е в отделна папка `data/index/`, наименувана по модела, и се състои от три файла: индекса на FAISS, метаданните на откъсите в същия ред като векторите и статистика за изграждането (модел, брой откъси, размерност, време).

Конфигурация. Параметрите, които определят поведението на системата, са събрани на две места. В `config.py` са генеративните модели с имената им в интерфейса, кандида-



Фигура 8: Компоненти на системата и обработката на един въпрос.

тите за модел за векторно представяне, моделът за повторно класиране, броят кандидати за него (20), прагът за отказ (0.1) и границата, под която една дума се смята за рядка при проверката на ключовите понятия (30 откъса). В `generation/generator.py` са параметрите на генерирането: контекстен прозорец от 8192 токена, температура нула, наказание за повторение 1.2 и най-много 1024 генерирани токена. Размерът на шрифта в интерфейса се задава във файла с настройки на Streamlit. Така смяната на модел или на праг изисква промяна на един ред.

5.3 Проверка и възпроизводимост

За модулите няма автоматизирани тестове, като това е ограничение на реализацията. Коректността е проверявана по два други начина.

Проверка на работещото приложение. След всяка промяна приложението се стартира и в него се задават въпроси, като се проверяват отговорът, предупрежденията и показаните източници. Така се проверява системата такава, каквато я вижда потребителят, включително отказът и маркирането на източниците.

Възпроизвеждане на резултатите. Всяка таблица и всеки числов резултат от глава 4 се възпроизвеждат със самостоятелен скрипт от папката `evaluation/`, например `python -m evaluation.retrieval_eval` за сравнението на методите за извличане, а графиките в нея – с `python -m evaluation.figures`. Наборът за разработка, въпросите извън обхвата и ключовите факти са в `evaluation/data/`. Тъй като генерирането на графичния процесор не е напълно повторимо (раздел 4.3), отговорите, класиранията и ръчните оценки, върху които са изчислени числата в текста, са запазени в `evaluation/results/thesis/`. Скриптовете, които не генерират нови отговори, като проверката за значимост и оценките на проверката и на маркирането, четат тези файлове и дават точно числата от текста. Скриптовете, които генерират отговори наново, дават същите изводи, но броят на възпроизведените факти може да се различава с един-два. Повторното пускане на всички скриптове потвърди числата в таблиците, като единствената разлика беше един факт при един от вариантите на подсказката (таблица 2). Изключение правят времената за изпълнение, които зависят от натоварването на машината: при повторното измерване повторното класиране отне 1.7 вместо 1.0 секунди на въпрос.

6 Изводи и препоръки за бъдещо развитие

7 Заключение

Литература

[1] Национален съвет по цени и реимбурсиране на лекарствените продукти. *Архив на утвърдени фармако-терапевтични ръководства*. https://www.ncpr.bg/bg/архив-на-утвърдени-фармако-терапевтични-ръководства.html, последно посещение: 06.10.2026.

[2] Ц. Пашовска. *Приложение на изкуствения интелект в работата на общопрактикуващите лекари в България – нагласи и предпочитания*. Курсов проект по избираемата дисциплина „Методология на изследователската работа“, магистърска програма „Изкуствен интелект“, ФМИ, СУ „Св. Климент Охридски“, 2025. `https://drive.google.com/file/d/1feuolmZadh7SvwRkg3pWH06SqLuoUsak/view`

[3] Ц. Пашовска. *Извличане и структуриране на текст от национални фармакотерапевтични ръководства за RAG система*. Преддипломен проект, магистърска програма „Изкуствен интелект“, ФМИ, СУ „Св. Климент Охридски“, 2026. `https://github.com/ccvetanska/Pdp`

[4] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. Yih, T. Rocktäschel, S. Riedel, D. Kiela. *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. Advances in Neural Information Processing Systems (NeurIPS), 2020. arXiv:2005.11401.

[5] S. Wu, Y. Xiong, Y. Cui, H. Wu, C. Chen, Y. Yuan, L. Huang, X. Liu, T.-W. Kuo, N. Guan, C. J. Xue. *Retrieval-Augmented Generation for Natural Language Processing: A Survey*. arXiv:2407.13193, 2024.

[6] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, M. Wang, H. Wang. *Retrieval-Augmented Generation for Large Language Models: A Survey*. arXiv:2312.10997, 2023.

[7] C. Sharma. *Retrieval-Augmented Generation: A Comprehensive Survey of Architectures, Enhancements, and Robustness Frontiers*. arXiv:2506.00054, 2025.

[8] A. Singh, A. Ehtesham, S. Kumar, T. Talaei Khoei, A. V. Vasilakos. *Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG*. arXiv:2501.09136, 2025.

[9] B. Malin, T. Kalganova, N. Boulgouris. *A Review of Faithfulness Metrics for Hallucination Assessment in Large Language Models*. arXiv:2501.00269, 2024.

[10] M. S. Tamber, F. S. Bao, C. Xu, G. Luo, S. Kazi, M. Bae, M. Li, O. Mendelevitch, R. Qu, J. Lin. *Benchmarking LLM Faithfulness in RAG with Evolving Leaderboards*. arXiv:2505.04847, 2025.

[11] K. Luo, M. Qin, Z. Liu, S. Xiao, J. Zhao, K. Liu. *Large Language Models as Foundations for Next-Gen Dense Retrieval: A Comprehensive Empirical Assessment*. arXiv:2408.12194, 2024.

[12] A. Rashmiks, T. Madushanka. *A Comprehensive Empirical Evaluation of Vector Database Systems for Approximate Nearest Neighbor Search: Performance, Quality, and Resource Trade-offs*. arXiv:2608.12812, 2026.

[13] J. He, B. Zhang, H. Rouhizadeh, Y. Chen, R. Yang, J. Lu, X. Chen, N. Liu, D. Teodoro. *Retrieval-Augmented Generation in Biomedicine: A Survey of Technologies, Datasets, and Clinical Applications*. arXiv:2505.01146, 2025.

[14] Y. Miao, Y. Zhao, Y. Luo, H. Wang, Y. Wu. *Improving Large Language Model Applications in the Medical and Nursing Domains With Retrieval-Augmented Generation: Scoping Review*. Journal of Medical Internet Research, 27:e80557, 2025.

[15] L. Li, W. Zhu. *Pursuing Best Industrial Practices for Retrieval-Augmented Generation in the Medical Domain*. arXiv:2602.03368, 2026.

[16] L. Ranaldi, B. Haddow, A. Birch. *Multilingual Retrieval-Augmented Generation for Knowledge-Intensive Task*. arXiv:2504.03616, 2025.

[17] I. Marinova, K. Simov, P. Osenova. *Transformer-Based Language Models for Bulgarian*. Proceedings of RANLP 2023 (Recent Advances in Natural Language Processing), 2023.

[18] N. Paev, K. Simov, P. Osenova, S. Petrova. *Large Language Models for Bulgarian*. CLaDA-BG Conference, 2024.

[19] A. Omotoso, H. Shopeju, A. M. Joshua, S. Oni. *Improving BGE-M3 Multilingual Dense Embeddings for Nigerian Low Resource Languages*. Proceedings of the 9th Widening NLP Workshop (WiNLP), pp. 224–229, 2025.

[20] A. Nzeyimana, A. N. Rubungo. *KinyaColBERT: A Lexically Grounded Retrieval Model for Low-Resource Retrieval-Augmented Generation*. arXiv:2507.03241, 2025.

[21] Z. Navasardyan, S. Bughdaryan, B. Minasyan, H. Davtyan. *Less is More: Adapting Text Embeddings for Low-Resource Languages with Small Scale Noisy Synthetic Data*. arXiv:2603.22290, 2026.

[22] A. Alexandrov, V. Raychev, D. I. Dimitrov, C. Zhang, M. Vechev, K. Toutanova. *BgGPT 1.0: Extending English-centric LLMs to other languages*. arXiv:2412.10893, 2024.

[23] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian, Z. Liu. *M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*. Findings of the Association for Computational Linguistics: ACL 2024, 2024. arXiv:2402.03216.

[24] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, F. Wei. *Multilingual E5 Text Embeddings: A Technical Report*. arXiv:2402.05672, 2024.

[25] N. Reimers, I. Gurevych. *Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation*. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), pp. 4512–4525, 2020.

[26] S. Robertson, H. Zaragoza. *The Probabilistic Relevance Framework: BM25 and Beyond*. Foundations and Trends in Information Retrieval, 3(4):333–389, 2009.

[27] G. V. Cormack, C. L. A. Clarke, S. Büttcher. *Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods*. Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval, pp. 758–759, 2009.

[28] R. Nogueira, K. Cho. *Passage Re-ranking with BERT*. arXiv:1901.04085, 2019.

[29] N. F. Liu, K. Lin, J. Hewitt, A. Paranjape, M. Bevilacqua, F. Petroni, P. Liang. *Lost in the Middle: How Language Models Use Long Contexts*. Transactions of the Association for Computational Linguistics, 12:157–173, 2024.

[30] Q. McNemar. *Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages*. Psychometrika, 12(2):153–157, 1947.

[31] M. D. Smucker, J. Allan, B. Carterette. *A Comparison of Statistical Significance Tests for Information Retrieval Evaluation*. Proceedings of the 16th ACM Conference on Information and Knowledge Management (CIKM), pp. 623–632, 2007.

[32] Y. Zhang и др. *Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models*. arXiv:2506.05176, 2025.

[33] H. Schechter Vera и др. *EmbeddingGemma: Powerful and Lightweight Text Representations*. arXiv:2509.20354, 2025.

[34] R. J. Connor. *Sample Size for Testing Differences in Proportions for the Paired-Sample Design*. Biometrics, 43(1):207–211, 1987.

[35] A. Holtzman, J. Buys, L. Du, M. Forbes, Y. Choi. *The Curious Case of Neural Text Degeneration*. International Conference on Learning Representations (ICLR), 2020. arXiv:1904.09751.

[36] N. S. Keskar, B. McCann, L. R. Varshney, C. Xiong, R. Socher. *CTRL: A Conditional Transformer Language Model for Controllable Generation*. arXiv:1909.05858, 2019.

[37] E. B. Wilson. *Probable Inference, the Law of Succession, and Statistical Inference*. Journal of the American Statistical Association, 22(158):209–212, 1927. https://doi.org/10.2307/2276774

[38] E. M. Voorhees. *Overview of the TREC 2003 Question Answering Track*. Proceedings of the Twelfth Text REtrieval Conference (TREC 2003), NIST Special Publication 500-255, 2003.

[39] R. Pradeep, N. Thakur, S. Upadhyay, D. Campos, N. Craswell, J. Lin. *Initial Nugget Evaluation Results for the TREC 2024 RAG Track with the AutoNuggetizer Framework*. arXiv:2411.09607, 2024.

[40] R. S. Goodman, J. R. Patrinely, C. A. Stone и др. *Accuracy and Reliability of Chatbot Responses to Physician Questions*. JAMA Network Open, 6(10):e2336483, 2023.

[41] K. Singhal, S. Azizi, T. Tu и др. *Large Language Models Encode Clinical Knowledge*. Nature, 620(7972):172–180, 2023.

[42] E. M. Voorhees. *Overview of the TREC-9 Question Answering Track*. Proceedings of the Ninth Text REtrieval Conference (TREC-9), NIST Special Publication 500-249, 2001.

ПРИЛОЖЕНИЯ

Приложение 1. Инсталиране и стартиране

Командите са за Windows и се изпълняват в PowerShell или в Git Bash от основната папка на проекта. Необходими са Python 3.11 и около 20 GB свободно място за моделите и библиотеките. За работа на графичния процесор е нужна видеокарта NVIDIA с драйвер, поддържащ CUDA 12.6. Без нея системата работи на централния процесор, но повторното класиране е бавно и в интерфейса трябва да се изключи.

1. Генеративен модел. Инсталира се Ollama и се изтеглят двата варианта на BgGPT:

```
winget install --id Ollama.Ollama -e
ollama pull hf.co/INSAIT-Institute/BgGPT-Gemma-3-4B-IT-GGUF:Q4_K_M
ollama pull hf.co/INSAIT-Institute/BgGPT-Gemma-2-2.6B-IT-v1.0-GGUF:
   Q4_K_M
```

2. Среда на Python. Създава се виртуална среда и библиотеките се инсталират на отделни стъпки, защото общата инсталация изчерпа паметта на машината за разработка при разархивирането на PyTorch. Втората команда заменя варианта на PyTorch само за централния процесор с варианта с CUDA и се пропуска, ако няма видеокарта NVIDIA:

```
python -m venv .venv
.venv/Scripts/python.exe -m pip install sentence-transformers
.venv/Scripts/python.exe -m pip install "torch==2.14.0+cu126" --index
   -url https://download.pytorch.org/whl/cu126
.venv/Scripts/python.exe -m pip install faiss-cpu ollama streamlit
   rank_bm25
.venv/Scripts/python.exe -m pip install -e .
```

3. Индекси и модели. Индексите се изграждат еднократно, като при това се изтеглят моделите за векторно представяне. Последната команда изтегля модела за повторно класиране. Изграждането на индекса с `BAAI/bge-m3` отнема около две минути на графичния процесор и около два часа на централния. Тази стъпка изисква връзка с интернет, а след нея системата работи без мрежа:

```
.venv/Scripts/python.exe -m medguiderag.indexing.build_index "BAAI/
   bge-m3"
.venv/Scripts/python.exe -m medguiderag.indexing.build_index "
   intfloat/multilingual-e5-base"
.venv/Scripts/python.exe -m medguiderag.indexing.build_index "
   sentence-transformers/paraphrase-multilingual-mpnet-base-v2"
.venv/Scripts/python.exe -c "from sentence_transformers import
   CrossEncoder; CrossEncoder('BAAI/bge-reranker-v2-m3', device='cpu
   ')"
```

4. Стартиране. Приложението се стартира с командата по-долу и се отваря на адрес `http://localhost:8501`. Първият въпрос отнема около 35 секунди, докато се заредят моделите. На машина с малко свободна памет е препоръчително броят на нишките на числовите библиотеки да се ограничи с променливите на средата `OMP_NUM_THREADS`, `OPENBLAS_NUM_THREADS` и `MKL_NUM_THREADS` (например до 2):

```
.venv/Scripts/python.exe -m streamlit run src/medguiderag/app/ui.py
```

5. Възпроизвеждане на оценката. Скриптовете за оценка се изпълняват при спряно приложение с `python -m evaluation.<script>`. Описание на всеки от тях и на таблицата, която възпроизвежда, има във файла `evaluation/README.md`.