Софийски университет „Св. Климент Охридски“
Факултет по математика и информатика
Катедра „Компютърна информатика“

ДИПЛОМНА РАБОТА

Система за извличане с генериране (RAG) за достъп до фармакотерапевтични ръководства на български език

Цветелина Пашовска
Магистърска програма „Изкуствен интелект“, фак. номер 7MI3400669

Ръководител:
проф. д-р Мария Нишева
катедра „Компютърна информатика“, ФМИ, СУ „Св. Климент Охридски“

София, 2026

Съдържание

1 Увод **2**
1.1 Достъп до медицинска информация на български език и ролята на извличането с генериране . . . 2
1.2 Цели и задачи на дипломната работа . . . 3

2 Литературен обзор **4**
2.1 Архитектура и компоненти на системите за извличане с генериране . . . 4
2.2 Методи за извличане и модели за векторно представяне . . . 5
2.3 Приложения в областта на медицината . . . 6
2.4 Особености при работа с по-слабо ресурсни езици . . . 6

3 Методология **8**
3.1 Корпус от данни . . . 8
3.2 Изграждане на векторно представяне и индексиране . . . 8
3.3 Извличане на релевантни откъси . . . 9
3.4 Генериране на отговори . . . 10

4 Експерименти и резултати **11**
4.1 Демонстрационно приложение . . . 11
4.2 Подобряване на резултатите – съставяне на подсказката към генеративния модел . . . 13
4.3 Подобряване на резултатите – хибридно извличане, повторно класиране и праг за отказ . . . 17
4.4 Подобряване на резултатите – проверка на отговора за неподкрепени в откъсите детайли . . . 23
4.5 Подобряване на резултатите – маркиране на изреченията, на които стъпва отговорът . . . 25
4.6 Подобряване на резултатите – проверка дали ключовите понятия от въпроса ги има в откъсите . . . 26
4.7 Качествен анализ и оценка . . . 27

5 Техническа реализация **34**
5.1 Използвани инструменти и технологии . . . 34
5.2 Структура на проекта и файлове . . . 35
5.3 Проверка и възпроизводимост . . . 36

6 Изводи и препоръки за бъдещо развитие **38**
6.1 Изводи . . . 38
6.2 Препоръки за бъдещо развитие . . . 39

7 Заключение **41**

Литература **42**

Приложения **45**
Приложение 1. Инсталиране и стартиране . . . 45

1 Увод

1.1 Достъп до медицинска информация на български език и ролята на извличането с генериране

Фармакотерапевтичните ръководства, публикувани от Националния съвет по цени и реимбурсиране на лекарствените продукти [1], съдържат клинично и нормативно значима информация за десетки медицински области, но са структурирани като обемни PDF документи с разнородно вътрешно оформление. За здравен специалист, който търси конкретна препоръка, дозировка на лекарство или противопоказание, това на практика означава ръчно търсене в десетки страници, дори когато отговорът вече е формулиран в официално одобрен документ. Проблемът тук не е липса на информация, а нейната трудна дотъпност в момента на вземане на клиничното решение.

Тази трудност се потвърждава и от самите лекари. В курсов проект по избираемата дисциплина „Методология на изследователската работа“ авторът на настоящата дипломна работа проучва нагласите на общопрактикуващите лекари в България към системите с изкуствен интелект чрез анкета, попълнена от 13 лекари в периода април – юни 2025 г. [2]. На въпроса при кои предизвикателства подобни системи биха им били от най-голяма полза 7 от 13 анкетирани посочват трудния достъп до актуална медицинска информация. Това е третият по честота отговор след координацията със специалисти (9) и проследяването на хронични заболявания (8), а в свободен текст един от лекарите назовава изрично като очакване „възможен достъп до медицински стандарти“. Същото проучване очертава и условията, при които такава система би била използвана. Най-честото притеснение е опасността от грешки (11 от 13), следвано от нарушаването на поверителността (6) и липсата на прозрачност (5), а като най-силни фактори за решението да започнат да я използват 12 от 13 лекари посочват научните доказателства за точност и лесната употреба. Тези очаквания съответстват пряко на проектните решения в настоящата система: при липса на подходящ откъс от ръководствата тя отказва да отговори (раздели 4.3 и 4.6), генерираният отговор се проверява за неподкрепени детайли (раздел 4.4) и се придружава от източниците си с отбелязани съответстващи изречения (раздел 4.5), а цялата обработка се извършва локално, без въпросите да напускат компютъра на потребителя (раздел 4.1). Извадката обаче е малка и непредставителна, тъй като преобладават лекари под 30-годишна възраст, със стаж под три години и с практика в столицата. Затова резултатите се приемат като ориентир за нуждите на практиката, а не като статистически обоснован извод.

Система от типа извличане с генериране (Retrieval-Augmented Generation, RAG) предлага пряко решение на този проблем. Вместо да разчита единствено на параметричната памет на езиков модел, която може да бъде остаряла или неточна за специфична за България нормативна база, системата извлича релевантни откъси от актуалните ръководства и генерира отговор въз основа на тях, придружен от изричен източник: документ, страница и раздел. Именно възможността отговорът да бъде проследен до конкретен официален документ прави подхода особено подходящ за медицински контекст, в който грешен или непроверим отговор носи реален риск, а не само неудобство.

Настоящата дипломна работа надгражда резултатите от преддипломния проект [3], в който бе изграден и структуриран корпус от 1380 откъса от 17 национални фармакотерапевтични ръководства, готов за индексиране, като всеки откъс носи данни за произход (provenance): документ, страници и раздел. След преглед на научната литература (arXiv, ACL Anthology, RANLP) и общодостъпни източници на български език не беше открита

публикувана система от типа извличане с генериране, насочена конкретно към медицински или фармакотерапевтични ръководства на български език. Намерените български публикации по темата са предимно общи, популярни разяснения на подхода, а не описания на реализирана система върху национален медицински корпус. Тази празнина е допълнителна мотивация за настоящата работа: тя не само прилага установен подход към нов, специализиран корпус, но го прави за език и предметна област, за които все още липсва пряк аналог.

1.2 Цели и задачи на дипломната работа

Основната цел на тази дипломна работа е да се разработи работещ прототип на система за извличане с генериране за достъп до национални фармакотерапевтични ръководства на български език, използвайки резултатите от преддипломния проект и надграждайки с компоненти за извличане на релевантна информация и генериране на отговори.

За постигането на тази цел са поставени следните задачи:

1. аналитичен обзор на литературата по системи за извличане с генериране, методи за извличане (retrieval), приложения в областта на медицината и особености при работа с текст на български език;
2. изграждане на векторно представяне (embeddings) на структурираните в преддипломния проект текстови откъси с многоезичен модел, подходящ за българския език, и индексиране във векторна база от данни;
3. реализация на компонент за извличане на релевантна информация (retrieval) по зададена заявка;
4. проектиране и имплементиране на слой за генериране на отговори на база извлечен контекст (prompt engineering);
5. разработване на демонстрационно уеб приложение за задаване на въпроси и преглед на генерираните отговори;
6. качествен анализ на примерни резултати от системата, включващи въпроси от различни медицински области, и дискусия на наблюдаваните ограничения;
7. формулиране на изводи и препоръки за бъдещо развитие.

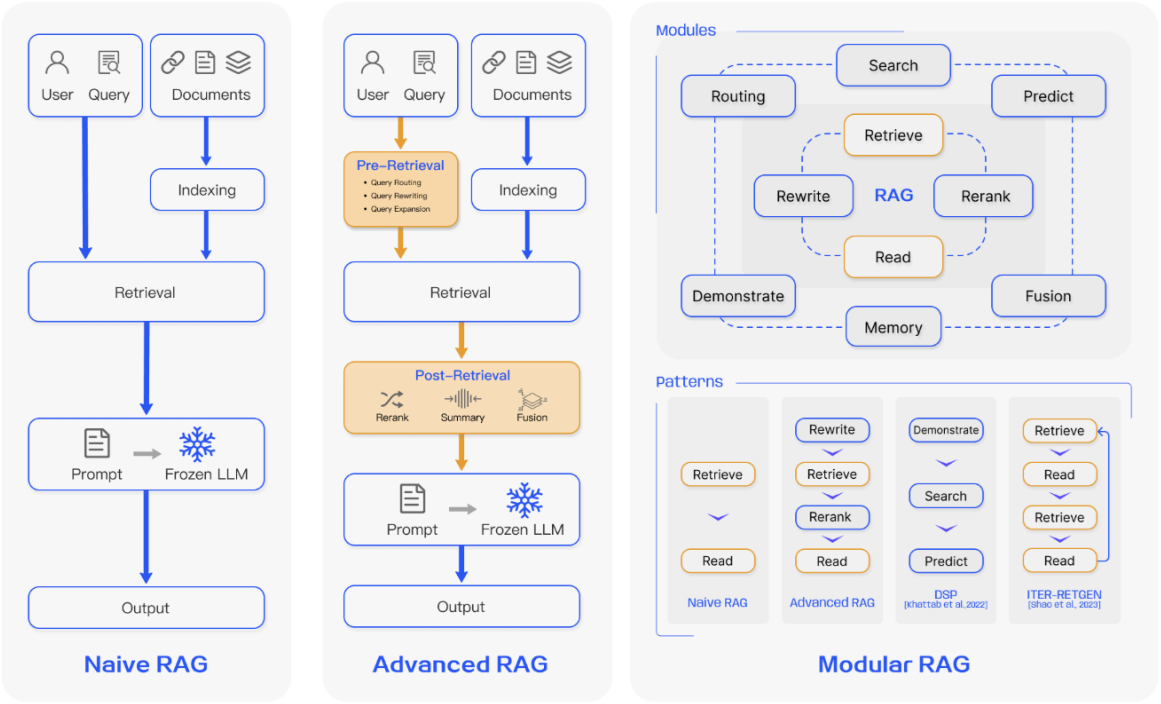
2 Литературен обзор

2.1 Архитектура и компоненти на системите за извличане с генериране

Подходът извличане с генериране (Retrieval-Augmented Generation, RAG) е предложен от Lewis и др. [4] като начин да се съчетаят параметричната памет на голям езиков модел с непараметрична памет под формата на външен, обновяем корпус от документи: вместо да разчита единствено на теглата си, моделът получава по заявка извлечени откъси и генерира отговор въз основа на тях. Тази идея решава едновременно два практически проблема: ограничената и статична памет на езиковите модели и невъзможността отговорът да бъде проверен спрямо конкретен източник. Същевременно обаче тя прехвърля тежестта на верността на отговора върху качеството на извличането, а не само върху генеративния модел.

По-новите систематизиращи прегледи очертават еволюция от тази първоначална, линейна схема, при която заявката преминава последователно през извличане, допълване на подсказката (prompt augmentation) и генериране, към т.нар. модулна архитектура, при която всеки компонент – индексиране, извличане, преработка на извлечения контекст, генериране – е независимо заменяем и може да се комбинира с допълнителни стъпки, като преформулиране на заявката или повторно класиране на резултатите [5]. Gao и др. [6] описват тази еволюция като три последователни парадигми (фигура 1): наивна (naive), при която индексирането, извличането и генерирането са свързани във верига; усъвършенствана (advanced), която запазва веригата, но добавя стъпки преди извличането, като преформулиране на заявката, и след него, като повторно класиране; и модулна (modular), при която компонентите могат да се заменят, повтарят и пренареждат. Sharma [7] систематизира съществуващите варианти в няколко ориентации, насочени съответно към подобряване на извличането, на генеративния модул, към хибридни решения и към устойчивост спрямо шумни или противоречиви извлечени откъси, и посочва качеството на извличането като най-честото тясно място в цялостната система. Като по-нататъшно развитие се откроява агентният подход (agentic RAG), при който системата итеративно решава дали и какво да извлече, вместо да следва фиксирана еднократна последователност [8]. За целите на настоящата дипломна работа подобна сложност не е оправдана, тъй като въвежда допълнителна латентност и трудности при проследяване на произхода на отговора, без да е ясно, че ще подобри резултата върху затворен и сравнително добре структуриран корпус от национални ръководства. Затова избраната отправна точка тук е модулна, но не агентна архитектура, съобразена със структурата, зададена от преддипломния проект: индексиране на откъсите, самостоятелен компонент за извличане и отделен слой за генериране, всеки от които може да бъде подобряван независимо.

Оценяването на подобни системи е отделен методологически въпрос: освен показателите за самото извличане (виж раздел 2.2), генерираният отговор трябва да бъде проверен за вярност спрямо извлечения контекст, тъй като езиковият модел може да „халюцинира“ твърдения, които не се съдържат в подадените откъси. Malin и др. [9] систематизират съществуващите показатели за вярност (faithfulness) и отбелязват, че оценяването с друг езиков модел като съдия към момента корелира най-добре с човешката преценка, докато Tamber и др. [10] предлагат постоянно обновяван еталон именно за тази цел. Тези резултати мотивират методиката за качествен анализ в тази дипломна работа (виж раз-



Фигура 1. Три парадигми на системите за извличане с генериране: наивна, усъвършенствана и модулна. Източник: Gao и др. [6], фиг. 3.

дел 4.7) да включва не само проверка на извлечения източник, но и отделна преценка доколко генерираният отговор се придържа само към предоставения контекст.

2.2 Методи за извличане и модели за векторно представяне

Класическото разграничение в извличането на информация е между лексикално извличане, което съпоставя точни думи или n-грами (например BM25), и семантично извличане, при което заявката и документите се представят като вектори в общо пространство и се сравняват чрез мярка за близост, най-често косинусова близост, независимо от точното съвпадение на думите. Лексикалното извличане е бързо, обяснимо и не изисква обучение, но пропуска синоними и перифрази. Семантичното извличане улавя смисъла, но зависи изцяло от качеството на модела за векторно представяне (embeddings) и е по-трудно за диагностициране, когато върне грешен резултат. За медицински текст, богат на синоними, съкращения и специализирана терминология, например различни търговски и генерични названия на едно и също лекарство, семантичното извличане изглежда по-подходящо. Именно поради тази специализирана терминология обаче качеството на векторното представяне не бива да се приема за дадено, а трябва да бъде проверено емпирично (виж раздел 3.2).

Що се отнася до самите модели за векторно представяне, Luo и др. [11] показват, че използването на голям езиков модел като енкодер за плътно извличане (dense retrieval) подобрява точността спрямо по-малки специализирани енкодери, но с чувствително по-висока изчислителна цена. Този компромис трябва да се претегли спрямо ограничените изчислителни ресурси на дипломна работа и необходимостта системата да отговаря

в разумно време при демонстрация. Извличането по правило се комбинира с векторна база от данни, оптимизирана за приблизително търсене на най-близки съседи. Неотдавнашно емпирично изследване на седем широко използвани системи – FAISS, Qdrant, Milvus, Weaviate, Chroma, pgvector и LanceDB – показва съществени разлики в компромиса между точност, латентност и консумация на памет в зависимост от индексиращата структура [12]. Това налага изборът на векторна база в тази дипломна работа (раздел 3.2) да бъде направен според мащаба на корпуса от преддипломния проект, тоест 1380 откъса, а не според общи препоръки за много по-големи колекции.

2.3 Приложения в областта на медицината

Систематизиращият преглед на He и др. [13] обхваща технологиите, наборите от данни и клиничните приложения на извличането с генериране в биомедицината и подчертава повтарящ се проблем: разминаване между способността на системите да извличат релевантна информация и способността им да я обосноват по проверим начин пред клиницист. Скринингов преглед на Miao и др. [14] върху 67 проучвания в областта на медицината и сестринските грижи установява, че по-голямата част от съществуващите системи са насочени към отговаряне на медицински въпроси и клинична подкрепа при вземане на решения. Приложения, изградени върху затворен корпус от официално одобрени ръководства, какъвто е разглежданият в тази работа, остават сравнително слабо застъпени: повечето изследвани системи разчитат на широки, отворени биомедицински корпуси, например PubMed, а не на регулаторно одобрен, ограничен по обхват източник.

Именно тази разлика е показателна за настоящата дипломна работа. Докато извличането от отворен уеб корпус трябва допълнително да преценява достоверността и авторитетността на всеки източник, затвореният корпус от национални фармакотерапевтични ръководства носи авторитетност „по подразбиране“, а основният риск се измества към точността на самото извличане и към честността на генеративния модул да не добавя информация извън предоставения контекст. Li и Zhu [15] формулират именно такива практически препоръки от индустриален опит за медицински системи за извличане с генериране: стриктно ограничаване на генерирания отговор до предоставения контекст, връщане на изричен източник (документ, страница, раздел) към всяко твърдение и изрично сигнализиране, когато не е намерен релевантен откъс. Тези препоръки директно съответстват на изискването за данни за произход, наследено от преддипломния проект, и са отправна точка при проектирането на слоя за генериране на отговори (раздел 3.4), където е обсъдено и доколко могат да бъдат изпълнени от малък генеративен модел.

2.4 Особености при работа с по-слабо ресурсни езици

Повечето цитирани дотук резултати са получени и оценени основно върху английски текст, което поставя въпроса доколко изводите им важат за българския език. Съществуват по същество два алтернативни подхода за извличане на информация, когато езикът на корпуса е по-слабо ресурсен. Първият е кросезиково извличане: заявката или корпусът се превежда към високоресурсен език като английски, след което се използва силен английски модел за извличане и генериране. Ranaldi и др. [16] показват, че подобен превод преди извличането подобрява резултатите върху задачи, изискващи много фактическо знание, включително за по-слабо ресурсни езици. Този подход обаче въвежда допълнителна стъпка на превод, която може да изкриви медицинска терминология, дозировки

и съкращения. Рисковете от подобно изкривяване вече бяха отчетени при OCR обработката в преддипломния проект и биха се повторили при машинен превод. Вторият подход е директна работа на изходния език чрез многоезичен или езиково специфичен модел за векторно представяне, без междинен превод. Той запазва оригиналната терминология, но изисква съответният модел действително да представя добре българския език, а не само големите езици в обучаващата му извадка.

По втория подход има насърчителни, но неоднозначни резултати. От една страна, съществуват специализирани български модели от типа BERT и RoBERTa, обучени основно за класификация, разпознаване на именувани обекти и синтактичен анализ [17, 18]. Това показва, че за българския език вече има зряла инфраструктура за представяне на текст, но тези модели не са били оценявани конкретно за задачата извличане чрез сходство на вектори, което представлява отворен въпрос. От друга страна, изследвания върху други по-слабо ресурсни езици показват, че общите многоезични модели за векторно представяне често подценяват съответния език и се нуждаят от допълнително адаптиране. Omotoso и др. [19] дообучават многоезичния модел BGE-M3 за нигерийски по-слабо ресурсни езици с осезаемо подобрение. Nzeyimana и Rubungo [20] изграждат специализиран, лексикално обоснован модел за извличане за езика киняруанда вместо да разчитат на генеричен многоезичен модел. Navasardyan и др. [21] показват, че дори малък обем шумни, синтетично генерирани данни е достатъчен за забележимо подобряване на векторното представяне на по-слабо ресурсен език. Общото между тези резултати е изводът, че годността на дадено многоезично векторно представяне за конкретен по-слабо ресурсен език не бива да се приема по подразбиране, а трябва да се провери емпирично и, при нужда, да се коригира с целево, дори ограничено по обем, дообучение.

За разлика от векторното представяне, при генеративния компонент положението за българския език е по-благоприятно. Alexandrov и др. [22] от Института по компютърни науки, изкуствен интелект и технологии (INSAIT) представят BgGPT – семейство отворени модели, получени чрез продължено предобучение на Gemma 2 върху около 100 милиарда токена, от които 85 милиарда на български, съчетано с техника за сливане на модели (branch-and-merge), ограничаваща катастрофалното забравяне на английски и общи умения при адаптирането към нов език. Моделите се разпространяват в няколко размера – 2.6, 9 и 27 милиарда параметри – с отворени тегла и готови квантувани версии за локално изпълнение, а по данни на самите автори по-малкият вариант надминава по представяне на български сравними по размер отворени модели. Наличието на специализиран за българския език генеративен модел, който може да се зарежда изцяло локално, прави обосновано генеративният компонент на настоящата система (раздел 3.4) да се базира на BgGPT, вместо на по-голям, но неспециализиран за българския език модел или на модел, достъпен само през платено API.

От направения преглед следват две методологически решения за настоящата дипломна работа. Първо, вместо предварително да се избере един модел за векторно представяне въз основа само на общите му многоезични показатели, ще бъдат съпоставени емпирично няколко кандидат-модела върху корпуса от преддипломния проект (раздел 3.2), а директният подход на изходния език ще бъде предпочетен пред превод към английски, за да се запази медицинската терминология непроменена. Второ, за генериране на отговори (раздел 3.4) ще бъде използван BgGPT, зареден локално чрез Ollama, което съответства едновременно на изискването системата да работи без връзка към платено API и на установената по-добра пригодност на този модел за българския език.

3 Методология

3.1 Корпус от данни

Корпусът е резултат от преддипломния проект [3] и се състои от 1380 откъса (chunks), получени чрез разбиване на текста на фрагменти (chunking) от 17 национални фармакотерапевтични ръководства, изтеглени от сайта на Националния съвет по цени и реимбурсиране на лекарствените продукти [1]. Всеки откъс запазва данни за произход: документ, диапазон страници, секция и идентификатор (`chunk_id`). Корпусът е публично достъпен заедно с изходния код на системата в хранилището `https://github.com/ccvetanska/MedGuideRag/tree/main/data/processed`: файлът `chunks.jsonl` съдържа откъсите, а `documents.jsonl` – извлечения текст на ръководствата по страници. Извличането, почистването и фрагментирането на текста са описани в преддипломния проект, чието хранилище съдържа и изходния код, с който е получен корпусът.

3.2 Изграждане на векторно представяне и индексиране

В съответствие с извода от литературния преглед (раздел 2.2), моделът за векторно представяне не е избран предварително, а се съпоставят три отворени, многоезични кандидата, поддържащи българския език, всеки изпълняван локално чрез библиотеката sentence-transformers: `BAAI/bge-m3` [23], `intfloat/multilingual-e5-base` [24] и `sentence-transformers/paraphrase-multilingual-mpnet-base-v2` [25], наричани по-нататък съответно bge-m3, e5-base и mpnet. При e5-base текстовете се предхождат от префиксите `query:` и `passage:`, изисквани от авторите на модела, а другите два модела не се нуждаят от тях.

За векторна база е избран FAISS, а не сървър-базирано решение като Qdrant или Milvus, разгледани в раздел 2.2: при корпус от 1380 откъса точното (а не приближено) търсене чрез `IndexFlatIP` върху нормализирани вектори – еквивалентно на косинусова близост – отнема пренебрежимо малко време, така че компромисите на приближеното търсене на най-близки съседи тук не се проявяват. За всеки кандидат-модел се изгражда отделен индекс с метаданните на откъсите (документ, страници, раздел, текст), така че моделите могат да се сравняват върху едни и същи заявки.

Таблица 1 обобщава индексирането на трите кандидата на централния процесор. Векторното представяне на корпуса с bge-m3 отнема близо два часа, около 20 пъти повече от по-леките кандидати, поради по-големия размер на модела (568 милиона параметри срещу около 278 милиона) и по-високата размерност. Това е еднократен разход, който не влияе на времето за отговор, а след преминаването към изчисления на графичния процесор (раздел 4.3) спада до 84 секунди.

Таблица 1. Резултати от индексирането на трите кандидат-модела върху корпуса от 1380 откъса.

Модел	Измерения	Размер на индекса	Време за индексиране
mpnet	768	4.0 MB	5.9 мин
e5-base	768	4.0 MB	15.9 мин
bge-m3	1024	5.4 MB	115.9 мин

Трите кандидата се различават и по характеристика, която не личи от таблица 1, но се оказва решаваща: максималната дължина на входа, която моделът обработва. Тя е 8192 токена за bge-m3, 512 за e5-base и едва 128 за mpnet, а по-дългите текстове се отрязват без предупреждение. Откъсите от преддипломния проект са с дължина около 420 думи, т.е. средно около 860 токена, като размерът им е избран преди да е известен моделът за векторно представяне. Последиците от това несъответствие са измерени в раздел 4.2.

3.3 Извличане на релевантни откъси

Компонентът за извличане приема текстова заявка и връща най-много k откъса заедно с оценка на релевантността и пълните данни за произход. В сегашния си вид той е хибриден и се състои от три последователни стъпки:

1. *Кандидати.* Заявката се търси по два независими начина: семантично, чрез векторното представяне и индекса от раздел 3.2, и лексикално, чрез функцията за класиране BM25 [26] върху същите откъси. Преди лексикалното търсене всяка дума се съкращава до първите си шест знака, за да съвпадат различните граматични форми на една и съща дума. Всеки от двата метода връща по 50 откъса.
2. *Сливане.* Двата списъка се обединяват чрез сливане по реципрочни рангове (Reciprocal Rank Fusion) [27]: всеки откъс получава сумата от $1/(60 + r)$ за всеки от списъците, в които се среща на позиция r, и за следващата стъпка се запазват първите 20.
3. *Повторно класиране (reranking).* Двадесетте кандидата се подреждат наново от модела `BAAI/bge-reranker-v2-m3`, изграден върху bge-m3. За разлика от модела за векторно представяне, той обработва заявката и откъса заедно, като кръстосан енкодер (cross-encoder) [28], и връща оценка на релевантността между 0 и 1. Запазват се най-много k откъса с оценка поне 0.1. Ако нито един откъс не достига този праг, системата не генерира отговор, а съобщава, че в ръководствата не е открита информация по въпроса.

Всяка от стъпките отговаря на конкретна слабост на по-простите алтернативи, измерена в раздел 4.3. Лексикалното търсене е добавено, защото двата метода грешат при различни въпроси и обединението им съдържа верния откъс по-често от всеки поотделно. За съкращаването на думите е предпочетено грубо отрязване (без систематично настройване на дължината от шест знака) пред морфологичен анализатор, защото не изисква допълнителен езиков ресурс, а вече подобрява съществено лексикалното търсене. Сливането използва само позициите в списъците, защото оценките на BM25 и косинусовата близост са в несравними скали, а претеглената им сума би изисквала настройване на тегло върху данни, каквито в достатъчен обем липсват. Константата 60 е препоръчаната от Cormack и др. и не е настройвана. Кръстосаният енкодер е по-точен от сравнението на независимо изчислени вектори, защото вижда заявката и откъса едновременно, но е и много по-бавен, затова се прилага само върху малък брой кандидати. Оценката му е в една и съща скала за всички заявки и затова служи и като праг за отказ. Така изискването за изрично съобщение при липса на релевантна информация (раздел 3.4) се изпълнява на ниво извличане, а не се поверява на генеративния модел.

Първоначалният вариант – само семантично търсене и k най-близки откъса – е запазен като алтернативен режим, който се избира от интерфейса. Той служи за отправна точка при сравненията и е единственият практичен режим без графичен процесор, тъй като на централния процесор повторното класиране отнема около 70 секунди на въпрос.

3.4 Генериране на отговори

За генеративния компонент е избран BgGPT (раздел 2.2) във варианта с 2.6 милиарда параметри и 4-битово квантуване, зареден локално чрез Ollama. По-големите варианти (9 и 27 милиарда параметри) изискват повече памет от наличните 6 GB на видеокартата. По-новият вариант с 4 милиарда параметри, изграден върху Gemma 3, също с 4-битово квантуване, е сравнен с избрания в раздел 4.3 и след въвеждането на проверката за неподкрепени подробности е приет по подразбиране (раздел 4.4).

Подсказката към модела е съставена по следния начин, като всяко от решенията е резултат от експериментите в раздел 4.2:

- Инструкцията и откъсите се подават в едно потребителско съобщение, като инструкцията стои след откъсите, непосредствено преди въпроса. Шаблонът за диалог (chat template) на Gemma 2 и Gemma 3 няма отделна системна роля и системното съобщение би попаднало в самото начало, най-далеч от въпроса.
- Откъсите се подреждат в обратен ред на релевантността, така че най-близкият до заявката откъс е последен, непосредствено до въпроса.
- Преносите на редове от PDF документите в текста на откъсите се заменят с интервали.
- Инструкцията изисква отговор само с информация от откъсите, но не и цитиране на източници. Източниците се показват от системата, от данните за произход на извлечените откъси, тъй като моделът измисля цитати, когато бъде помолен да ги посочи.
- Контекстният прозорец (context window) е зададен изрично на 8192 токена вместо стойността по подразбиране на Ollama от 4096 токена, при която подсказката се отрязва без предупреждение. Поради същото ограничение броят на подаваните откъси е най-много пет.
- Температурата на генериране, която управлява степента на случайност при избора на следващ токен, е нула, така че един и същ въпрос върху едни и същи откъси получава практически един и същ отговор.
- Наказанието за повторение (repeat penalty) е 1.2, а дължината на отговора е ограничена до 1024 токена, за да не зацикля моделът.
- Преди генерирането се проверява дали ключовите понятия от въпроса се срещат в показаните откъси (раздел 4.6), а след него – дали в отговора има имена на лекарства, АТС кодове и числа, които не се срещат в откъсите (раздел 4.4).
- Изреченията от отговора се съпоставят с изреченията от откъсите, а използваните части се маркират в показаните източници (раздел 4.5).

Спрямо препоръките на Li и Zhu [15] това е съзнателно отклонение: вместо моделът да посочва източник към всяко твърдение, проследимостта се постига на ниво система, като потребителят вижда точните откъси, върху които е изграден отговорът, с документа и страниците им. Изискването за изрично съобщение при липса на релевантна информация също не е поверено на модела, защото при опит да бъде изпълнено чрез инструкция той отказва да отговори и когато откъсите съдържат отговора. Решението се взема преди генерирането – чрез праг върху оценката на повторното класиране (раздели 3.3 и 4.3) и проверка дали ключовите понятия от въпроса се срещат в откъсите (раздел 4.6).

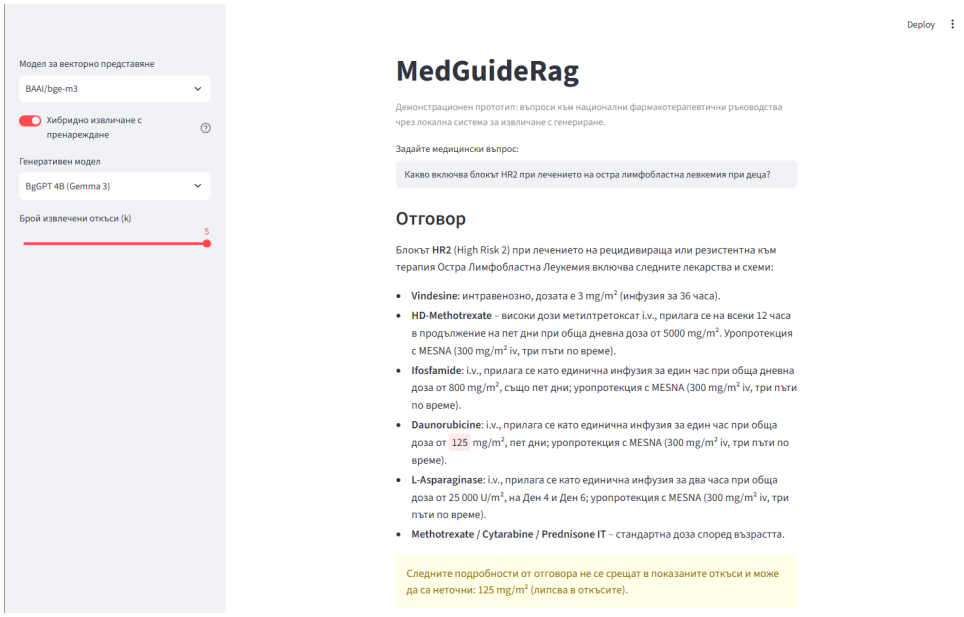
4 Експерименти и резултати

4.1 Демонстрационно приложение

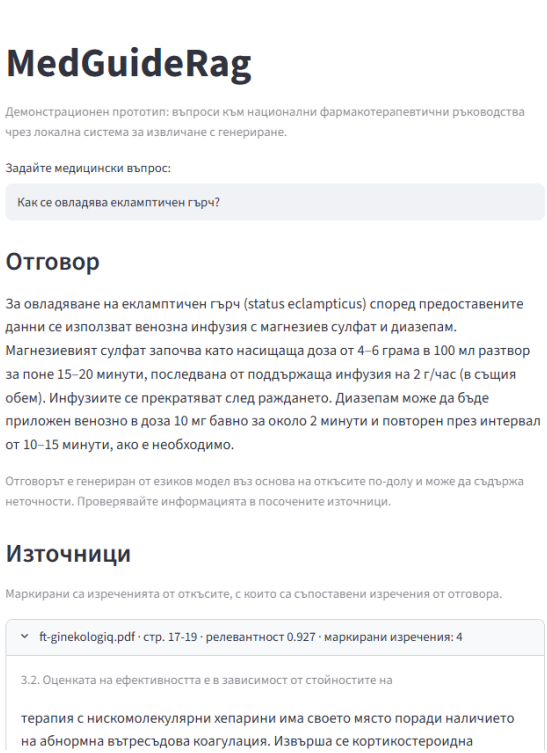
Демонстрационното приложение дава достъп до системата чрез уеб интерфейс, в който потребителят задава въпрос и вижда отговора заедно с откъсите, на които той стъпва. Описано е окончателното му състояние, а промените, довели до него, са обосновани в следващите раздели. Приложението е реализирано с библиотеката Streamlit. Разгледани са три алтернативи. Gradio е насочен преди всичко към демонстрации с един вход и един изход, докато тук резултатът се състои от отговор, предупреждения и няколко източника с маркиран текст. Отделен сървър (например Flask или FastAPI) със собствен клиент на JavaScript дава пълен контрол върху интерфейса, но изисква втори език и много повече код, което не е оправдано за прототип с един потребител. Chainlit е предназначен за разговор с история, какъвто приложението съзнателно не поддържа. Streamlit позволява целият конвейер да остане на Python.

Интерфейс. Всеки въпрос се обработва самостоятелно, без история на разговора. Историята би заела част от контекстния прозорец, който петте откъса почти изчерпват (раздел 3.4), и би смесила откъси от различни въпроси. Отговорът се показва под въпроса (фигура 2), като имената на лекарства, ATC кодовете и числата, които не се срещат в откъсите, са оцветени и изброени в предупреждение (раздел 4.4). Отговорът е придружен и от постоянна бележка, че е генериран от езиков модел и може да съдържа неточности.

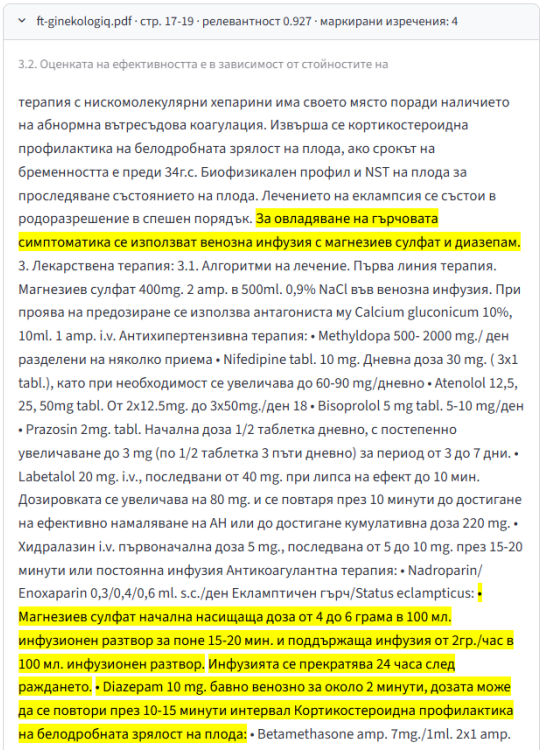
Под отговора са източниците (фигура 3). Всеки откъс е показан като разгъващ се панел, озаглавен с документа, страниците, оценката на релевантност и броя маркирани изречения, а в панела са разделът на ръководството и пълният текст на откъса с оцветени изречения, съпоставени с отговора (раздел 4.5). Ако нито един откъс не достигне прага на релевантност или ключовите понятия от въпроса не се срещат в откъсите, отговор не се генерира, а се показва съобщение за причината (фигура 4, раздели 4.3 и 4.6).



Фигура 2. Отговор с отбелязана неподкрепена подробност и предупреждение под него. Вляво са настройките на приложението.



(а) отговор



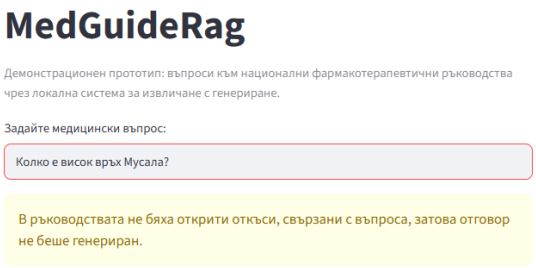
(б) разгънат първи източник

Фигура 3. Отговор и разгънатият му първи източник: изреченията от откъса, съпоставени с изречения от отговора, са оцветени.

Настройки. Страничната лента съдържа четири настройки, които позволяват част от сравненията в следващите раздели да се повторят направо в интерфейса:

- *Модел за векторно представяне* – един от трите кандидата от раздел 3.2, по подразбиране bge-m3.
- *Хибридно извличане с повторно класиране* – включено по подразбиране, когато е наличен графичен процесор. Без него системата използва само семантичното търсене.
- *Генеративен модел* – BgGPT с 4 милиарда параметри по подразбиране или вариантът с 2.6 милиарда (раздел 4.4).
- *Брой откъси* – от един до пет. При хибридното извличане откъсите могат да са по-малко, защото тези под прага се отхвърлят.

Обработка на въпрос. Приложението последователно извлича откъсите (раздел 3.3), проверява дали ключовите понятия от въпроса се срещат в тях (раздел 4.6), генерира отговора чрез Ollama, проверява го за неподкрепени подробности и съпоставя изреченията му с откъсите. Първият въпрос отнема около 35 секунди, защото тогава моделите се зареждат на графичния процесор. Следващите отговори отнемат около 6–8 секунди с модела с 4 милиарда параметри и около 5 секунди с по-малкия, а отказът – около 2 секунди. Трите заредени модела заемат около 5.7 от 6 GB видеопамет, затова в нея се побира само един генеративен модел.



Фигура 4. Отказ при въпрос извън обхвата на ръководствата: нито един откъс не достига прага и генеративният модел не се използва.

Локално изпълнение. Всички компоненти работят на машината, без връзка към външни услуги. Ollama приема заявки само на локалния адрес, а моделите за векторно представяне и за повторно класиране се зареждат от локалното хранилище на Hugging Face в режим без мрежа. Проверка на мрежовите връзки потвърждава, че в този режим приложението не осъществява нито една връзка извън машината.

Ограничения. Приложението е предназначено за един потребител: заявките към моделите се обработват последователно, а видеопаметта не оставя място за паралелна работа. Отговорът се показва след като е генериран изцяло, а не постепенно. Приложението не поддържа потребителски профили, история на въпросите или събиране на обратна връзка.

4.2 Подобряване на резултатите – съставяне на подсказката към генеративния модел

Първите опити с демонстрационното приложение показаха, че отговорите често не възпроизвеждат информацията от показаните източници, а съдържат общи или неподкрепени от тях твърдения. Характерен пример е въпросът „Как се лекува хиперемезис гравидарум?“ с модела за векторно представяне bge-m3. Извлеченият откъс от Фармакотерапевтичното ръководство по акушерство и гинекология изрежда конкретни групи лекарства: антиеметици (ondansetron, metoclopramide, фенотиазини), антисекреторни средства (esomeprazole, famotidine, ranitidine), инфузии с глюкозни разтвори и електролити, седативни средства. Генерираният отговор споменава инфузионната терапия и антисекреторните средства, но пропуска антиеметиците и добавя групи лекарства, каквито в откъса няма: антихипертензивни средства (метопролол), антикоагуланти (варфарин) и антиконвулсанти (валпроат). Разделът описва експериментите, с които бяха установени причините, и промените, които подобриха отговорите.

Протокол. Използват се три въпроса от различни области, за които корпусът съдържа отговор: хиперемезис гравидарум (акушерство и гинекология), кога се прилага инсулин при захарен диабет тип 2 (ендокринология) и лечение на атопичен дерматит (дерматология). За всеки въпрос откъсите се извличат веднъж с bge-m3 ($k = 5$) и остават фиксирани, а между вариантите се променя по един фактор на подсказката. Генерирането е с температура нула. Всеки отговор се оценява по два начина. Автоматично се брои колко от предварително изброените факти в релевантния откъс се срещат в отговора (съответно

14, 7 и 8 факта, най-често имена на лекарства и мерки). Ръчно отговорът се прочита изцяло и се отбелязват твърденията, които не се съдържат в откъсите. Автоматичната мярка отчита само наличието на ключова дума, затова при разминаване предимство има ръчният прочит.

Отрязване на подсказката. Първата находка не е свързана с формулировката на подсказката, а с размера ѝ. Пет откъса заедно с инструкцията заемат между 5500 и 6300 токена, а Ollama по подразбиране използва контекстен прозорец от 4096 токена и при препълване запазва само последната половина от него. Така подсказката е била съкратена до около 2000 токена без предупреждение, като отпадат първите откъси, които при подреждане по релевантност са и най-важните. Контекстният прозорец е увеличен до 8192 токена, а броят на откъсите е ограничен до пет.

Системна роля, цитиране и отказ. Първоначалната подсказка съдържаше правилата в системно съобщение: да се използва само предоставеният контекст, да се цитира източник във формат „[документ, стр.]“ и изрично да се съобщава, когато липсва информация. Тъй като шаблонът за диалог на Gemma 2 няма системна роля, правилата попадат в самото начало на подсказката и при отрязването ѝ са отпадали изцяло. След като бяха преместени непосредствено преди въпроса, проверката с откъси, извлечени с mpnet, разкри два по-сериозни проблема. С дословно зададена фраза за отказ моделът отговаря с нея на всички въпроси, включително на въпроса за инсулина, чийто отговор се съдържа във втория извлечен откъс. Без тази фраза моделът отговаря, но измисля източници: за контролния въпрос „Колко е висок връх Мусала?“, на който корпусът няма отговор, посочва хематологичното ръководство, а в друг вариант – несъществуващ файл „ФТР_География.pdf“. В медицински контекст измисленият източник е по-опасен от липсващия, защото придава привидна достоверност на отговора. Затова цитирането и отказът са изнесени извън генеративния модел (раздел 3.4).

Варианти на подсказката. Таблица 2 обобщава вариантите, сравнени при фиксирани откъси. Изходният вариант V0 съответства на състоянието на системата в момента на наблюдавания проблем: инструкцията е след откъсите, а контекстният прозорец е 8192 токена.

Таблица 2. Възпроизведени факти от релевантния откъс при различни варианти на подсказката (откъси, извлечени с bge-m3, температура нула).

Вариант	Описание	Хиперемезис	Инсулин	Дерматит
V0	изходен: необработен текст, 5 откъса по реда на релевантност	2/14	1/7	3/8
V1	V0 с нормализиран текст	1/14	1/7	3/8
V2	V1, най-релевантният откъс последен	7/14	2/7	4/8
V3	V2 с 3 откъса	7/14	3/7	4/8
V4	V2 с конкретизираща инструкция	9/14	5/7	4/8
V5	V4 с 3 откъса	8/14	6/7	4/8
V6	само най-релевантният откъс, конкретизираща инструкция	7/14	4/7	4/8

Ред на откъсите. Най-голямото подобрение идва от реда на откъсите (V1 спрямо V2): при въпроса за хиперемезис възпроизведените факти нарастват от 1 на 7 от 14. При подреждане по релевантност най-подходящият откъс е първи, на около 5000 токена от въпроса, и моделът на практика го пренебрегва, като съставя отговора от последните, несвързани откъси и от собствената си параметрична памет. Във варианта V1 например отговорът представя като лечение на хиперемезис вазоактивните лекарства terlipressin и octreotide от последния откъс, който описва лечението на кървене. Резултатът е в съгласие с наблюденията на Liu и др. [29], според които езиковите модели използват най-добре информацията в началото и в края на дълъг контекст. При BgGPT с 2.6 милиарда параметри ефектът е дори по-силен: позицията в началото не е достатъчна, ако между нея и въпроса има хиляди токени несвързан текст, и решаваща е близостта до въпроса.

Нормализиране на текста. Замяната на преносите на редове с интервали (V0 спрямо V1) променя броя възпроизведени факти най-много с един, но съкращава подсказката с около 6% и премахва накъсването на изреченията, затова е запазена.

Конкретизираща инструкция. Инструкция, която изрично иска да се изброят мерките, лекарствата и дозировките в откъсите (V4–V6), повишава автоматичната оценка, но ръчният прочит показва обратното: моделът попълва исканата структура с измислено съдържание. При хиперемезис добавя диетичен режим („банани, ориз и ябълково пюре“), какъвто в откъса няма, погрешни ATC кодове и дози („Ondansetron: 4 mg“), а при инсулина посочва взаимно противоречиви прагове на гликирания хемоглобин. Затова е запазена по-простата инструкция. Случаят илюстрира и ограничението на автоматичната мярка: тя отчита наличието на ключова дума, но не и верността на твърдението около нея.

Брой откъси. С три откъса (V3) отговорите остават верни спрямо източниците, а подсказката е с около 40% по-кратка. Въпреки това е запазен вариантът с пет откъса, защото при три откъса верният откъс отпада винаги, когато извличането го класира на четвърто или пето място – в набора за разработка от раздел 4.3 при два от 24 въпроса.

Температура. При температура 0.2 три последователни изпълнения на въпроса за инсулина върху едни и същи откъси дадоха три различни отговора, единият с невярно твърдение: хипогликемията е представена като показание за инсулиново лечение, докато тя е риск от него. Температура нула прави отговорите повторими и е условие за сравнимост на експериментите.

Резултат. След промените (вариант V2) отговорът за хиперемезис описва инфузиите, корекцията на електролитите, групите антиеметици, антисекреторните и седативните средства и критериите за оценка на ефективността – все сведения от откъса. Пропуснати остават хоспитализацията, покоят и диетичните препоръки, както и конкретните антиеметици.

Зависимост от извличането. Промените в подсказката подобряват отговора само когато релевантният откъс е сред извлечените. Таблица 3 показва, че при въпроса за хиперемезис това е изпълнено единствено за bge-m3. Другите два модела не извличат откъса с отговора сред първите пет, а връщат откъси от други ръководства или от друг раздел на

същото. При другите два въпроса трите модела извличат релевантни откъси и отговорите са сравними.

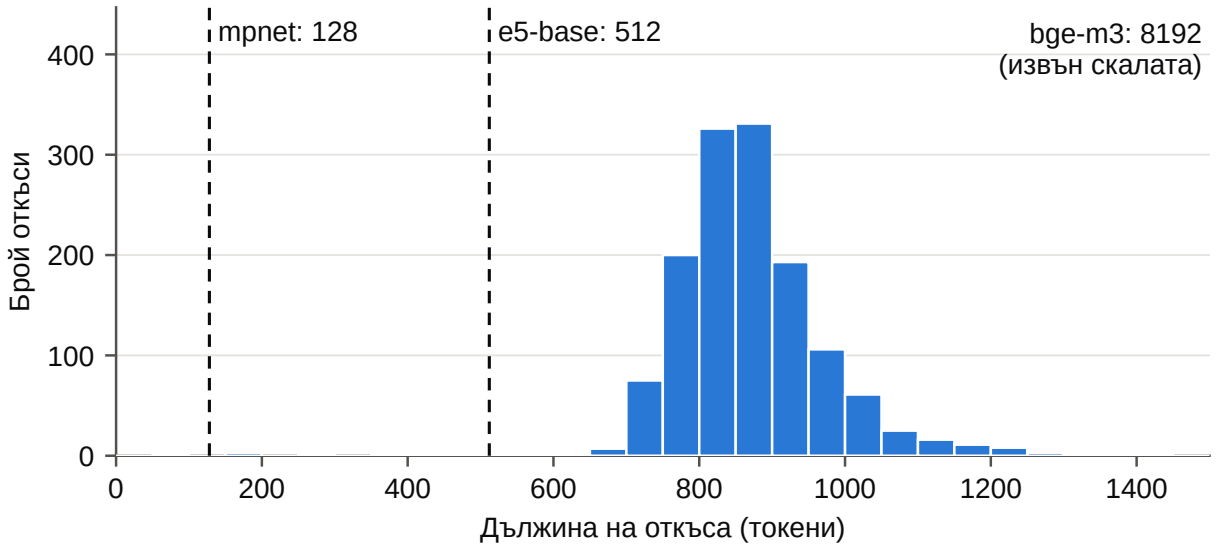
Таблица 3. Позиция на откъса с отговора сред петте извлечени и възпроизведени факти по модели за векторно представяне (подсказка V2).

Модел	Хиперемезис	Инсулин	Дерматит
bge-m3	№1; 7/14	2/7	№1; 4/8
e5-base	не е извлечен; 1/14	3/7	№1; 3/8
mpnet	не е извлечен; 1/14	2/7	№2; 4/8

Ограничение на дължината на входа. Причината е несъответствието, посочено в раздел 3.2, между дължината на откъсите и максималната дължина на входа на моделите (таблица 4). Откъсите са с медиана около 860 токена и максимум около 1410 (фигура 5). mpnet представя средно едва 15% от всеки откъс, т.е. първите около 60 думи, а в откъса за хиперемезис терминът се появява около 440-ия токен, така че моделът никога не го „вижда“. e5-base обхваща термина, но не и описанието на лечението след него. Само bge-m3 представя откъсите изцяло.

Таблица 4. Обхват на представянето на откъсите при максималната дължина на входа на всеки модел.

Модел	Макс. вход (токени)	Отрязани откъси	Представена част	Позиция на „hyperemesis“
bge-m3	8192	0%	100%	438
e5-base	512	99%	60%	439
mpnet	128	100%	15%	437



Фигура 5. Дължина на 1380-те откъса в токени и максимална дължина на входа на моделите за векторно представяне. Частта от откъса след линията на даден модел не участва в представянето му.

Следователно досегашното сравнение на трите модела не е равностойно, защото два от кандидатите се оценяват върху непълно представяне на откъсите. Размерът на откъсите е определен в преддипломния проект преди избора на модел за векторно представяне и за mpnet е неподходящ по конструкция.

Отворени проблеми.

1. *Несвързани откъси.* Когато по дадена тема корпусът съдържа един релевантен откъс, фиксираният брой $k = 5$ добавя четири несвързани. При хиперемезис сходството им е 0.59–0.60 срещу 0.65 за релевантния, така че праг, който да ги отдели, не е очевиден. След обръщането на реда те вече не влияят на отговора, но продължават да се показват като източници.
2. *Размер на откъсите спрямо ограничението на моделите.* За равностойно сравнение откъсите трябва да бъдат съобразени с максималната дължина на входа, например чрез по-кратки подоткъси.
3. *Граници на откъсите.* Откъсът за хиперемезис завършва по средата на списъка с лекарства, така че част от информацията остава в съседния откъс.
4. *Формална оценка.* Изводите в този раздел почиват на три въпроса и следва да бъдат проверени върху по-голям набор от въпроси.

4.3 Подобряване на резултатите – хибридно извличане, повторно класиране и праг за отказ

Този раздел е насочен към отворените проблеми от раздел 4.2, свързани с извличането: несвързаните откъси, неравностойното сравнение на моделите за векторно представяне и липсата на количествена оценка. За разлика от раздел 4.2, тук се сравняват методи за извличане, затова първо е съставен набор за разработка с автоматично изчислими показатели. Промяната в извличането разкри и нов проблем при генерирането, описан в края на раздела.

Набор за разработка. От всяко от 17-те ръководства е избран случайно по един откъс, а от четирите ръководства с поне 100 откъса – по два, като изборът е ограничен до откъси, в които се споменават дози. Към тях са добавени трите откъса от раздел 4.2, общо 24. За всеки откъс е формулиран въпрос, на който той отговаря, и този откъс се счита за верния резултат от извличането. Наборът служи за сравнение на варианти по време на разработката и има две ограничения. Първо, при 24 въпроса един въпрос съответства на 0.04 от всеки показател, така че разлики от един-два въпроса не са показателни. Второ, въпросите са формулирани при наличен текст на откъса и неизбежно повтарят част от думите му, което облагодетелства лексикалното търсене. Окончателната оценка върху независимо формулирани въпроси е предмет на раздел 4.7.

Показатели. Пълнотата при k (Recall@k) е делът на въпросите, при които верният откъс е сред първите k извлечени. Пълнотата при 5 съответства на броя откъси, подавани на генеративния модел, а пълнотата при 20 – на броя кандидати за повторното класиране. Средният реципрочен ранг (Mean Reciprocal Rank) е средната стойност на $1/r$, където r е позицията на верния откъс (нула, ако той не е сред първите десет), и отчита и колко високо е класиран верният откъс. Оценката е строга: за верен се приема само конкретният откъс.

Тъй като всички методи се оценяват върху едни и същи въпроси, разликите между тях се проверяват със сдвоени тестове. За пълнотата, която за всеки въпрос е „да“ или „не“, се използва точният тест на Макнемар (McNemar’s test) [30], който отчита само въпросите, при които двата метода се различават. За средния реципрочен ранг се използва рандомизационен тест (randomization test), препоръчан за оценка на извличането от Smucker и др. [31]: знакът на разликата за всеки въпрос се обръща случайно 100 000 пъти, а p-стойността е делът на случаите, в които така получената разлика в средното е поне толкова голяма, колкото наблюдаваната.

Таблица 5. Сравнение на методите за извличане върху набора за разработка (24 въпроса).

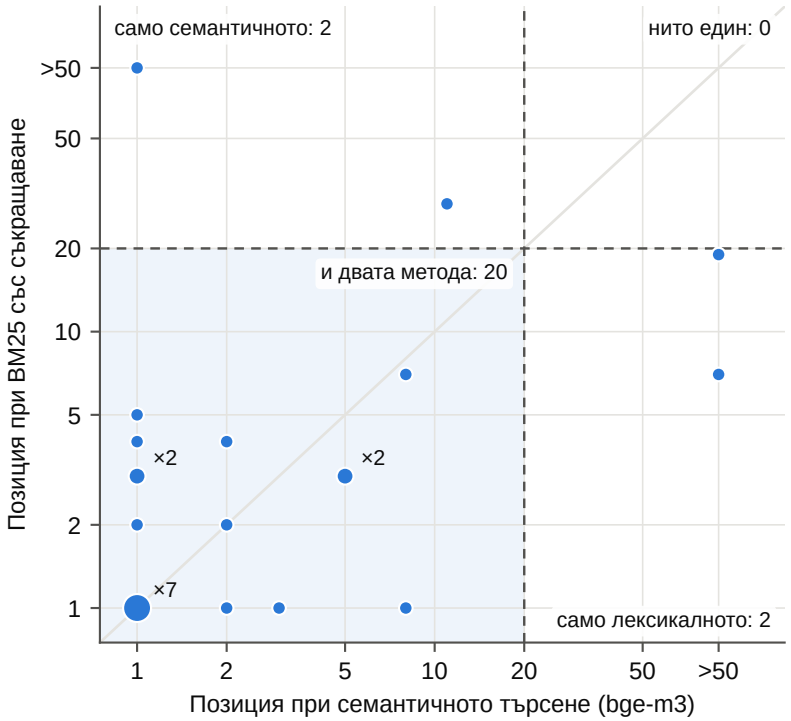
Метод	Пълнота при 1	Пълнота при 5	Пълнота при 20	Среден реципрочен ранг
Семантично търсене				
mpnet	0.04	0.25	0.46	0.15
e5-base	0.42	0.62	0.75	0.50
embeddinggemma	0.33	0.71	0.83	0.48
qwen3-embedding	0.46	0.83	0.96	0.61
bge-m3	0.54	0.79	0.92	0.65
Лексикално търсене				
BM25	0.25	0.79	0.92	0.44
BM25 със съкращаване на думите	0.42	0.79	0.92	0.55
Хибридно търсене				
сливане на bge-m3 и BM25	0.46	0.83	0.96	0.60
сливане и повторно класиране	**0.58**	**0.92**	**0.96**	**0.74**

Модели за векторно представяне. Таблица 5 потвърждава количествено наблюденията от раздел 4.2. mpnet е практически неизползваем: верният откъс е на първо място само при един от 24 въпроса и не е сред първите 20 при повече от половината. Това е единствената статистически значима разлика в таблицата ($p < 0.001$), така че моделът не може да служи дори като първа стъпка, чиито грешки да се поправят от повторното класиране. e5-base отстъпва на bge-m3 по всички показатели, в съответствие с по-непълното представяне на откъсите (таблица 4), но при 24 въпроса разликата не е значима. Като алтернативи на bge-m3 са изпробвани и два по-нови компактни многоезични модела с достатъчна дължина на входа, изпълнявани чрез Ollama: qwen3-embedding с 0.6 милиарда параметри [32] и embeddinggemma с 0.3 милиарда параметри [33]. За равностойно сравнение bge-m3 е изпълнен и по същия начин, с практически същите резултати. qwen3-embedding е наравно с bge-m3, с разлики от един-два въпроса в двете посоки, а embeddinggemma е по-слаб (среден реципрочен ранг 0.48 срещу 0.65, $p = 0.051$). Нито един от двата не дава основание за смяна на модела.

Варианти на представянето. Изпробвани са и три начина за подобряване на представянето при bge-m3: нормализиране на текста, добавяне на заглавието на ръководството и на раздела пред текста на откъса и разделяне на откъса на застъпващи се подоткъси от 120 или 200 думи, предложено в раздел 4.2. Нито един от вариантите не подобрява последователно резултата: разликите спрямо изходния вариант са от един-два въпроса в двете

посоки и не са статистически значими (най-малката p-стойност е 0.25). Вероятното обяснение е, че bge-m3 и без това обработва откъсите изцяло, а подоткъсите разделят сведения, които в заявката са свързани, например името на заболяването и описанието на лечението.

Лексикално търсене. BM25 без обработка на думите класира верния откъс на първо място едва при 6 от 24 въпроса, защото при богатата морфология на българския език „лечение“, „лечението“ и „лечения“ са различни думи за функцията за класиране. Съкращаването на всяка дума до първите шест знака, грубо приближение на основата ѝ (stemming), повишава пълнотата при 1 от 0.25 на 0.42 и средния реципрочен ранг от 0.44 на 0.55 – ясна тенденция, но не и доказано подобрение ($p = 0.22$ и 0.14). По пълнота при 5 и при 20 лексикалното търсене се изравнява с bge-m3, отчасти заради начина на съставяне на въпросите. По-важно е, че двата метода грешат при различни въпроси (фигура 6): сред първите 20 резултата всеки от тях намира верния откъс при два въпроса, при които другият не го намира, а поне единият го намира при всичките 24 въпроса.



Фигура 6. Позиция на верния откъс при семантичното търсене с bge-m3 и при лексикалното търсене BM25 със съкращаване на думите (24 въпроса, логаритмична скала). Пунктирните линии отделят първите 20 резултата, оцветената област съдържа въпросите, при които и двата метода намират верния откъс сред тях, а по-големите точки обединяват няколко въпроса с еднакви позиции.

Сливане и повторно класиране. Сливането по реципрочни рангове повишава пълнотата при 20 до 0.96, т.е. обединеният списък съдържа верния откъс при 23 от 24 въпроса. То обаче понижава пълнотата при 1 спрямо bge-m3 самостоятелно (0.46 срещу 0.54; разлика от два въпроса, $p = 0.63$), защото позицията на верния откъс се усреднява с тази от по-слабия за дадения въпрос метод. Затова сливането е само първа стъпка, последвана от повторно класиране на първите 20 кандидата. Така се постигат най-добрите стойности по всички показатели: пълнота при 1 от 0.58, пълнота при 5 от 0.92 и среден реципрочен ранг от 0.74. Спрямо bge-m3 най-голямо е подобрението при пълнотата при 5, която

определя дали верният откъс изобщо достига до генеративния модел: от 19 на 22 въпроса. Повторното класиране има и ограничение: високата оценка показва, че откъсът е тематично близък до въпроса, но не гарантира, че е от вярното ръководство. При въпроса за проследяването на бъбречната функция при хепатит B първите пет откъса са от други ръководства, с оценки от 0.78 до 0.98.

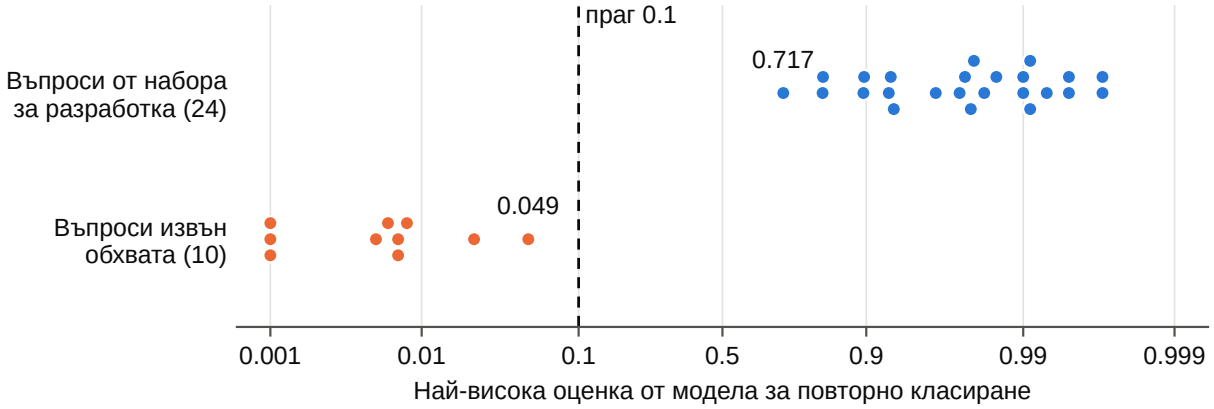
Статистическа значимост. Разликите между най-добрите методи са от порядъка на няколко въпроса и при 24 въпроса не са статистически значими (таблица 6). Хибридното извличане с повторно класиране превъзхожда bge-m3 по пълнота при 5 при три въпроса и не отстъпва при нито един, но вероятността такова разпределение да се получи случайно е 0.25. Резултатите показват последователна посока – никой от показателите на окончателния метод не е по-лош от тези на bge-m3 – но не доказват подобрение. Ако съотношението между спечелените и загубените въпроси се запази, за да се открие подобрението на пълнотата при 5 с мощност 80% при ниво на значимост 0.05, са нужни около 60 въпроса, а ако повторното класиране губи и при един от 24 въпроса – около 190 [34]. Това определя минималния размер на набора за окончателната оценка (раздел 4.7). Тестовете се изчисляват върху запазените класирания и отговори от експериментите, така че резултатът не зависи от неповторимостта на генерирането, обсъдена по-долу.

Таблица 6. Значимост на основните разлики при извличането (24 въпроса). Посочени са въпросите, при които само единият метод е успешен, и p-стойността на сдвоения тест.

Сравнение (А → Б)	Пълнота при 1: само А / само Б, p	Пълнота при 5: само А / само Б, p	Среден реципрочен ранг: А → Б, p
bge-m3 → сливане и повторно класиране	4 / 5; 1.00	0 / 3; 0.25	0.65 → 0.74; 0.27
сливане → сливане и повторно класиране	3 / 6; 0.51	0 / 2; 0.50	0.60 → 0.74; 0.095
BM25 → BM25 със съкращаване	1 / 5; 0.22	1 / 1; 1.00	0.44 → 0.55; 0.14
bge-m3 → e5-base	6 / 3; 0.51	5 / 1; 0.22	0.65 → 0.50; 0.15
bge-m3 → qwen3-embedding	4 / 2; 0.69	1 / 2; 1.00	0.65 → 0.61; 0.67
bge-m3 → mpnet	12 / 0; <0.001	13 / 0; <0.001	0.65 → 0.15; <0.001

Праг за отказ. Оценката на модела за повторно класиране е в една и съща скала за всички заявки, за разлика от косинусовата близост, чиито стойности зависят от модела за векторно представяне. Затова прагът е определен върху нея. За калибрирането освен 24-те въпроса от набора за разработка са използвани десет въпроса извън обхвата на корпуса: седем общи („Колко е висок връх Мусала?“) и три близки до медицината, но не и до фармакотерапевтичните ръководства („Каква е дозата на парацетамол за куче?“). Най-високата оценка при въпросите извън обхвата е 0.049, а най-ниската оценка на първия откъс при въпросите от набора – 0.717. Прагът 0.1 е избран в интервала между двете стойности (фигура 7), с двукратен запас над най-високата оценка извън обхвата. Така системата отказва да отговори на всичките десет въпроса извън обхвата, без да вика генеративния модел. Прагът решава и първия отворен проблем от раздел 4.2: прилага се към всеки откъс поотделно, затова несвързаните откъси отпадат. При въпроса за хиперемезис остава само релевантният откъс, с оценка 0.98, докато останалите кандидати получават най-много 0.02. От

24-те въпроса три запазват по-малко от пет откъса, като верният откъс не е отпаднал при нито един. Изводът за прага обаче почива на малък брой въпроси извън обхвата, повечето от които са далеч от темата на корпуса. Най-рискови са медицинските въпроси по теми, които ръководствата не покриват, и прагът трябва да бъде проверен върху такива въпроси при окончателната оценка.



Фигура 7. Най-висока оценка от модела за повторно класиране за всеки въпрос от набора за разработка и за всеки въпрос извън обхвата. Оста е в скала на логаритъма на шансовете (logit), която разтяга стойностите близо до 0 и до 1. Пунктирната линия е прагът за отказ.

Изчислителна цена. На централния процесор повторното класиране на 20 кандидата отнема около 70 секунди на въпрос, което е неприемливо за интерактивна система. Затова моделите за векторно представяне и за повторно класиране са преместени на графичния процесор (NVIDIA GeForce RTX 2060, 6 GB), където се изпълняват в половинна точност (fp16), т.е. с 16-битови числа с плаваща запетая вместо 32-битови. Това намалява двойно заеманата памет и е необходимо, за да се поберат всички модели в 6 GB. Таблица 7 обобщава резултата. Половинната точност не променя резултатите: подредбата след повторното класиране съвпада изцяло с получената на централния процесор, а векторните представяния на откъсите имат косинусова близост поне 0.9997 с изчислените преди това.

Таблица 7. Време за изпълнение на централния и на графичния процесор.

Задача	Централен процесор	Графичен процесор, половинна точност
Повторно класиране на 20 кандидата за един въпрос	около 70 с	0.97 с
Индексиране на корпуса с bge-m3	116 мин	84 с
Цялото извличане за един въпрос	около 70 с	около 1 с

Зацикляне при кратък контекст. Прагът за релевантност разкри нов проблем при генерирането. При въпроса за хиперемезис до модела вече достига само един откъс, в който групите лекарства са изброени заедно с АТС кодовете им, и моделът започна да повтаря едни и същи четири реда, докато не изчерпа контекстния прозорец – около две минути. При температура нула всеки следващ токен се избира като най-вероятния (алчно декодиране, greedy decoding), а този начин на декодиране е известен със склонността си към

повторения [35]. Вероятно ефектът се засилва от списъчната структура на откъса, чийто шаблон моделът продължава.

Разгледани са четири възможни мерки. Връщането към температура над нула е отхвърлено, защото в раздел 4.2 доведе до различни отговори на един и същ въпрос, единият с невярно твърдение. Ограничението на дължината на отговора спира зацикляне, но не и безсмисления текст преди това. Разширяването на прозореца, в който се отчитат повторенията, до 512 токена не спря зацикляне при предварителен опит върху шест въпроса. Затова по-подробно е сравнена силата на наказанието за повторение (repetition penalty), което намалява вероятността на токени, срещнали се сред последните обработени [36], върху 24-те въпроса от набора за разработка (таблица 8). Освен зацикляниятa и възпроизведените факти, таблицата отчита числата и ATC кодовете в отговора, които не се срещат в подадените откъси. Те са най-опасният вид неподкрепена подробност във фармакотерапията, защото изразяват дози, прагове и идентификатори на лекарства, а проверката им не изисква предварително изброени факти.

Таблица 8. Влияние на наказанието за повторение (24 въпроса, откъси от хибридното извличане, температура нула).

Наказание	Зацикляния	Факти (6 въпроса)	Числа и кодове	Отсъстващи от откъсите	Средна дължина (токени)
няма (1.0)	1	21/44	67	1	177
1.05	0	24/44	75	6	130
1.1	0	17/44	60	1	125
1.2	0	25/44	51	2	149

Избор на наказанието за повторение. Всяка от изпробваните стойности премахва зацикляне. Стойността 1.2 дава най-много възпроизведени факти, а при предварителния опит отговорът за хиперемезис съдържа 12 от 14 факта срещу 7 за варианта V2 от таблица 2. Разликата спрямо алчното декодиране (25 срещу 21 от 44 факта) не е статистически значима ($p = 0.34$ при сдвояване по факт), така че решаващо за избора е премахването на зацикляне. Числата и кодовете, отсъстващи от откъсите, са малко при всички стойности и не нарастват систематично със силата на наказанието. Ръчната проверка на отбелязаните случаи показва, че мярката открива истински грешки: ATC кодове, приписани на грешни лекарства, измислената схема на прилагане „на ден 1, 4, 7, …, 31“ и доза на ganciclovir от „8–16 mg/kg“, каквато в откъсите няма. Два от случаите са фалшиви сигнали заради различен запис на едно и също число („90,000“ срещу „90 000“). Прието е наказание 1.2 заедно с ограничение на отговора до 1024 токена, което при нормална работа (средно около 150 токена) не се достига, но ограничава времето за отговор, ако зацикляне все пак се появи.

Повторимост. Сравнението на две изпълнения на експеримента показа, че температура нула не гарантира напълно еднакви отговори. При многократно подаване на една и съща подсказка се получават до два различни отговора, които съвпадат в началото и се разклоняват на различно място. Това се наблюдава и без наказание за повторение, а фиксирането на началната стойност на генератора на случайни числа (seed) не го променя. Вероятната причина са малки числени разлики в изчисленията на графичния процесор, които при два

почти еднакво вероятни токена променят избора, а оттам и целия следващ текст. Отговорите остават близки, но разлики между вариантите от порядъка на един-два факта не са показателни: например наказание 1.2 дава 25 и 26 от 44 факта в две изпълнения с едни и същи откъси.

Генеративен модел. Като алтернатива на BgGPT с 2.6 милиарда параметри е изпробван по-новият вариант с 4 милиарда параметри, изграден върху Gemma 3, също с 4-битово квантуване. Той се зарежда изцяло на графичния процесор (2.8 GB) и генерира 66 токена в секунда срещу 83 за по-малкия модел. При шестте въпроса с изброени факти, преди въвеждането на повторното класиране и на наказанието за повторение, той възпроизвежда 32 от 44 факта срещу 22 за по-малкия модел. По-дългите му отговори обаче съдържат и повече неподкрепени подробности: при хиперемезис приписва на лекарствата АТС кодове, каквито в откъсите няма, а при еклампсията изрежда metoprolol, който не се споменава в откъсите, и пропуска посочения в тях methyldopa. Както при конкретизиращата инструкция, повече възпроизведени факти не означава по-вярен отговор. Затова по-големият модел засега не е приет, а изборът е преразгледан след въвеждането на автоматичната проверка за неподкрепени подробности (раздел 4.4).

Резултат. Стойностите на всички показатели за извличането нарастват спрямо bge-m3 самостоятелно: пълнотата при 1 от 0.54 на 0.58, пълнотата при 5 – от 0.79 на 0.92, а средният реципрочен ранг – от 0.65 на 0.74. При 24 въпроса тези разлики не са статистически значими и трябва да се потвърдят при окончателната оценка. Качествените промени обаче не зависят от размера на набора: несвързаните откъси вече не достигат до генеративния модел, системата отказва да отговори на въпроси извън обхвата на корпуса, без да вика генеративния модел, а цялото извличане отнема около секунда. Така се изпълнява и препоръката на Li и Zhu [15] за изрично съобщение при липса на релевантен откъс. Генерирането вече не зацикля.

Отворени проблеми.

1. *Неподкрепени подробности.* Моделът продължава да допуска грешни АТС кодове и дози, включително когато те са в откъса. Проверката на числата и кодовете от този раздел може да се прилага автоматично към всеки отговор, като се разшири с имената на лекарствата.
2. *Граници на откъсите.* Откъсът за хиперемезис продължава да завършва по средата на списъка с лекарства.
3. *Проверка на прага.* Прагът за отказ трябва да бъде проверен върху медицински въпроси по теми, които ръководствата не покриват.
4. *Повторимост.* Сравненията на варианти на генерирането трябва да почиват на няколко изпълнения или на разлики, по-големи от тези между отделните изпълнения.

4.4 Подобряване на резултатите – проверка на отговора за неподкрепени в откъсите детайли

Грешните АТС кодове, дози и имена на лекарства, отбелязани като първи отворен проблем в раздел 4.3, не могат да бъдат отстранени надеждно чрез подсказката, тъй като ги допускат и двата изпробвани генеративни модела. Затова всеки отговор се проверява

автоматично спрямо показаните откъси. Алтернативата – оценка на верността на целия отговор от друг езиков модел в ролята на съдия [9] – би изисквала втори модел в почти изчерпаната видеопамет и би удължила отговора. Затова проверката е детерминистична и се ограничава до три вида подробности, които във фармакотерапията носят най-голям риск и могат да бъдат проверени дословно:

- имена на лекарства, които не се срещат в откъсите;
- АТС кодове, които липсват в откъсите или в тях стоят до друго лекарство;
- числа (дози, прагове, срокове), които не се срещат в откъсите.

Отбелязаните подробности се оцветяват в отговора и се изброяват в предупреждение под него, но самият отговор не се променя. Преценката остава за потребителя, който вижда и откъсите.

Основната трудност е, че една и съща подробност се записва различно в отговора и в откъсите. Ръководствата дават лекарствата с международните им непатентни наименования (INN) на латиница, а моделът често ги пише на кирилица, затова двете форми се свеждат до обща транслитерация („метоклопрамид“ и „Metoclopramide“). Дума на кирилица се приема за име на лекарство, ако латинската ѝ форма се среща в корпуса поне толкова често, колкото тази на кирилица – иначе общи думи като „терапия“ биха били отбелязвани заради „therapy“. Кодовете в откъсите съдържат букви на кирилица и погрешно разпознати цифри („A02BAO3“ вместо A02BA03), а числата се записват с различни разделители („90 000“ и „90,000“), затова и двете се уеднаквяват преди сравнението. Имената се сравняват с допустима разлика от една или две букви, за да не се отбелязват правописни варианти.

Оценка. Проверката е приложена към всички 132 отговора от експериментите в раздел 4.3. Тя отбелязва 44 подробности в 15 отговора, от които ръчният прочит потвърждава 41 като истински грешки, т.е. 93% с 95% доверителен интервал на Уилсън (Wilson score interval) от 82 до 98% [37]. Сред тях са всички описани там грешки, несъществуващи имена на лекарства („Chlormizine“) и четири грешки, пропуснати при ръчния прочит. Трите фалшиви сигнала се дължат на превод на термин от откъса („Sodium“ за „натриев“). Пълнотата на проверката не е измерена, защото това изисква ръчна анотация на всички отговори.

Ограничения. Проверката установява дали дадена подробност се среща в откъсите, но не и дали е свързана с правилното твърдение. Доза, отнесена към друг ден от схемата, вярно име с погрешно показание и пропуснатите сведения остават неоткрити. Затова тя допълва, но не замества проверката на източниците от потребителя.

Преразглеждане на генеративния модел. С въведената проверка моделът с 4 милиарда параметри е сравнен отново с досегашния, при сегашните настройки на системата и в две изпълнения върху 24-те въпроса, които дадоха еднакви резултати. По-големият модел възпроизвежда 29 срещу 25 от 44 факта, а проверката отбелязва неподкрепена подробност в един негов отговор срещу два за по-малкия модел. Нито една от двете разлики не е статистически значима (при фактите $p = 0.45$), затова изборът почива главно на ръчния прочит. Той показва по-пълни отговори при по-големия модел, например пълната схема на магнезиевия сулфат и диазепама при еклампсия, но и грешки, които проверката не открива: дози и дни, отнесени към грешно лекарство в сложна схема на химиотерапия,

и мерна единица mg/kg вместо mg/m² при paclitaxel. Сходни грешки допуска и по-малкият модел. Затова по подразбиране е приет по-големият модел, а по-малкият остава избираем от интерфейса. Трите модела заемат заедно около 5.7 от 6 GB видеопамет, а отговорът отнема средно около 7 секунди срещу около 5 за по-малкия модел.

4.5 Подобряване на резултатите – маркиране на изреченията, на които стъпва отговорът

Системата показва до пет откъса от по около 420 думи, така че проверката на един отговор изисква прочитането на около 2000 думи. В раздел 3.4 проследимостта беше постигната на ниво откъс, като съзнателно отклонение от препоръката на Li и Zhu [15] за източник към всяко твърдение. Тук проследимостта се стеснява до изречение: в показаните откъси се маркират изреченията, на които стъпва отговорът.

Разгледани са три алтернативи. Генеративният модел да посочва сам източниците е отхвърлено, защото при експериментите в раздел 4.2 той измисляше цитати. Модел за логическо следване (natural language inference) или кръстосан енкодер върху всички двойки изречения би бил по-точен, но би добавил трети модел в почти изчерпаната видеопамет или стотици оценки на отговор. Маркирането направо в оригиналните PDF документи изисква откриване на текста по страниците, което разпознаването на сканираните документи затруднява, и е оставено за бъдещо развитие. Избраният подход съпоставя изреченията с два признака, които вече са налични в системата. Семантичният е косинусовата близост между векторните представяния, изчислени с модела, който е зареден за извличането. Лексикалният е делът от имената, числата и думите на изречението от отговора, които се срещат в изречението от откъса, като всяка дума тежи толкова повече, колкото по-рядко се среща в откъсите. Изречение от отговора се свързва с изречение от откъс, ако средното от двата признака е поне 0.45, като се допускат до три връзки, ако отговорът съчетава няколко факта. Съпоставянето не удължава забележимо отговора.

Оценка. Прагът е определен чрез ръчен преглед на най-добрите съвпадения за изреченията в отговорите на модела с 4 милиарда параметри на 24-те въпроса: под 0.45 съвпаденията бяха предимно грешни. При окончателните настройки от 93 изречения в тези отговори 87 са свързани с общо 136 изречения от откъсите, а 6 остават без съответствие. Ръчният преглед на всички 136 връзки показва, че 118 (87%, 95% доверителен интервал от 80 до 91%) сочат вярното място, 11 сочат сходен текст на друго място и 7 не могат да бъдат оценени еднозначно, защото таблица от документа е разпозната като едно дълго изречение. Типичната грешка е сходен текст в съседен раздел, например режимът за късен вместо за ранен сифилис. Тъй като прагът е определен и оценен върху едни и същи отговори, резултатът е по-скоро горна граница.

Полза. Съпоставянето допълва проверката от раздел 4.4. При въпроса за първично рефрактерната остра миелоидна левкемия откъсът с отговора не е извлечен и моделът отговаря от собствената си памет. Проверката за неподкрепени подробности не отбелязва нищо, защото отговорът не съдържа числа и имена на лекарства, но съпоставянето обозначава и петте откъса като неизползвани. Освен това погрешните твърдения често се свързват точно с мястото, което ги опровергава: дозата на paclitaxel в mg/kg сочи реда със 175 mg/m², което улеснява откриването на грешката.

Ограничения. Маркираното изречение показва откъде идва дадено твърдение, но не и че то е предадено вярно. Точността на маркирането зависи от разделянето на текста на изречения, което при таблиците и списъците в документите е грубо.

4.6 Подобряване на резултатите – проверка дали ключовите понятия от въпроса ги има в откъсите

Прагът за отказ от раздел 4.3 е калибриран върху въпроси извън обхвата, далечни от медицината, и проверката му върху медицински въпроси беше отбелязана там като отворен проблем. Затова въпросите извън обхвата в окончателния набор са медицински, а първото му пускане (раздел 4.7) потвърди опасението. И десетте такива въпроса получават откъси над прага, защото моделът за повторно класиране намира текст с общи думи – лекарството, органа или вида лечение. При шест от тях генеративният модел отговаря с подробности от несвързаните откъси, например на въпрос за ревматоиден артрит изрежда лекарства за множествена склероза. Това е най-опасният вид грешка в системата, защото отговорът изглежда уверен и се позовава на източник, а проверката за неподкрепени подробности не го открива, защото подробностите се срещат в показаните откъси.

Разгледани са три начина за решаване на проблема. По-висок праг не е решение, защото оценките на модела за повторно класиране при въпросите в обхвата и извън него се застъпват: праг, който отказва на всички въпроси извън обхвата, би отказал и на осем въпроса в обхвата (раздел 4.7). Отделна стъпка, в която генеративният модел решава дали откъсите отговарят на въпроса, добавя още едно извикване на модела, а при опита отказът да бъде поверен на модела чрез инструкция той отказваше и когато откъсите съдържат отговора (раздел 3.4). Избрана е детерминистична проверка преди генерирането дали ключовите понятия от въпроса се срещат в откъсите. Тя не изисква допълнителен модел и решението ѝ може да бъде обяснено на потребителя, като му се посочи липсващото понятие.

Ключови понятия. От въпроса се вземат думите с поне четири букви, като се пропускат въпросителните и общите за медицинските въпроси думи („лечение“, „доза“, „пациент“), глаголните форми, разпознати по окончанието, и собствените имена, които ръководствата пишат с друга транслитерация („Гилен-Баре“). Всяка дума се сравнява с текста чрез основите си с дължина от четири до шест букви, на кирилица и в латинска транслитерация, така че „ризатриптан“ съвпада с „rizatriptan“. Една дума се смята за специфична, ако основата ѝ се среща в най-много 30 от 1380-те откъса на корпуса (около 2%). Така общи думи като „хронична“ или „дете“ не влияят на решението, а имената на заболявания и лекарства влияят.

Правила. Отговор не се генерира в два случая:

- дума, която изглежда като име на лекарство (окончание от международните непатентни наименования или типично за лекарствата окончание), не се среща никъде в корпуса – „„еренумаб“ не се споменава в ръководствата“;
- въпросът съдържа специфични думи, но нито една от тях не се среща в показаните откъси – „в намерените откъси не се споменава „бизопролол“…“.

Второто правило изисква да липсват всички специфични думи, а не само една. Така въпрос, формулиран с думи, различни от тези в ръководството, продължава да получава отго-

вор, ако поне едно от ключовите му понятия е в откъсите. Въпрос без специфични думи също получава отговор.

Оценка. Проверката решава само дали да се генерира отговор, затова е оценена върху откъсите, които системата вече е извлякла: при 24-те въпроса от набора за разработка и при 69-те въпроса от първото пускане на окончателната оценка. Проверката не спира нито един въпрос в обхвата: 0 от 24 в набора за разработка и 0 от 59 в окончателния набор (95% доверителен интервал 0–6%). От десетте въпроса извън обхвата спира седем, при нито един отказ преди нея (точен тест на Макнемар, $p = 0.016$). Три са спрени от първото правило (еренумаб, семаглутид, ескетамин) и четири от второто (бизопролол, ревматоиден артрит, подагра, зъбен абсцес), сред тях и шестте въпроса, на които без проверката генеративният модел отговаряше с несвързано съдържание. Не са спрени трите въпроса, на които моделът и без това отговаря, че в откъсите няма информация. Ключовите им думи („отит“, „морбили“) се срещат в показаните откъси, но в друг контекст, например отитът като причина за фебрилни гърчове. Резултатът почти не зависи от границата за специфична дума: при граница от 5 до 80 откъса проверката спира шест или седем от въпросите извън обхвата и нито един от въпросите в обхвата на окончателния набор, а от набора за разработка – най-много един.

Ограничения. Проверката работи на ниво дума, а не на ниво смисъл. Тя не открива въпрос извън обхвата, чиято ключова дума се среща в откъсите в друг контекст, и може да откаже на въпрос в обхвата, ако ключовото му понятие е изразено с дума, каквато в ръководствата няма. За този случай съобщението посочва липсващото понятие, така че потребителят да може да преформулира въпроса. Правилата за глаголните форми и за собствените имена са уточнени при прегледа на погрешните откази на първия вариант на проверката, сред които имаше и въпроси от окончателния набор. Те са общи правила за българския език, а не изключения за отделни въпроси, и резултатът е устойчив в широк диапазон на границата. Окончателна оценка на дела на погрешните откази обаче изисква въпроси, които не са използвани при разработването на проверката.

4.7 Качествен анализ и оценка

Изводите от итерациите в раздели 4.2–4.5 почиват на набора за разработка, върху който са избирани и самите настройки. Затова окончателната оценка е проведена върху отделен набор от въпроси, съставен след края на разработката. Настройките на системата са замразени и съвпадат с тези на демонстрационното приложение по подразбиране: хибридно извличане с повторно класиране и праг 0.1, $k = 5$, BgGPT с 4 милиарда параметри с наказание за повторение 1.2, проверка за неподкрепени подробности и маркиране на източниците. След първото пускане към тях е добавена проверката на ключовите понятия от раздел 4.6, мотивирана от резултатите му при въпросите извън обхвата. Освен правилата на тази проверка, върху набора нищо не е настройвано.

Набор за оценка. Наборът съдържа 59 въпроса в обхвата на корпуса и 10 въпроса извън него. Размерът му следва от оценката на нужния брой въпроси в раздел 4.3 (около 60). Въпросите в обхвата са разпределени по всички 17 ръководства: по два от всяко, а останалите 25 – пропорционално на броя на откъсите му. Въпросите са формулирани от автора въз основа на текста на ръководствата, но така, както би ги задал лекар или фармацевт,

без преписване на изрази от откъсите, за да се избегне предимството на лексикалното търсене, отбелязано при набора за разработка. При съставянето им авторът се е допитал до български общопрактикуващ лекар. Повечето въпроси засягат дози, избор на лекарство и продължителност на лечението. За всеки въпрос, преди да бъдат видени отговорите на системата, са записани мястото в ръководството, където е отговорът (страница и дословен цитат), и между един и четири ключови факта, които верният отговор трябва да съдържа. Верните откъси са определени автоматично по цитата. Ръководствата за хепатити B и C и за възпалителните болести на червата повтарят дословно части от общото ръководство по гастроентерология, затова при съвпадащ текст и откъсът от другото ръководство се приема за верен. Същото важи за двата въпроса, на които друго ръководство отговаря със свой текст: дозата на тенофовир, която ръководството по гастроентерология и това за хепатити B и C записват различно, и лечението на болестта на Уилсън, описана и в ръководството по неврология. Правилото е приложено и след пускането: при въпроса за дозата на ентекавир показаният откъс от ръководството по гастроентерология дава същите дози като ръководството за хепатити B и C и е приет за верен. Един от верните откъси съвпада с откъс от набора за разработка.

Въпросите извън обхвата са медицински, за разлика от въпросите, използвани за калибриране на прага в раздел 4.3. Седем са по теми, които нито едно ръководство не покрива: сърдечна недостатъчност, ревматоиден артрит, подагра, хронична обструктивна белодробна болест, зъбен абсцес, остър среден отит и ваксинация срещу морбили, паротит и рубеола. Три са по теми, които ръководствата покриват, но за лекарства, които в тях не се споменават: еренумаб, семаглутид и ескетамин.

Провеждане. Системата е пусната два пъти върху всички 69 въпроса: веднъж без проверката на ключовите понятия и веднъж с нея. Отговорите, класиранията и показаните откъси от двете пускания са запазени (раздел 5.3). Извличането е детерминистично, а отговорите на въпросите в обхвата също са еднакви при двете пускания. Затова резултатите по-долу се отнасят за системата с проверката, а там, където е посочено, и за първото пускане. Медианното време е 1.0 с за извличането и 5.3 с за генерирането, а най-дългият отговор е генериран за 14.6 с. Нито един отговор не е прекъснат от ограничението на дължината.

Оценка на отговорите. Отговорите са оценени ръчно от автора с участието на общопрактикуващия лекар, с когото са обсъдени и въпросите, тъй като автоматичното броене на възпроизведени факти отчита наличието на ключова дума, но не и верността на твърдението около нея (раздел 4.2). Схемата на оценката съчетава три утвърдени подхода, всеки от които отговаря на отделен въпрос: колко от нужната информация съдържа отговорът, има ли в него невярно твърдение и колко сериозно е то. Първият подход е оценката по съществени факти (nugget evaluation), въведена в конференцията TREC за оценка на системи за отговаряне на въпроси [38] и приложена наскоро и към системи за извличане с генериране [39]. За всеки въпрос ключовите факти са записани предварително, а показателят е делът на фактите, които се срещат в отговорите. По-нататък той е наречен изчерпателност на отговора, за да не се смесва с пълнотата при извличането. Вторият подход е вярността да се оценява отделно от изчерпателността. Така постъпват Goodman и др. [40], при които лекари оценяват отговорите на езиков модел на медицински въпроси по отделни скали за точност и за пълнота, и авторите на Med-PaLM [41], при които фактическата вярност и възможната вреда са отделни оси на оценката. Всеки отговор получава една от три присъди: „верен и пълен“, ако съдържа всички ключови факти, които се отнасят за въпроса,

и няма невярно твърдение, „верен, но непълен“, ако липсва част от фактите, и „с невярно твърдение“, ако поне едно твърдение противоречи на ръководството или няма опора в него. При отговорите с невярно твърдение е отбелязана и тежестта на грешката: грешка по същество, когато тя засяга това, което въпросът пита (лекарството, дозата, показанието, популацията или продължителността), и странична неточност, когато основният отговор е верен, а грешката е в допълнителна подробност. Тежестта е определена спрямо въпроса, а не като оценка на вероятната клинична вреда. Третият подход е отчитането в строг и мек вариант, както в TREC, където двата варианта се различават по това дали се приема отговор без опора в документа [42]. При строгия вариант всяко невярно твърдение прави отговора грешен, а при мекия – само грешката по същество, докато отговорът със странична неточност се отчита като непълен. Така вярността има три степени: без невярно твърдение, със странична неточност и с грешка по същество. Освен присъдите, за всеки сигнал на проверката за неподкрепени подробности е отбелязано дали е истинска грешка, записани са грешките, които тя е пропуснала, а за всяка връзка от маркирането – дали сочи място, което подкрепя изречението от отговора. При въпросите извън обхвата, на които системата не отказва, е отбелязано дали отговорът съобщава за липса на информация, или съдържа измислено съдържание.

Извличане. Показателите са същите като в раздел 4.3. Освен строгата оценка е дадена и оценка, при която се приема и съседен откъс от същото ръководство, тъй като откъсите се застъпват и отговорът често продължава в съседния (таблица 9). Окончателният метод отново е най-добрият по всички показатели: верният откъс е първи при 58% от въпросите и е сред първите пет при 86%, а със съседните откъси пълнотата при 5 достига 0.93. Спрямо набора за разработка стойностите му се променят малко. При bge-m3 пълнотата при 5 също е близка (0.76 срещу 0.79), докато при лексикалното търсене пада от 0.79 на 0.64. Това потвърждава предположението от раздел 4.3, че въпросите от набора за разработка облагодетелстват лексикалното търсене. Сливането само по себе си не подобрява bge-m3 (0.75 срещу 0.76 при пълнота при 5), т.е. подобрението идва от модела за повторно класиране.

Таблица 9. Извличане при окончателната оценка (59 въпроса). Вляво – строга оценка, вдясно – приема се и съседен откъс от същото ръководство.

	Строго			Със съседни откъси		
Метод	П@1	П@5	СРР	П@1	П@5	СРР
mpnet	0.10	0.22	0.15	0.20	0.32	0.26
e5-base	0.39	0.64	0.50	0.51	0.75	0.61
bge-m3	0.41	0.76	0.56	0.59	0.88	0.71
BM25 със съкращаване на думите	0.34	0.64	0.47	0.49	0.83	0.62
Сливане (bge-m3 и BM25)	0.44	0.75	0.58	0.58	0.88	0.71
Сливане и повторно класиране	0.58	0.86	0.70	0.69	0.93	0.80

П@k – пълнота при k; СРР – среден реципрочен ранг.

Статистическа значимост. При 59 въпроса част от подобренията, които при набора за разработка не можеха да бъдат потвърдени, стават статистически значими (таблица 10). Спрямо bge-m3 повторното класиране подобрява пълнотата при 1 (печели при 13 въпроса и губи при 3, $p = 0.021$) и средния реципрочен ранг ($p = 0.004$). Спрямо самото сливане

то подобрява средния реципрочен ранг (p = 0.009), а при пълнотата при 5 печели при 9 въпроса и губи при 2, което е на границата на значимостта (p = 0.065). Подобрението на пълнотата при 5 спрямо bge-m3 обаче остава незначимо (p = 0.18): повторното класиране печели при 10 въпроса, но губи при 4, което съответства на по-песимистичния сценарий от раздел 4.3, изискващ около 190 въпроса. Следователно основният доказан принос на повторното класиране е в подреждането: верният откъс по-често е на първо място. Разликите между bge-m3, лексикалното търсене и e5-base не са значими, а значимо е само изоставането на mpnet.

Таблица 10. Значимост на разликите при извличането в окончателната оценка (59 въпроса, строга оценка). Означенията и тестовете са като в таблица 6.

Сравнение (А → Б)	Пълнота при 1: само А / само Б, p	Пълнота при 5: само А / само Б, p	Среден реципрочен ранг: А → Б, p
bge-m3 → сливане и повторно класиране	3 / 13; 0.021	4 / 10; 0.18	0.56 → 0.70; 0.004
сливане → сливане и повторно класиране	5 / 13; 0.096	2 / 9; 0.065	0.58 → 0.70; 0.009
bge-m3 → сливане	3 / 5; 0.73	6 / 5; 1.00	0.56 → 0.58; 0.58
bge-m3 → BM25 със съкращаване	10 / 6; 0.45	13 / 6; 0.17	0.56 → 0.47; 0.089
bge-m3 → e5-base	9 / 8; 1.00	12 / 5; 0.14	0.56 → 0.50; 0.34
bge-m3 → mpnet	18 / 0; <0.001	32 / 0; <0.001	0.56 → 0.15; <0.001

Откази. Системата не отказва на нито един въпрос в обхвата. С проверката на ключовите понятия тя отказва на седем от десетте медицински въпроса извън обхвата (95% доверителен интервал 40–89%), а без нея – на нито един. Прагът за отказ сам по себе си не спира нито един от тези въпроси. Най-високата оценка на модела за повторно класиране при тях е между 0.10 и 0.69 (медиана 0.42), при праг 0.1. При въпросите в обхвата най-ниската оценка е 0.30, а медианата – 0.96. Двата интервала се застъпват, така че никой праг не разделя напълно двете групи: праг 0.3 би отказал на три от десетте въпроса извън обхвата без погрешен отказ, праг 0.5 – на осем от тях, но и на три въпроса в обхвата, а отказът на всички въпроси извън обхвата (праг 0.7) би струвал осем погрешни отказа. При медицински въпрос моделът за повторно класиране намира откъси, свързани с отделни думи от въпроса, и им дава средни оценки.

При първото пускане, без проверката на ключовите понятия, решението дали да се отговори зависеше изцяло от генеративния модел. При четири от десетте въпроса той отговаря, че в откъсите няма такава информация. При останалите шест отговаря с подробности от несвързаните откъси: на въпроса за ревматоиден артрит изрежда лекарства за множествена склероза, на въпроса за ескетамин дава дозата на десмопресин, а на въпроса за бизопролол – доза „3–5 mg три пъти дневно“, каквато няма в нито едно ръководство, с позоваване на ръководството по хематология. Това са най-опасните грешки в оценката, защото отговорът изглежда уверен и се позовава на източник. Проверката на ключовите понятия спира и шестте въпроса, както и въпроса за еренумаба (раздел 4.6), а на останалите три системата отговаря, че в откъсите няма такава информация.

Проверка за неподкрепени подробности и маркиране. Проверката отбелязва подробности в 4 от 62-те генерирани отговора (5 сигнала), всички на въпроси в обхвата. При

първото пускане тя не отбеляза нито един от шестте отговора с несвързано съдържание на въпросите извън обхвата, защото имената и числата в тях се срещат в показаните откъси, макар и в друг контекст. Ръчният преглед показва, че от петте сигнала само един е истинска грешка – дозата „18,3 mg“, добавена към дозата на далтепарина. Останалите четири отбелязват подробности, които ги има в откъсите, но записани по друг начин, например имена на лекарства, изкривени в сканирания текст. Проверката е пропуснала една неподкрепена подробност – несъществуващото име „Викасопресин“, съставено от изкривено при сканирането име на лекарство. Повечето грешки в отговорите обаче са от друг вид: подробност, която е в показаните откъси, но се отнася за друго заболяване, лекарство или популация, и проверката по замисъл не ги открива.

Маркирането свързва изречения от отговорите с изречения от откъсите в 241 връзки, а 26 изречения остават без съответствие. От връзките 158 (66%, 95% доверителен интервал 59–71%) сочат място, което подкрепя изречението от отговора, 65 са грешни и 18 са неясни. Делът е по-нисък от този при набора за разработка (87%, раздел 4.5), защото връзката е оценявана спрямо твърдението в отговора: когато моделът е пренесъл подробност от друг раздел, маркирането сочи мястото, откъдето тя е взета, но то не подкрепя твърдението.

Вярност и изчерпателност на отговорите. Таблица 11 обобщава присъдите за 59-те отговора на въпросите в обхвата. При строгия вариант 41 отговора (69%, 95% доверителен интервал 57–80%) не съдържат невярно твърдение, като 25 от тях (42%) са и пълни. При 18 отговора има поне едно невярно твърдение. При четири от тях грешката е в странична подробност при иначе верен отговор, например добавено лекарство или доза, каквато в откъсите няма. При мекия вариант те се отчитат като непълни и делът на отговорите без грешка по същество е 76% (45 от 59, 95% доверителен интервал 64–85%). Грешка по същество съдържат 14 отговора (24%). Изчерпателността, т.е. делът на ключовите факти в отговорите, е 58% (89 от 153, 95% доверителен интервал 50–66%), като са отчетени фактите, които се отнасят пряко за въпроса. На трите въпроса извън обхвата, които проверката на ключовите понятия не спира, системата отговаря, че в откъсите няма такава информация, така че нито един от десетте въпроса извън обхвата не получава измислено съдържание.

Качеството на отговора зависи силно от извличането. При осемте въпроса, при които верният откъс не е показан, пет отговора съдържат грешка по същество, три са непълни и нито един не е пълен. При 51-те въпроса с показан верен откъс грешка по същество има в 9 отговора (18%), а 25 са верни и пълни. Разликата е статистически значима (точен тест на Фишер, $p = 0.014$).

Таблица 11. Присъди за отговорите на 59-те въпроса в обхвата.

Присъда	Строг вариант	Мек вариант
Верен и пълен	25	25
Верен, но непълен	16	20
С невярно твърдение (при мекия вариант: с грешка по същество)	18	14
Без невярно твърдение (при мекия вариант: без грешка по същество)	41 (69%)	45 (76%)

При мекия вариант четирите отговора със странична неточност се отчитат като непълни.

Анализ на грешките. Грешките са разгледани по компонентите, които ги предизвикват.

Извличане. Верният откъс не е показан на модела при 8 от 59 въпроса. Причините са няколко:

- *Разделяне на раздела при фрагментирането.* Схемата за предоперативна химиотерапия при хепатобластом е в откъс, в който думата „хепатобластом“ не се среща, защото заглавието на раздела остава в предходния откъс. Лечението на неоперабилния хепатоцелуларен карцином е в откъса след описанието на заболяването, който моделът за повторно класиране поставя на шесто място. Поддържащата терапия на острата миелоидна левкемия при деца е в откъс, обозначен с раздела за болестта на Ходжкин, в който заболяването се споменава само със съкращението AML.
- *Съкращения.* Текстът за лечението на епилептичния статус използва съкращението „EC“. Лексикалното търсене не намира откъса, а след сливането той е 21-ви – точно извън 20-те кандидата за повторно класиране.
- *Грешка на модела за повторно класиране.* При въпроса дали се спира лечението на болестта на Крон по време на бременност двата верни откъса са на шесто и осмо място след сливането, но моделът за повторно класиране ги измества на 15-о и 16-о място в полза на откъси за лечението на множествена склероза.
- *Повреден текст.* В сканираното ръководство по хематология верният откъс за полицитемия вера е осми.
- *Съседен откъс.* При два въпроса е показан съседният на верния откъс. При въпроса за лечението на хепатит B преди директно действащите антивирусни средства той съдържа продължението на отговора и отговорът е верен по същество, но се позовава на цитат, който не го подкрепя. При въпроса дали депресията може да предизвика болест на Крон съседният откъс започва непосредствено след отговора и моделът отговаря погрешно, че няма данни за връзка.

Двата случая показват, че строгата оценка и оценката със съседни откъси ограждат реалното положение, а случаят с ентекавира – че строгата оценка може да подцени извличането, когато друго ръководство дава същата информация.

Генериране. Когато верният откъс липсва, генеративният модел не отказва, а отговаря с подробности от показаните откъси, както при въпросите извън обхвата. За хепатоцелуларния карцином дава схемата FOLFIRINOX от предходния раздел за рак на панкреаса, а за болестта на Крон – спиране на natalizumab и alemtuzumab, които са лекарства за множествена склероза. При показан верен откъс 42 от 51 отговора са без грешка по същество, а грешките по същество идват главно от съседни пасажи в показаните откъси: схемата за магнезиев сулфат е дадена от раздела за преждевременно раждане, а на въпроса за астма моделът отговаря с поддържащото лечение на улцерозния колит от друг показан откъс. Останалите грешки са пропуски и разместване на подробности. При болестта на Уилсън отговорът назовава само D-penicillamine, въпреки че показаният откъс съдържа и триентин, а при хроничната миелоидна левкемия дозите са приписани на грешни лекарства, чиито имена в сканирания текст са изкривени.

Корпус. Част от грешките идват от данните, а не от системата. В ръководството по детска клинична хематология и онкология предварителната обработка е загубила много от имената на лекарствата в таблиците със схеми (например vincristine се среща 67 пъти в текста на PDF файла и само 23 пъти в откъсите), вероятно защото повтарящите се редове са премахнати като колонтитули. Затова в схемата на поддържащата терапия при острата миелоидна левкемия дозата на cytarabine е останала без името на лекарството. Около 1% от текста на PDF файловете изобщо не е влязъл в откъсите, главно таблици

с лекарства (стр. 30–37 от ръководството по урологични заболявания). Отделен случай са две ръководства, които дават една и съща информация различно. Ръководството по гастроентерология посочва за тенофовир 300 mg дневно, а ръководството за хепатити B и C – 245 mg тенофовир дизопроксил или 25 mg тенофовир алафенамид. По думите на консултиралия автора лекар в някои страни препаратът се продава в доза 300 mg, а в други – 245 mg, което вероятно е довело до разликата. При този въпрос системата показва само откъси от ръководството по гастроентерология и отговаря „300 mg веднъж дневно“, без да спомене другото ръководство. Тя третира ръководствата като независими източници и не открива, когато те си противоречат или записват едно и също различно.

Ограничения на оценката. Въпросите и ключовите факти са на автора, а присъдите за отговорите са направени с участието на общопрактикуващия лекар, с когото са обсъдени и въпросите. Съгласието между независими оценители не е измервано. При ново пускане отделни отговори могат да се различават в подробности, макар двете пускания тук да дадоха еднакви отговори в обхвата. Десетте въпроса извън обхвата са достатъчни, за да покажат, че прагът сам не разпознава медицинските въпроси извън обхвата (0 от 10 отказа, 95% доверителен интервал 0–28%) и че проверката на ключовите понятия подобрява това значимо. Те не са достатъчни обаче за точна оценка на дела на отказите, а правилата на проверката са уточнени след преглед и на въпроси от този набор (раздел 4.6). Строгата оценка на извличането подценява системата, а оценката със съседни откъси я надценява, когато съседният откъс не съдържа отговора.

Изводи. Окончателната оценка потвърждава избора на хибридно извличане с повторно класиране и прави статистически значимо подобрението му в подреждането на откъсите. От отговорите на въпросите в обхвата 69% не съдържат невярно твърдение, а 76% не съдържат грешка по същество, и нито един от въпросите извън обхвата не получава измислено съдържание. Грешките по същество са значимо по-чести, когато верният откъс не е показан, така че извличането остава решаващо за качеството на отговора. Най-сериозният проблем, който оценката разкри – отговорите на медицински въпроси извън обхвата от несвързани откъси, – е решен в седем от десетте случая от проверката на ключовите понятия, без погрешен отказ. Остават случаите, в които понятията от въпроса присъстват в показаните откъси, но в друг контекст. За тях е нужна преценка по смисъл дали откъсите отговарят на въпроса (глава 6).

5 Техническа реализация

Тази глава описва как е реализирана системата: използваните инструменти, организацията на кода и данните и средствата за проверка и възпроизвеждане на резултатите. Изборът на методите е обоснован в глави 3 и 4, а инсталирането и стартирането са описани в приложение 1.

5.1 Използвани инструменти и технологии

Системата е написана на Python, на който са и всички използвани библиотеки за работа с езикови модели, така че целият конвейер, от индексирането до уеб интерфейса, е на един език. Таблица 12 изброява инструментите с версиите, с които са получени резултатите.

Таблица 12. Използвани инструменти и модели.

Компонент	Инструмент (версия)	Роля
Език	Python 3.11.9	целият конвейер
Изчисления	PyTorch 2.14.0 (CUDA 12.6)	изпълнение на моделите за векторно представяне и повторно класиране на графичния процесор
Векторно представяне	sentence-transformers 6.0.1 (transformers 5.17.0)	зареждане на моделите, изчисляване на векторите, кръстосан енкодер
Векторна база	FAISS 1.15.0	точно търсене по косинусова близост (раздел 3.2)
Лексикално търсене	rank_bm25 0.2.2	функцията за класиране BM25
Генериране	Ollama 0.34.4 (llama.cpp), клиент ollama 0.6.2	локален сървър за генеративния модел
Уеб интерфейс	Streamlit 1.64.0	демонстрационното приложение (раздел 4.1)
Модели		
Векторно представяне	bge-m3 (по подразбиране), e5-base, mpnet (раздел 3.2)	семантично търсене; съпоставяне на изреченията (раздел 4.5)
Повторно класиране	`BAAI/bge-reranker-v2-m3`	подреждане на кандидатите и праг за отказ
Генериране	BgGPT 4B (Gemma 3) и 2.6B (Gemma 2), 4-битово квантуване (Q4_K_M)	генериране на отговора

Повечето избори вече са обосновани в предходните глави: FAISS в раздел 3.2, BgGPT в раздели 3.4 и 4.4, Streamlit в раздел 4.1, а изчисленията на графичния процесор в половинна точност в раздел 4.3. Остават два избора, които се отнасят само до реализацията.

Изпълнение на генеративния модел. Освен Ollama са разгледани три възможности за локално изпълнение на BgGPT. Библиотеката transformers зарежда теглата на модела в половинна точност, при което вариантът с 4 милиарда параметри заема около 8 GB, повече

от наличните 6 GB видеопамет, а 4-битовото квантуване с нея би изисквало допълнителни библиотеки и не би използвало публикуваните от INSAIT квантувани версии. Библиотеката llama-cpp-python използва същия изпълнителен механизъм като Ollama (llama.cpp), но за работа на графичния процесор се компилира при инсталирането, което под Windows е крехко. Сървърът vLLM е предназначен за едновременна работа на много потребители и поддържа официално само Linux. Ollama предлага готови изпълними файлове с поддръжка на CUDA, работи с квантуваните модели във формата GGUF и сам управлява зареждането и освобождаването им. Цената на това удобство е по-малкият контрол: кешът на обработените подсказки в оперативната памет, достигащ до 8 GB, не може да бъде ограничен, което на машината за разработка неколкократно изчерпа паметта при серии от заявки.

Векторни представяния. Библиотеката sentence-transformers е предпочетена пред директното използване на transformers, защото предоставя общ интерфейс за моделите за векторно представяне и за кръстосания енкодер. При директно използване на transformers обединяването на векторите на отделните токени във вектор на целия текст трябва да се реализира отделно за всеки модел (bge-m3 използва вектора на първия токен, а другите два модела – средното на всички), а грешка в тази стъпка би влошила извличането, без да е очевидна.

Машина за разработка. Системата е разработена и оценена на компютър с Windows 11, графичен процесор NVIDIA GeForce RTX 2060 с 6 GB видеопамет и 16 GB оперативна памет, от които при работа обикновено са свободни между 2 и 5 GB. Тези ограничения определиха 4-битовото квантуване на генеративния модел, половинната точност на останалите модели, еднократното им зареждане и наличието на само един генеративен модел във видеопаметта.

5.2 Структура на проекта и файлове

Кодът на системата е в пакета `src/medguiderag/` и е разделен на модули по стъпките на конвейера (таблица 13). Освен пакета проектът съдържа папката `evaluation/` със скриптовете за оценка (раздел 5.3), папката `data/` с корпуса и индексите и папката `docs/` с текста на дипломната работа.

Фигура 8 показва как модулите се свързват при обработката на въпрос. Индексирането е предварителна стъпка, която се изпълнява веднъж за всеки модел за векторно представяне, а индексът за BM25 се изгражда в паметта при стартиране, тъй като за 1380 откъса това отнема под секунда. Моделите се зареждат при първото използване и остават в паметта, като един и същ модел за векторно представяне служи и за извличането, и за съпоставянето на изреченията.

Данни. Корпусът е копие на резултата от преддипломния проект в папката `data/processed/`, така че системата не зависи от неговите файлове. Файлът `chunks.jsonl` съдържа по един ред за всеки от 1380-те откъса с текста, документа, началната и крайната страница, раздела и идентификатора, а `documents.jsonl` – текста на ръководствата по страници. За всеки модел за векторно представяне в `data/index/` има отделна папка с индекса на FAISS и метаданните на откъсите в същия ред като векторите.

Таблица 13. Модули на пакета `src/medguiderag`.

Файл	Предназначение
`config.py`	пътища до данните, модели, праг за отказ, брой кандидати, граница за редките думи
`ingest/load_chunks.py`	зареждане на откъсите от корпуса
`indexing/embed.py`	зареждане на модела за векторно представяне и изчисляване на нормализираните вектори
`indexing/build_index.py`	изграждане на индекса и метаданните за даден модел (от командния ред)
`retrieval/retriever.py`	семантично търсене в индекса
`retrieval/bm25.py`	лексикално търсене със съкращаване на думите
`retrieval/reranker.py`	модел за повторно класиране
`retrieval/hybrid.py`	хибридно извличане: сливане, повторно класиране, праг
`generation/coverage.py`	проверка дали ключовите понятия от въпроса се срещат в откъсите
`generation/generator.py`	подсказка и заявка към Ollama; премахва указанието, ако моделът го повтори в началото на отговора
`generation/grounding.py`	проверка за неподкрепени подробности
`generation/attribution.py`	съпоставяне на изреченията от отговора с откъсите
`app/ui.py`	уеб интерфейс

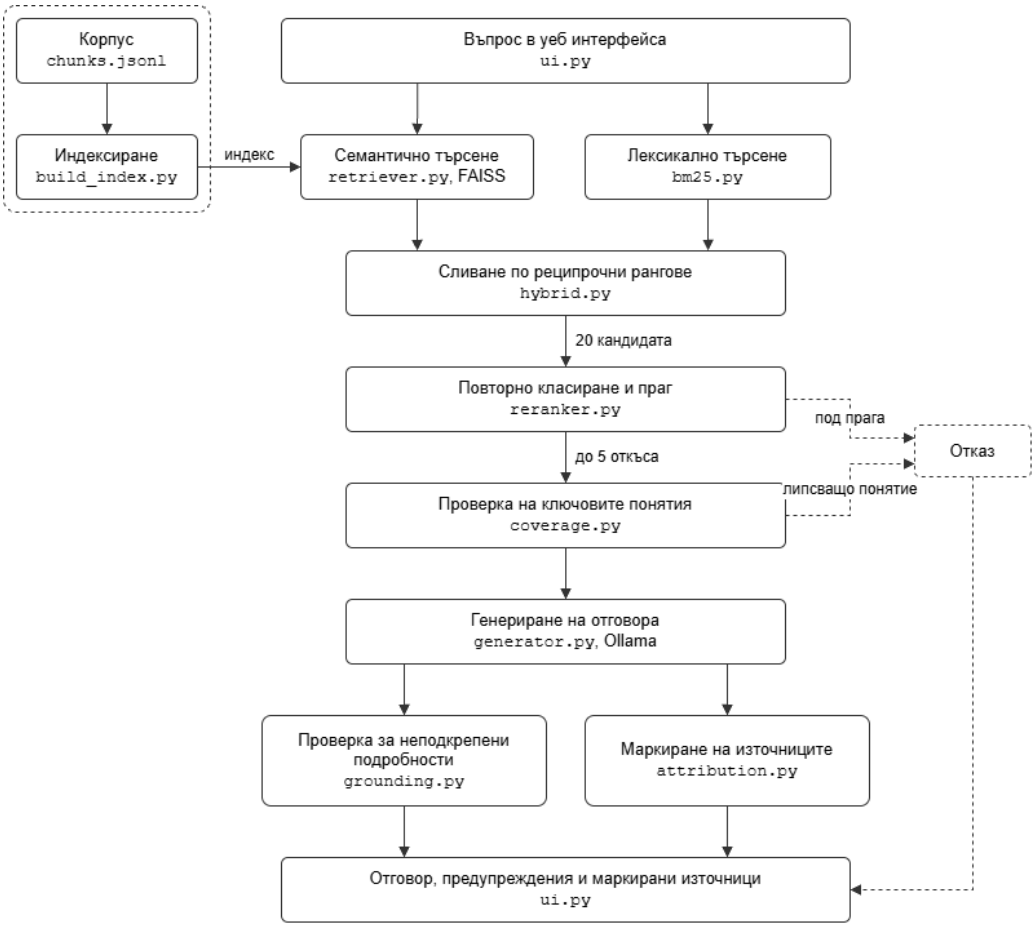
Конфигурация. Моделите, броят кандидати за повторно класиране (20), прагът за отказ (0.1) и границата за специфична дума при проверката на ключовите понятия (30 откъса) са събрани в `config.py`, а параметрите на генерирането – в `generation/generator.py`. Така смяната на модел или на праг изисква промяна на един ред.

5.3 Проверка и възпроизводимост

За модулите няма автоматизирани тестове, като това е ограничение на реализацията. Коректността е проверявана по два други начина.

Проверка на работещото приложение. След всяка промяна приложението се стартира и в него се задават въпроси, като се проверяват отговорът, предупрежденията и показаните източници, включително отказът и маркирането на източниците.

Възпроизвеждане на резултатите. Тъй като генерирането на графичния процесор не е напълно повторимо (раздел 4.3), отговорите, класиранията и ръчните оценки, върху които са изчислени числата в текста, са запазени в `evaluation/results/thesis/`. Окончателната оценка (раздел 4.7), проверката на ключовите понятия, сравнението на методите за извличане и прагът за отказ, статистическите тестове, оценките на проверката за неподкрепени подробности и на маркирането и графиките се възпроизвеждат със скриптове от папката `evaluation/`. Извличането е детерминистично, а скриптовете, които зависят от генерирани отговори, четат запазените файлове и дават точно числата от текста. Изключение правят времената за изпълнение, които зависят от натоварването на машината. Експериментите с подсказката, с представянето на откъсите и с параметрите на генерирането (раздели 4.2–4.4) са проведени с междинни версии на системата. Техните резултати са запазени, но скриптовете, с които са получени, не са част от окончателния проект.



Фигура 8. Компоненти на системата и обработката на един въпрос.

Повторното им пускане по време на разработката потвърди числата в таблиците с разлика от един факт при един от вариантите на подсказката (таблица 2).

6 Изводи и препоръки за бъдещо развитие

Окончателната оценка (раздел 4.7) и итерациите преди нея позволяват да се направят изводи както за отделните компоненти на системата, така и за данните, върху които тя работи. Тази глава ги обобщава и очертава насоките, в които системата може да бъде развита.

6.1 Изводи

Извличането определя качеството на отговора. Хибридното извличане с повторно класиране е най-добрият от изпробваните методи: верният откъс е първи при 58% от въпросите и е сред петте показани при 86% (при 93%, ако се приеме и съседният откъс). Подобрението в подреждането спрямо самото семантично търсене е статистически значимо. Значението на извличането личи пряко и в отговорите: когато верният откъс не е показан, пет от осем отговора съдържат грешка по същество, а когато е показан – 9 от 51. Затова подобренията на извличането, включително на данните, от които то зависи, имат най-голямо значение за надеждността на системата.

Защитата срещу неподкрепени отговори трябва да е на няколко нива. Всяка от проверките в системата открива различен вид грешка. Прагът върху оценката на модела за повторно класиране спира въпросите, далечни от медицината, но не и медицинските въпроси извън обхвата на ръководствата. Проверката на ключовите понятия спира седем от десетте такива въпроса без нито един погрешен отказ, а на останалите три генеративният модел сам отговаря, че в откъсите няма информация. Проверката за неподкрепени подробности открива имена и числа, които липсват в откъсите, но не и подробност, взета от неподходящ откъс. Маркирането на източниците не предотвратява грешката, но позволява на потребителя да я забележи. Нито една от проверките не е достатъчна сама по себе си, а заедно те правят грешките по-редки и по-видими.

Малкият генеративен модел е основното ограничение. Системата работи изцяло локално, без връзка с мрежата, на компютър с графичен процесор с 6 GB памет, и отговаря за около 6–8 секунди. Цената на това е генеративен модел с 4 милиарда параметри и 4-битово квантуване. Експериментите показаха характерните слабости на малките модели: те пренебрегват откъсите, отдалечени от въпроса в подсказката, измислят източници, когато бъдат помолени да цитират, попълват поискана структура с несъществуващо съдържание и при един-единствен откъс могат да зациклят. Повечето от тях са преодолени чрез устройството на подсказката и на системата. Остава обаче най-честата грешка в окончателната оценка: моделът смесва съседни пасажи от показаните откъси, като дава схемата от съседен раздел, приписва доза на друго лекарство или я отнася за друга популация. Тези грешки са най-трудни за откриване, защото всяка подробност в отговора се среща в източниците. В медицинската област системата ще бъде приета с доверие само ако такива грешки са рядко изключение, затова качеството на генеративния модел е решаващо за практическото ѝ приложение.

Проблемите в данните преминават в системата. Системата е толкова надеждна, колкото са данните, върху които работи. Изкривените при разпознаването на сканираните

документи имена на лекарства се появяват в отговорите, понякога като несъществуващи имена. Загубените при предварителната обработка имена в таблиците оставят дози без лекарство, а заглавие, отделено при фрагментирането от съдържанието на раздела, прави верния откъс невидим за извличането. Когато две ръководства записват една и съща доза различно, както при тенофовира, системата показва само едното от тях, без да предупреди за разликата.

Разнородността на ръководствата затруднява обработката. Ръководствата са писани от различни автори и колективи и се различават по структура: едни излагат препоръките в свързан текст, други – в таблици и списъци, а част от тях са сканирани. Тази разнородност е в основата на повечето проблеми с данните и не може да бъде преодоляна изцяло с общи правила за обработка. По-еднороден корпус, в който препоръките са структурирани по един и същ начин (заболяване, лекарство, доза, популация), най-вероятно би подобрил както извличането, така и отговорите. Участието на медицински специалисти при изграждането и проверката на корпуса би направило това постижимо.

6.2 Препоръки за бъдещо развитие

Версии на ръководствата. Ръководствата се обновяват периодично, но новите версии често не заменят изцяло предишните, а обновяват само отделни раздели. Така в корпуса едновременно присъстват по-стари и по-нови текстове по една и съща тема – например ръководствата за възпалителните болести на червата и за хепатитите повтарят части от общото ръководство по гастроентерология. Нужен е механизъм, който отчита датата и версията на всеки източник, дава по-голяма тежест на препоръките от по-новите ръководства и предупреждава потребителя, когато те се разминават с по-старите. Това изисква данни за взаимното отношение между ръководствата, каквито корпусът сега не съдържа, и е извън обхвата на настоящата работа.

Корпус. Фрагментирането може да следва разделите на ръководствата, като всеки откъс наследява заглавието на своя раздел, а таблиците с дози не се разделят. Разпознатият текст на сканираните документи и загубените имена на лекарства могат да бъдат проверени спрямо оригиналните документи, по възможност с участието на медицински специалисти. Откриването на откъси от различни ръководства с различни дози за едно лекарство би позволило системата да предупреди за противоречието, вместо да покаже само единия източник.

Генеративен модел. Най-голямо подобрение на отговорите може да се очаква от по-голям генеративен модел. Една възможност е по-големите варианти на BgGPT (с 9 и 27 милиарда параметри) да се изпълняват локално на по-мощен хардуер. Така се запазват предимствата на локалната работа, но е нужна значително повече видеопамет. Друга възможност е генерирането да се извършва от голям модел чрез платен програмен интерфейс (API). Тя не изисква специален хардуер, но носи разходи за всяка заявка и изнася въпросите извън компютъра на потребителя, което засяга поверителността – едно от основните опасения на лекарите в проучването от раздел 1.1. Скриптовете за окончателната оценка позволяват всеки такъв вариант да бъде сравнен със сегашния върху същите въпроси.

Проверки на отговора. Остават грешки, които сегашните детерминистични проверки не улавят: подробност, взета от неподходящ откъс, и въпрос, чиито понятия се срещат в откъсите, но в друг контекст. За тях е нужна преценка по смисъл, например проверка дали разделът, от който идва подкрепата, се отнася за заболяването от въпроса, или отделна стъпка, в която езиков модел решава дали откъсите отговарят на въпроса. Такава стъпка е по-перспективна с по-голям генеративен модел.

Оценка. Окончателната оценка може да бъде разширена с повече въпроси, с което да се потвърди и подобрението на пълнотата при 5 от повторното класиране ($p = 0.065$), с независими оценители, чието съгласие да бъде измерено, и с нови въпроси за проверката на ключовите понятия, които не са използвани при разработването ѝ.

Приложение. Маркирането на използваните изречения може да бъде пренесено в оригиналните PDF документи, така че потребителят да вижда препоръката в контекста на ръководството. За модулите на системата е добре да бъдат добавени и автоматизирани тестове.

7 Заключение

В дипломната работа е разработен работещ прототип на система за извличане с генериране за достъп до 17 национални фармакотерапевтични ръководства на български език. Изпълнени са всички поставени задачи: направен е обзор на литературата, сравнени са три модела за векторно представяне, реализирано е хибридно извличане със сливане и повторно класиране, подсказката към генеративния модел BgGPT е съставена въз основа на контролирани експерименти, изградено е демонстрационно уеб приложение, а системата е оценена върху независим набор от 69 въпроса и резултатите са анализирани по компоненти.

Системата работи изцяло локално, на компютър с потребителски хардуер, без въпросите да напускат машината, и отговаря за няколко секунди. Отговорите са придружени от източниците си с маркирани изречения и от предупреждения за неподкрепени подробности, а когато ръководствата не отговарят на въпроса, системата отказва, вместо да съставя отговор от несвързан текст. В окончателната оценка тя не дава измислен отговор на нито един от десетте въпроса извън обхвата, а 76% от отговорите на въпросите в обхвата не съдържат грешка по същество.

Принос на работата е и начинът, по който е разработена системата. Всяко решение е проверено с експеримент, разликите между вариантите са проверени със статистически тестове, а неуспешните опити също са описани. Отговорите, класиранията и ръчните оценки, върху които са изчислени числата в текста, са запазени, а окончателната оценка и статистическите тестове могат да бъдат повторени със скриптовете за оценка. Доколкото е известно на автора, това е първата система от този вид, насочена към фармакотерапевтичните ръководства на български език.

Ограниченията на системата, свързани главно с малкия генеративен модел и с качеството на данните, са описани открито и очертават ясни насоки за развитие (глава 6). Като прототип системата показва, че достъпът до официалните ръководства може да бъде улеснен със средства, които работят локално и проследимо. Тя е основа, върху която по-голям генеративен модел и по-внимателно подготвен корпус могат да доведат до инструмент, полезен в клиничната практика.

Литература

[1] Национален съвет по цени и реимбурсиране на лекарствените продукти. „Архив на утвърдени фармако-терапевтични ръководства.“ https://www.ncpr.bg/bg/архив-на-утвърдени-фармако-терапевтични-ръководства.html. Последно посещение: 06.10.2026.

[2] Пашовска, Цветелина. „Приложение на изкуствения интелект в работата на общопрактикуващите лекари в България – нагласи и предпочитания.“ Курсов проект по избираемата дисциплина „Методология на изследователската работа“, магистърска програма „Изкуствен интелект“, ФМИ, СУ „Св. Климент Охридски“ (2025). https://drive.google.com/file/d/1feuolmZadh7SvwRkg3pWH06SqLuoUsak/view

[3] Пашовска, Цветелина. „Извличане и структуриране на текст от национални фармакотерапевтични ръководства за RAG система.“ Преддипломен проект, магистърска програма „Изкуствен интелект“, ФМИ, СУ „Св. Климент Охридски“ (2026). https://github.com/ccvetanska/Pdp

[4] Lewis, Patrick et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.” *Advances in Neural Information Processing Systems* 33 (2020): 9459–9474.

[5] Wu, Shangyu et al. “Retrieval-Augmented Generation for Natural Language Processing: A Survey.” *ArXiv* abs/2407.13193 (2024).

[6] Gao, Yunfan et al. “Retrieval-Augmented Generation for Large Language Models: A Survey.” *ArXiv* abs/2312.10997 (2023).

[7] Sharma, Chaitanya. “Retrieval-Augmented Generation: A Comprehensive Survey of Architectures, Enhancements, and Robustness Frontiers.” *ArXiv* abs/2506.00054 (2025).

[8] Singh, Aditi et al. “Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG.” *ArXiv* abs/2501.09136 (2025).

[9] Malin, Ben et al. “A Review of Faithfulness Metrics for Hallucination Assessment in Large Language Models.” *ArXiv* abs/2501.00269 (2024).

[10] Tamber, Manveer Singh et al. “Benchmarking LLM Faithfulness in RAG with Evolving Leaderboards.” *ArXiv* abs/2505.04847 (2025).

[11] Luo, Kun et al. “Large Language Models as Foundations for Next-Gen Dense Retrieval: A Comprehensive Empirical Assessment.” *ArXiv* abs/2408.12194 (2024).

[12] Rashmiks, Ashen and Tiroshan Madushanka. “A Comprehensive Empirical Evaluation of Vector Database Systems for Approximate Nearest Neighbor Search: Performance, Quality, and Resource Trade-offs.” *ArXiv* abs/2608.12812 (2026).

[13] He, Jiawei et al. “Retrieval-Augmented Generation in Biomedicine: A Survey of Technologies, Datasets, and Clinical Applications.” *ArXiv* abs/2505.01146 (2025).

[14] Miao, Yiqun et al. “Improving Large Language Model Applications in the Medical and Nursing Domains With Retrieval-Augmented Generation: Scoping Review.” *Journal of Medical Internet Research* 27 (2025): e80557.

[15] Li, Liz and Wei Zhu. “Pursuing Best Industrial Practices for Retrieval-Augmented Generation in the Medical Domain.” *ArXiv* abs/2602.03368 (2026).

[16] Ranaldi, Leonardo et al. “Multilingual Retrieval-Augmented Generation for Knowledge-Intensive Task.” *ArXiv* abs/2504.03616 (2025).

[17] Marinova, Iva et al. “Transformer-Based Language Models for Bulgarian.” *Proceedings of the 14th International Conference on Recent Advances in Natural Language Processing (RANLP 2023)* (2023): 712–720.

[18] Paev, Nikolay et al. “Large Language Models for Bulgarian.” *CLaDA-BG Conference* (2024).

[19] Omotoso, Abdulmatin et al. “Improving BGE-M3 Multilingual Dense Embeddings for Nigerian Low Resource Languages.” *Proceedings of the 9th Widening NLP Workshop (WiNLP)* (2025): 224–229.

[20] Nzeyimana, Antoine and Andre Niyongabo Rubungo. “KinyaColBERT: A Lexically Grounded Retrieval Model for Low-Resource Retrieval-Augmented Generation.” *ArXiv* abs/2507.03241 (2025).

[21] Navasardyan, Zaruhi et al. “Less is More: Adapting Text Embeddings for Low-Resource Languages with Small Scale Noisy Synthetic Data.” *ArXiv* abs/2603.22290 (2026).

[22] Alexandrov, Anton et al. “BgGPT 1.0: Extending English-centric LLMs to other languages.” *ArXiv* abs/2412.10893 (2024).

[23] Chen, Jianlyu et al. “M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation.” *Findings of the Association for Computational Linguistics: ACL 2024* (2024): 2318–2335.

[24] Wang, Liang et al. “Multilingual E5 Text Embeddings: A Technical Report.” *ArXiv* abs/2402.05672 (2024).

[25] Reimers, Nils and Iryna Gurevych. “Making Monolingual Sentence Embeddings Multilingual using Knowledge Distillation.” *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (2020): 4512–4525.

[26] Robertson, Stephen and Hugo Zaragoza. “The Probabilistic Relevance Framework: BM25 and Beyond.” *Foundations and Trends in Information Retrieval* 3 (2009): 333–389.

[27] Cormack, Gordon V. et al. “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods.” *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval* (2009): 758–759.

[28] Nogueira, Rodrigo and Kyunghyun Cho. “Passage Re-ranking with BERT.” *ArXiv* abs/1901.04085 (2019).

[29] Liu, Nelson F. et al. “Lost in the Middle: How Language Models Use Long Contexts.” *Transactions of the Association for Computational Linguistics* 12 (2024): 157–173.

[30] McNemar, Quinn. “Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages.” *Psychometrika* 12 (1947): 153–157.

[31] Smucker, Mark D. et al. “A Comparison of Statistical Significance Tests for Information Retrieval Evaluation.” *Proceedings of the 16th ACM Conference on Information and Knowledge Management (CIKM)* (2007): 623–632.

[32] Zhang, Yanzhao et al. “Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models.” *ArXiv* abs/2506.05176 (2025).

[33] Schechter Vera, Henrique et al. “EmbeddingGemma: Powerful and Lightweight Text Representations.” *ArXiv* abs/2509.20354 (2025).

[34] Connor, Robert J. “Sample Size for Testing Differences in Proportions for the Paired-Sample Design.” *Biometrics* 43 (1987): 207–211.

[35] Holtzman, Ari et al. “The Curious Case of Neural Text Degeneration.” *International Conference on Learning Representations (ICLR)* (2020).

[36] Keskar, Nitish Shirish et al. “CTRL: A Conditional Transformer Language Model for Controllable Generation.” *ArXiv* abs/1909.05858 (2019).

[37] Wilson, Edwin B. “Probable Inference, the Law of Succession, and Statistical Inference.” *Journal of the American Statistical Association* 22 (1927): 209–212.

[38] Voorhees, Ellen M. “Overview of the TREC 2003 Question Answering Track.” *Proceedings of the Twelfth Text REtrieval Conference (TREC 2003)*, NIST Special Publication 500-255 (2003): 54–68.

[39] Pradeep, Ronak et al. “Initial Nugget Evaluation Results for the TREC 2024 RAG Track with the AutoNuggetizer Framework.” *ArXiv* abs/2411.09607 (2024).

[40] Goodman, Rachel S. et al. “Accuracy and Reliability of Chatbot Responses to Physician Questions.” *JAMA Network Open* 6 (2023): e2336483.

[41] Singhal, Karan et al. “Large Language Models Encode Clinical Knowledge.” *Nature* 620 (2023): 172–180.

[42] Voorhees, Ellen M. “Overview of the TREC-9 Question Answering Track.” *Proceedings of the Ninth Text REtrieval Conference (TREC-9)*, NIST Special Publication 500-249 (2000).

Приложения

Приложение 1. Инсталиране и стартиране

Командите са за Windows и се изпълняват в PowerShell или в Git Bash от основната папка на проекта. Необходими са Python 3.11, около 20 GB свободно място и за работа на графичния процесор – видеокарта NVIDIA с драйвер, поддържащ CUDA 12.6. Без нея повторното класиране е бавно и в интерфейса трябва да се изключи.

1. Генеративен модел. Инсталира се Ollama и се изтеглят двата варианта на BgGPT:

```
winget install --id Ollama.Ollama -e
ollama pull hf.co/INSAIT-Institute/BgGPT-Gemma-3-4B-IT-GGUF:Q4_K_M
ollama pull hf.co/INSAIT-Institute/BgGPT-Gemma-2-2.6B-IT-v1.0-GGUF:Q4_K_M
```

2. Среда на Python. Библиотеките се инсталират на отделни стъпки, защото общата инсталация изчерпа паметта на машината за разработка. Втората команда заменя PyTorch за централния процесор с варианта с CUDA и се пропуска без видеокарта NVIDIA:

```
python -m venv .venv
.venv/Scripts/python.exe -m pip install sentence-transformers
.venv/Scripts/python.exe -m pip install "torch==2.14.0+cu126" --index-url https://
    download.pytorch.org/whl/cu126
.venv/Scripts/python.exe -m pip install faiss-cpu ollama streamlit rank_bm25
.venv/Scripts/python.exe -m pip install -e .
```

3. Индекси и модели. Индексите се изграждат еднократно, с връзка с интернет, като се изтеглят и моделите за векторно представяне, а последната команда изтегля модела за повторно класиране. След това системата работи без мрежа:

```
.venv/Scripts/python.exe -m medguiderag.indexing.build_index "BAAI/bge-m3"
.venv/Scripts/python.exe -m medguiderag.indexing.build_index "intfloat/multilingual-
    e5-base"
.venv/Scripts/python.exe -m medguiderag.indexing.build_index "sentence-transformers/
    paraphrase-multilingual-mpnet-base-v2"
.venv/Scripts/python.exe -c "from sentence_transformers import CrossEncoder;
    CrossEncoder('BAAI/bge-reranker-v2-m3', device='cpu')"
```

4. Стартиране. Приложението се стартира с файла `start.bat`, който при нужда стартира и Ollama и ограничава броя на нишките на числовите библиотеки, или ръчно с командата по-долу. То се отваря на адрес `http://localhost:8501`, а първият въпрос отнема около 35 секунди, докато се заредят моделите:

```
.venv/Scripts/python.exe -m streamlit run src/medguiderag/app/ui.py
```

5. Възпроизвеждане на оценката. Скриптовете за оценка се изпълняват при спряно приложение с `python -m evaluation.<script>` и са описани в `evaluation/README.md`.